



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE
CENTRO DE ENGENHARIA ELÉTRICA E INFORMÁTICA
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA

SAULO JOSÉ ALMEIDA SILVA

**ANÁLISE DA MODELAGEM DE ESPAÇO DE ESTADOS NA ESTIMAÇÃO DE
SINAIS SENOIDAIS VIA FILTROS DE KALMAN LINEAR E ESTENDIDO**

Campina Grande - PB
2026

SAULO JOSÉ ALMEIDA SILVA

**ANÁLISE DA MODELAGEM DE ESPAÇO DE ESTADOS NA
ESTIMAÇÃO DE SINAIS SENOIDAIS VIA FILTROS DE KALMAN
LINEAR E ESTENDIDO**

Relatório apresentado ao Programa de Pós-Graduação
em Engenharia Elétrica (PPgEE) pela Universidade Fe-
deral de Campina Grande (UFCG), como requisito par-
cial para avaliação na disciplina de Sistemas Inteligentes

Professor: Dr. Antônio Marcus Nogueira Lima

SUMÁRIO

1	INTRODUÇÃO	1
2	FUNDAMENTAÇÃO TEÓRICA	2
2.1	Modelos Dinâmicos de Sistemas com Modelagem dos Erros	2
2.2	Discretização de Sistemas Contínuos	3
2.3	Filtro de Kalman Linear (LKF)	4
2.4	Filtro de Kalman Estendido (EKF)	6
2.5	Discretização da Covariância do Ruído de Processo	7
3	OBJETIVOS	9
4	METODOLOGIA E FORMULAÇÃO DOS MODELOS	9
4.1	Metodologia de Avaliação e Cenários de Teste	9
4.2	Formulação Matemática dos Modelos	10
4.2.1	Modelo 1: Oscilador Harmônico Linear (LKF Padrão)	10
4.2.2	Modelo 2: Estimação Não Linear de Parâmetros via EKF	12
4.2.3	Modelo 3: EKF de 2 Estados (Amplitude Conhecida)	13
4.2.4	Modelo 4: EKF Alternativo de 3 Estados (Sinal, Derivada e Frequência)	14
4.2.5	Modelo 5: EKF de 3 Estados com Frequência ao Quadrado	16
5	RESULTADOS E DISCUSSÕES	17
5.1	Análise do Modelo 1: Abordagem Linear (<i>Baseline</i>)	17
5.1.1	Testes 1 e 2: Desempenho em Cenário Nominal	18
5.1.2	Teste 3: Estresse de Ruído e Incerteza Inicial	19
5.1.3	Teste 4: Impacto da Não Discretização da Covariância Q	20
5.1.4	Conclusão da Parcial do Modelo 1	21
5.2	Análise do Modelo 2: Abordagem de Três Estados (ϕ, ω, A)	21
5.2.1	Teste 1: Cenário Nominal e Convergência Ideal	21
5.2.2	Teste 2: Inversão de Frequência 1	22
5.2.3	Teste 3: Inversão de Frequência 2	23
5.2.4	Conclusão Parcial do Modelo 2	24
5.3	Análise do Modelo 3: Redução de Ordem e Estabilização (ϕ, ω)	25
5.3.1	Teste 1: Desempenho em Cenário Nominal	25
5.3.2	Teste 2: Robustez à Inversão de Sinais e Ambiguidade	26
5.3.3	Teste 3: Convergência em Condições de Desajuste Acentuado	27
5.3.4	Conclusão Parcial do Modelo 3	28
5.4	Análise do Modelo 4: Estados Dinâmicos ($x, \dot{x}, \omega$)	29
5.4.1	Teste 1: Desempenho em Cenário Nominal	29

5.4.2	Teste 2: Resolução da Ambiguidade de Sinal	30
5.4.3	Teste 3: Robustez à Estimativa Inicial e Transiente de Adaptação	31
5.4.4	Conclusão da Parcial do Modelo 4	32
5.5	Análise do Modelo 5: Resolução via Frequência ao Quadrado $(x, \dot{x}, z)$	33
5.5.1	Teste 1: Desempenho em Cenário Nominal	33
5.5.2	Teste 2: Resolução da Ambiguidade de Sinal	34
5.5.3	Teste 3: Robustez a estimativa inicial inicial	35
5.5.4	Conclusão Parcial do Modelo 5	36
5.5.5	Síntese Comparativa da Evolução dos Modelos	37
5.6	Análise Comparativa Global	37
6	CONCLUSÃO	40
A	Solução da equação de estados homogênea	42
B	Solução geral de estados não-homogênea com ruído de processo	44
C	Linearização da dinâmica do erro de estimação para o Filtro de Kalman Estendido	45

LISTA DE FIGURAS

1	Rastreio nominal (Teste 1).	18
2	Erro de estimação (Teste 1).	18
3	Rastreio nominal (Teste 2).	19
4	Erro de estimação (Teste 2).	19
5	Rastreio sob estresse (Teste 3).	19
6	Convergência do erro (Teste 3).	19
7	Rastreio com $\mathbf{Q}$ não discretizada.	20
8	Rastreio com $\mathbf{Q}_k$ discreta.	20
9	Erro residual ($\mathbf{Q}$).	20
10	Erro residual ($\mathbf{Q}_k$).	20
11	Modelo 2: Estimativas (Teste 1).	22
12	Modelo 2: Convergências do erro (Teste 1).	22
13	Modelo 2: Estimativas de estado e sinal (Teste 2).	23
14	Modelo 2: Análise de convergência e erro (Teste 2).	23
15	Modelo 2: Estimativas de estado e sinal (Teste 3).	24
16	Modelo 2: Análise de convergência e erro (Teste 3).	24
17	Modelo 3: Estimativas (Teste 1).	26
18	Modelo 3: Convergências do erro (Teste 1).	26
19	Modelo 4: Estimativas (Teste 2).	27
20	Modelo 3: Convergências do erro (Teste 2).	27
21	Modelo 3: Estimativas (Teste 3).	28
22	Modelo 3: Convergências do erro (Teste 3).	28
23	Modelo 4: Estimativas (Teste 1).	30
24	Modelo 4: Convergências do erro (Teste 1).	30
25	Modelo 4: Estimativas (Teste 2).	31
26	Modelo 4: Convergências do erro (Teste 2).	31
27	Modelo 4: Estimativas (Teste 3).	32
28	Modelo 4: Convergências do erro (Teste 3).	32
29	Modelo 5: Estimativas (Teste 1).	34
30	Modelo 5: Convergências do erro (Teste 1).	34
31	Modelo 5: Estimativas (Teste 2).	35
32	Modelo 5: Convergências do erro (Teste 2).	35
33	Modelo 5: Estimativas (Teste 3).	36
34	Modelo 5: Convergências do erro (Teste 3).	36

LISTA DE TABELAS

1	Parâmetros de simulação para os testes do Modelo 1.	18
2	Parâmetros de simulação para os testes do Modelo 2.	21
3	Parâmetros de simulação para os testes do Modelo 3.	25
4	Parâmetros de simulação para os testes do Modelo 4.	29
5	Parâmetros de simulação para os testes do Modelo 5.	33
6	Comparativo global de Robustez e Precisão dos Modelos da Senoide	37
7	Estimativa do MSE (inicial e convergido) e tempo até quasi-estacionário (Monte Carlo, 10 execuções).	38

1 INTRODUÇÃO

A modelagem de sistemas físicos reais é inerentemente acompanhada por incertezas paramétricas e ruídos de medição, o que torna a representação puramente determinística insuficiente e exige a adoção de abordagens estocásticas, conforme discutido historicamente por Gauss (1857) e Sorenson (1970). Nesse contexto, o Filtro de Kalman (KF) (KALMAN, 1960) consolidou-se como o estimador recursivo ótimo para sistemas lineares, enquanto o Filtro de Kalman Estendido (EKF) atua como a ferramenta padrão para contornar dinâmicas não lineares através de linearizações locais (GELB et al., 1974; SIMON, 2006). Este trabalho foi desenvolvido no escopo da disciplina de Sensores Inteligentes, com o intuito de aprofundar o estudo matemático e a aplicação prática dessas técnicas de filtragem na extração confiável de informações a partir de sensores ruidosos.

A motivação central deste estudo baseia-se no clássico problema de rastreamento de sinais senoidais, introduzido de forma prática por Zarchan e Musoff (2015). A estimação dos parâmetros de uma senoide torna-se particularmente desafiadora quando a sua frequência é desconhecida, cenário que converte um modelo linear simples em um problema estritamente não linear, exigindo o uso do EKF. Contudo, a eficácia do EKF não é garantida apenas pela escolha arbitrária dos estados, estando sujeita a severas falhas de observabilidade e ambiguidades matemáticas, especialmente quando o filtro é inicializado com estimativas muito distantes da realidade física do sinal.

Para investigar esses fenômenos, o presente relatório expande a base experimental de Zarchan e Musoff (2015), conferindo maior rigor analítico às deduções das matrizes de transição e observação. O comportamento do filtro é avaliado por meio da implementação de cinco modelos matemáticos de complexidade progressiva no ambiente GNU Octave. A análise parte de um oscilador harmônico linear (utilizado como limite ótimo de desempenho) e avança por diferentes topologias não lineares, submetendo os algoritmos a testes de estresse e simulações de Monte Carlo para determinar a modelagem mais robusta contra erros de inicialização.

O presente relatório está estruturado da seguinte forma: a Seção 2 estabelece a fundamentação teórica, abrangendo a modelagem no espaço de estados, a discretização de sistemas e as equações do KF e do EKF; a Seção 3 define os objetivos principais e específicos do estudo; a Seção 4 detalha a metodologia de testes e a formulação matemática completa dos cinco modelos propostos; a Seção 5 apresenta os resultados gráficos e quantitativos obtidos nas simulações, acompanhados de suas respectivas discussões; por fim, a Seção 6 consolida as conclusões do trabalho.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Modelos Dinâmicos de Sistemas com Modelagem dos Erros

De acordo com Ogata (2010), a representação de um sistema dinâmico no espaço de estados permite descrever o comportamento interno do sistema por meio de n equações diferenciais de primeira ordem. Considere um sistema com n variáveis de estado $x_1(t), x_2(t), \dots, x_n(t)$, r variáveis de entrada $u_1(t), u_2(t), \dots, u_r(t)$ e m variáveis de saída $y_1(t), y_2(t), \dots, y_m(t)$. A dinâmica desse sistema pode ser escrita de forma explícita como:

$$\begin{cases} \dot{x}_1(t) = f_1(x_1, x_2, \dots, x_n; u_1, u_2, \dots, u_r; t) \\ \dot{x}_2(t) = f_2(x_1, x_2, \dots, x_n; u_1, u_2, \dots, u_r; t) \\ \vdots \\ \dot{x}_n(t) = f_n(x_1, x_2, \dots, x_n; u_1, u_2, \dots, u_r; t) \end{cases} \quad (1)$$

As saídas do sistema, que representam as variáveis passíveis de observação direta, podem ser expressas como:

$$\begin{cases} y_1(t) = g_1(x_1, x_2, \dots, x_n; u_1, u_2, \dots, u_r; t) \\ y_2(t) = g_2(x_1, x_2, \dots, x_n; u_1, u_2, \dots, u_r; t) \\ \vdots \\ y_m(t) = g_m(x_1, x_2, \dots, x_n; u_1, u_2, \dots, u_r; t) \end{cases} \quad (2)$$

Para simplificação e manipulação matemática, estas variáveis são agrupadas em vetores de coluna, definidos como:

$$\mathbf{x}(t) = \begin{bmatrix} x_1(t) \\ x_2(t) \\ \vdots \\ x_n(t) \end{bmatrix}, \quad \mathbf{u}(t) = \begin{bmatrix} u_1(t) \\ u_2(t) \\ \vdots \\ u_r(t) \end{bmatrix}, \quad \mathbf{y}(t) = \begin{bmatrix} y_1(t) \\ y_2(t) \\ \vdots \\ y_m(t) \end{bmatrix} \quad (3)$$

Dessa forma, o sistema dinâmico assume a forma vetorial compacta apresentada na Equação 4:

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}, \mathbf{u}, t) \\ \mathbf{y}(t) = \mathbf{g}(\mathbf{x}, \mathbf{u}, t) \end{cases} \quad (4)$$

Contudo, conforme observado por Gauss (1857) e reiterado por Sorenson (1970), a modelagem de um sistema físico real nunca é perfeita, estando sujeita a incertezas paramétricas e perturbações externas. Sob a ótica de Kalman (1960), a formulação determinística apresentada na Equação (4) é insuficiente para descrever sistemas em ambientes reais, exigindo a inclusão de termos estocásticos para representar as incertezas de processo e de medição.

Dessa forma, definem-se os vetores de ruído branco $\mathbf{w}(t) \in \mathbb{R}^n$ (processo) e $\mathbf{v}(t) \in \mathbb{R}^m$ (medição), cujas propriedades estatísticas modelam as imprecisões do modelo dinâmico e dos sensores, respectivamente. A representação evolui, então, para sua forma estocástica:

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t), t) + \mathbf{w}(t) \\ \mathbf{y}(t) = \mathbf{g}(\mathbf{x}(t), \mathbf{u}(t), t) + \mathbf{v}(t) \end{cases} \quad (5)$$

Em muitos casos, conforme cita Ogata (2010), a Equação (5) pode ser linearizada em torno de um ponto de operação nominal. Ao considerar pequenas variações em relação a esse ponto, o sistema é aproximado por um modelo linear em espaço de estados:

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{A}(t)\mathbf{x}(t) + \mathbf{B}(t)\mathbf{u}(t) + \mathbf{w}(t) \\ \mathbf{y}(t) = \mathbf{C}(t)\mathbf{x}(t) + \mathbf{D}(t)\mathbf{u}(t) + \mathbf{v}(t) \end{cases} \quad (6)$$

Nesta configuração, a dinâmica e a observação são regidas pelas matrizes de estado $\mathbf{A} \in \mathbb{R}^{n \times n}$, de entrada $\mathbf{B} \in \mathbb{R}^{n \times r}$, de saída $\mathbf{C} \in \mathbb{R}^{m \times n}$ e de transmissão direta $\mathbf{D} \in \mathbb{R}^{m \times r}$, mantendo-se as definições dos vetores de estado, entrada e saída estabelecidas anteriormente.

Caso as funções $\mathbf{f}$ e $\mathbf{g}$ não envolvam explicitamente o tempo t , então o sistema é dito invariante no tempo (OGATA, 2010), reduzindo-se a:

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t) + \mathbf{w}(t) \\ \mathbf{y}(t) = \mathbf{C}\mathbf{x}(t) + \mathbf{D}\mathbf{u}(t) + \mathbf{v}(t) \end{cases} \quad (7)$$

2.2 Discretização de Sistemas Contínuos

A discretização é o processo de converter funções, sinais ou modelos definidos no domínio do tempo contínuo em sequências de valores correspondentes no domínio do tempo discreto. Segundo Ogata (2010), essa etapa é essencial para que modelos dinâmicos baseados em equações diferenciais possam ser processados por computadores digitais, que operam em intervalos de tempo discretos.

O processo de amostragem consiste em observar o estado do sistema a cada intervalo de tempo constante T , denominado período de amostragem. Assim, a variável de tempo contínuo t é substituída por kT , onde $k = 0, 1, 2, \dots$ representa o passo de simulação.

Para demonstrar o processo de discretização do modelo de estados linear e invariante no tempo, considera-se a equação diferencial completa do sistema, englobando as parcelas determinísticas e as incertezas de modelagem (ruído de processo):

$$\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t) + \mathbf{w}(t) \quad (8)$$

A solução geral desta equação diferencial linear, conforme demonstrado passo a passo no Anexo B, para um instante de tempo $t > t_0$, é obtida através da superposição das integrais de

convolução:

$$\mathbf{x}(t) = e^{\mathbf{A}(t-t_0)}\mathbf{x}(t_0) + \int_{t_0}^t e^{\mathbf{A}(t-\tau)}\mathbf{B}\mathbf{u}(\tau)d\tau + \int_{t_0}^t e^{\mathbf{A}(t-\tau)}\mathbf{w}(\tau)d\tau \quad (9)$$

Para transpor essa solução contínua para o formato recursivo de tempo discreto, define-se $t_0 = kT$ e $t = (k+1)T$. Assume-se ainda a premissa do Segurador de Ordem Zero (*Zero-Order Hold* - ZOH) para o sinal de controle, onde a entrada $\mathbf{u}(t)$ é mantida constante entre os instantes de amostragem, ou seja, $\mathbf{u}(t) = \mathbf{u}(kT)$ para $kT \leq t < (k+1)T$. Aplicando estas condições, a evolução do estado em um passo de integração resulta em:

$$\begin{aligned} \mathbf{x}((k+1)T) = & e^{\mathbf{A}T}\mathbf{x}(kT) + \left(\int_{kT}^{(k+1)T} e^{\mathbf{A}((k+1)T-\tau)}d\tau \right) \mathbf{B}\mathbf{u}(kT) \\ & + \int_{kT}^{(k+1)T} e^{\mathbf{A}((k+1)T-\tau)}\mathbf{w}(\tau)d\tau \end{aligned} \quad (10)$$

Realizando uma mudança de variável $\lambda = (k+1)T - \tau$ nas integrais, a expressão assume a forma compacta de uma equação de diferenças estocástica:

$$\mathbf{x}_{k+1} = \mathbf{F}\mathbf{x}_k + \mathbf{G}\mathbf{u}_k + \mathbf{w}_k \quad (11)$$

Onde a matriz discreta de transição de estados ($\mathbf{F}$), a matriz discreta de entrada ($\mathbf{G}$) e o vetor de ruído de processo discreto ($\mathbf{w}_k$) são definidos, respectivamente, por:

$$\mathbf{F} = e^{\mathbf{A}T}, \quad \mathbf{G} = \left(\int_0^T e^{\mathbf{A}\lambda}d\lambda \right) \mathbf{B}, \quad \mathbf{w}_k = \int_0^T e^{\mathbf{A}\lambda}\mathbf{w}((k+1)T - \lambda)d\lambda \quad (12)$$

Nesta formulação final, $\mathbf{F}$ descreve como o estado evolui naturalmente no intervalo T , $\mathbf{G}$ quantifica o efeito do controle constante $\mathbf{u}_k$ sobre o estado, e $\mathbf{w}_k$ representa o efeito acumulado das perturbações contínuas durante o mesmo período de amostragem.

2.3 Filtro de Kalman Linear (LKF)

O Filtro de Kalman, introduzido originalmente por Kalman (1960), é um algoritmo ótimo de processamento de dados recursivo. Ele resolve o problema de estimativa de estado para sistemas dinâmicos lineares de tempo discreto, minimizando a variância do erro de estimação, desde que os ruídos do sistema atendam a critérios estatísticos específicos. A sua formulação matemática apoia-se fortemente na teoria de controle moderno que, conforme estabelecido por Ogata (2010), baseia-se na representação de sistemas no espaço de estados, viabilizando o tratamento de problemas complexos através de operações matriciais no domínio do tempo.

Para a formulação do filtro linear padrão (LKF), toma-se como base o modelo discreto deduzido na Seção 2.2. A dinâmica do sistema e a equação de observação (medição) no instante

de tempo k são expressas como:

$$\begin{cases} \mathbf{x}_k = \mathbf{F}\mathbf{x}_{k-1} + \mathbf{G}\mathbf{u}_{k-1} + \mathbf{w}_{k-1} \\ \mathbf{y}_k = \mathbf{H}\mathbf{x}_k + \mathbf{v}_k \end{cases} \quad (13)$$

Onde $\mathbf{F}$ é a matriz de transição de estados, $\mathbf{G}$ é a matriz de entrada, e $\mathbf{H}$ é a matriz de observação (análoga à matriz $\mathbf{C}$ da formulação contínua da Equação 7). Assume-se que a matriz de transmissão direta $\mathbf{D}$ é nula, cenário comum na maioria dos sistemas físicos onde não há acoplamento instantâneo entre entrada e medição.

Uma premissa fundamental do LKF é que o ruído de processo $\mathbf{w}_k$ e o ruído de medição $\mathbf{v}_k$ são modelados como processos estocásticos de ruído branco, mutuamente independentes, com distribuição Gaussiana normal e média zero. Suas matrizes de covariância são definidas por:

$$E[\mathbf{w}_k \mathbf{w}_j^T] = \mathbf{Q} \delta_{ij} = \begin{cases} \mathbf{Q}, & k = j \\ \mathbf{0}, & k \neq j \end{cases}, \quad E[\mathbf{v}_k \mathbf{v}_j^T] = \mathbf{R} \delta_{ij} = \begin{cases} \mathbf{R}, & k = j \\ \mathbf{0}, & k \neq j \end{cases} \quad (14)$$

Onde $\mathbf{Q}$ é a matriz de covariância do ruído de processo e $\mathbf{R}$ é a matriz de covariância do ruído de medição.

A lógica de funcionamento do algoritmo divide-se recursivamente em duas etapas principais: a **Predição** (atualização no tempo) e a **Correção** (atualização de medição).

Etapa 1: Predição (Time Update)

Nesta fase, o filtro utiliza o modelo matemático dinâmico para projetar o estado atual e a covariância do erro um passo à frente no tempo, antes que a nova medição $\mathbf{y}_k$ seja processada. Denotando $\hat{\mathbf{x}}_{k|k-1}$ como a estimativa a priori, tem-se:

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}\hat{\mathbf{x}}_{k-1|k-1} + \mathbf{G}\mathbf{u}_{k-1} \quad (15)$$

A incerteza dessa estimativa, representada pela matriz de covariância do erro a priori $\mathbf{P}_{k|k-1}$, evolui de acordo com a dinâmica do sistema e sofre o acréscimo da incerteza do modelo ($\mathbf{Q}$):

$$\mathbf{P}_{k|k-1} = \mathbf{F}\mathbf{P}_{k-1|k-1}\mathbf{F}^T + \mathbf{Q} \quad (16)$$

Etapa 2: Correção (Measurement Update)

Ao receber a nova medição $\mathbf{y}_k$, o filtro incorpora essa informação para corrigir a estimativa projetada. Primeiramente, calcula-se o resíduo da medição, também chamado de inovação ($\tilde{\mathbf{y}}_k$), que quantifica a discrepância entre o valor medido e o valor previsto:

$$\tilde{\mathbf{y}}_k = \mathbf{y}_k - \mathbf{H}\hat{\mathbf{x}}_{k|k-1} \quad (17)$$

A covariância dessa inovação, denotada por $\mathbf{S}_k$, engloba tanto a incerteza da predição quanto a incerteza do próprio sensor ($\mathbf{R}$):

$$\mathbf{S}_k = \mathbf{H}\mathbf{P}_{k|k-1}\mathbf{H}^T + \mathbf{R} \quad (18)$$

Com isso, calcula-se o Ganho de Kalman ($\mathbf{K}_k$), que atua como um fator de ponderação ótimo, decidindo se o filtro deve confiar mais no modelo matemático ou na medição real:

$$\mathbf{K}_k = \mathbf{P}_{k|k-1}\mathbf{H}^T\mathbf{S}_k^{-1} \quad (19)$$

Finalmente, o estado estimado a posteriori ($\hat{\mathbf{x}}_{k|k}$) e a sua respectiva matriz de covariância do erro ($\mathbf{P}_{k|k}$) são atualizados de forma ótima:

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k\tilde{\mathbf{y}}_k \quad (20)$$

$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k\mathbf{H})\mathbf{P}_{k|k-1} \quad (21)$$

Onde $\mathbf{I}$ representa a matriz identidade. Este ciclo de predição e correção repete-se a cada novo passo de tempo, tornando o Filtro de Kalman um algoritmo computacionalmente leve e ideal para processamento de sinais em tempo real.

2.4 Filtro de Kalman Estendido (EKF)

O Filtro de Kalman Estendido (EKF) é a ferramenta padrão na literatura para a estimativa de estados em sistemas que apresentam dinâmicas ou processos de observação não lineares. Diferente do LKF, que é um estimador ótimo para sistemas lineares Gaussianos, o EKF é um estimador subótimo que se baseia na linearização das equações do sistema em torno da estimativa atual através de uma expansão em série de Taylor de primeira ordem (GELB et al., 1974; SIMON, 2006).

Considere o modelo de estados em tempo discreto com ruídos aditivos:

$$\mathbf{x}_k = \mathbf{f}(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) + \mathbf{w}_{k-1}, \quad \mathbf{y}_k = \mathbf{h}(\mathbf{x}_k) + \mathbf{v}_k \quad (22)$$

onde as funções vetoriais $\mathbf{f}(\cdot)$ e $\mathbf{h}(\cdot)$ representam, respectivamente, a transição de estados e o modelo de observação, ambas assumidas como diferenciáveis.

A propagação das estatísticas de segunda ordem (covariâncias) exige a computação das matrizes Jacobianas, que representam as melhores aproximações lineares locais das funções não lineares. Define-se $\mathbf{F}_{k-1}$ como o Jacobiano da dinâmica e $\mathbf{H}_k$ como o Jacobiano da medição:

$$\mathbf{F}_{k-1} = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k-1|k-1}}, \quad \mathbf{H}_k = \left. \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k|k-1}} \quad (23)$$

O algoritmo segue a estrutura recursiva de predição e correção. Na predição, a estimativa

do estado evolui pela função não linear original, enquanto a covariância utiliza a aproximação linear:

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{f}(\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{u}_{k-1}) \quad (24)$$

$$\mathbf{P}_{k|k-1} = \mathbf{F}_{k-1} \mathbf{P}_{k-1|k-1} \mathbf{F}_{k-1}^T + \mathbf{Q} \quad (25)$$

Na etapa de correção, a atualização do estado é realizada ponderando a inovação — calculada via função não linear $\mathbf{h}(\cdot)$ — pelo Ganho de Kalman ($\mathbf{K}_k$), obtido a partir da Jacobiana $\mathbf{H}_k$:

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R})^{-1} \quad (26)$$

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k [\mathbf{y}_k - \mathbf{h}(\hat{\mathbf{x}}_{k|k-1})] \quad (27)$$

$$\mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} \quad (28)$$

De acordo com Brown e Hwang (2012), a eficácia do EKF está condicionada à validade da aproximação linear no intervalo de tempo considerado. Caso as não linearidades sejam severas ou o período de amostragem seja excessivo, o truncamento da série de Taylor pode levar a instabilidades ou divergência do filtro, uma vez que o EKF não considera termos de ordem superior (Hessianos) na propagação da incerteza.

2.5 Discretização da Covariância do Ruído de Processo

Para que o filtro de Kalman reflita com precisão a incerteza de um sistema físico, é necessário transpor a densidade espectral do ruído contínuo para uma matriz de covariância discreta. Conforme demonstrado na dedução do Anexo B, o vetor de ruído de processo discreto $\mathbf{w}_k$ não é uma amostra pontual, mas o valor acumulado da perturbação contínua $\mathbf{w}(t)$ ponderada pela dinâmica do sistema ao longo do intervalo T :

$$\mathbf{w}_k = \int_{t_{k-1}}^{t_k} \phi(t_k, \tau) \mathbf{w}(\tau) d\tau \quad (29)$$

Onde $\phi(t_k, \tau) = e^{\mathbf{A}(t_k - \tau)}$ representa a matriz de transição de estados para o tempo residual da integração.

A matriz de covariância discreta $\mathbf{Q}_k$ é definida pelo valor esperado do produto externo do ruído acumulado, ou seja, $\mathbf{Q}_k = E[\mathbf{w}_k \mathbf{w}_k^T]$. Substituindo a definição integral, tem-se:

$$\mathbf{Q}_k = E \left[\left(\int_{t_{k-1}}^{t_k} \phi(t_k, \tau) \mathbf{w}(\tau) d\tau \right) \left(\int_{t_{k-1}}^{t_k} \phi(t_k, \alpha) \mathbf{w}(\alpha) d\alpha \right)^T \right] \quad (30)$$

Aplicando a propriedade da transposta para o produto matricial no segundo integrando e agrupando os termos (visto que as variáveis de integração τ e α são independentes), a equação

pode ser desenvolvida passo a passo:

$$\begin{aligned}\mathbf{Q}_k &= E \left[\int_{t_{k-1}}^{t_k} \phi(t_k, \tau) \mathbf{w}(\tau) d\tau \int_{t_{k-1}}^{t_k} \mathbf{w}^T(\alpha) \phi^T(t_k, \alpha) d\alpha \right] \\ &= E \left[\int_{t_{k-1}}^{t_k} \int_{t_{k-1}}^{t_k} \phi(t_k, \tau) \mathbf{w}(\tau) \mathbf{w}^T(\alpha) \phi^T(t_k, \alpha) d\tau d\alpha \right]\end{aligned}\quad (31)$$

Pela propriedade da linearidade do operador esperança, é válido permutá-lo com a integral dupla. Como as matrizes de transição de estados ϕ são estritamente determinísticas, o operador atua exclusivamente sobre os termos estocásticos:

$$\mathbf{Q}_k = \int_{t_{k-1}}^{t_k} \int_{t_{k-1}}^{t_k} \phi(t_k, \tau) E[\mathbf{w}(\tau) \mathbf{w}^T(\alpha)] \phi^T(t_k, \alpha) d\tau d\alpha \quad (32)$$

Assumindo que o ruído de processo contínuo é branco, estacionário, com média nula e matriz de densidade espectral de potência $\mathbf{Q}_c$, sua função de autocorrelação é dada por $E[\mathbf{w}(\tau) \mathbf{w}^T(\alpha)] = \mathbf{Q}_c \delta(\tau - \alpha)$, onde δ é a função impulso de Dirac. Substituindo esta relação:

$$\mathbf{Q}_k = \int_{t_{k-1}}^{t_k} \int_{t_{k-1}}^{t_k} \phi(t_k, \tau) [\mathbf{Q}_c \delta(\tau - \alpha)] \phi^T(t_k, \alpha) d\tau d\alpha \quad (33)$$

Devido à propriedade de filtragem (peneira) da função impulso de Dirac, a integração em relação a α colapsa, avaliando a expressão do integrando apenas no instante em que $\alpha = \tau$. Com isso, a integral dupla simplifica-se para uma integral simples (BROWN; HWANG, 2012):

$$\mathbf{Q}_k = \int_{t_{k-1}}^{t_k} \phi(t_k, \tau) \mathbf{Q}_c \phi^T(t_k, \tau) d\tau \quad (34)$$

Por fim, realizando a mudança de variável $\zeta = t_k - \tau$ para expressar a integral em termos do passo de amostragem ΔT (sendo o sinal negativo absorvido pela inversão dos limites de integração), obtém-se a expressão final para a covariância discretizada:

$$\mathbf{Q}_k = \int_0^{\Delta T} \phi(\zeta) \mathbf{Q}_c \phi^T(\zeta) d\zeta \quad (35)$$

Esta formulação explicita que a incerteza $\mathbf{Q}_k$ depende diretamente de como a matriz ϕ propaga o erro ao longo do intervalo de amostragem. De acordo com Simon (2006), a omissão desta integração — frequentemente substituída pela aproximação ingênua $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta T$ — pode resultar em uma subestimação severa da covariância em sistemas com dinâmicas rápidas (autovalores de $\mathbf{A}$ elevados), levando à divergência do filtro ou a estimativas excessivamente otimistas.

3 OBJETIVOS

O objetivo principal deste estudo é avaliar a robustez e a convergência dos Filtros de Kalman Linear e Estendido na estimação de sinais senoidais. Para isso, busca-se modelar o problema de rastreo em cenários de frequência conhecida e desconhecida, testando a estabilidade e a observabilidade dos algoritmos sob condições iniciais adversas e erros de estimativa. Adicionalmente, pretende-se realizar uma análise quantitativa do desempenho dos modelos através do Erro Quadrático Médio (MSE) e da evolução temporal dos estados estimados.

4 METODOLOGIA E FORMULAÇÃO DOS MODELOS

4.1 Metodologia de Avaliação e Cenários de Teste

A metodologia de testes baseia-se nos experimentos de Zarchan e Musoff (2015) apresentados no capítulo "*Tracking a Sine Wave*", com implementações desenvolvidas no ambiente GNU Octave.

O estudo divide-se em duas etapas: a primeira utiliza um Filtro de Kalman Linear (LKF), assumindo a frequência do sinal como conhecida; a segunda emprega o Filtro de Kalman Estendido (EKF) para lidar com a frequência desconhecida. Como o desempenho do EKF é sensível às condições iniciais, os algoritmos serão avaliados variando a estimativa inicial da frequência ($\hat{\omega}_0$) em relação à frequência real (ω_{real}). Os testes dividem-se nas seguintes categorias:

- **Linha de Base (LKF):** Avaliação com a frequência exata (limite ótimo) e com frequência incorreta, evidenciando a necessidade de estimação conjunta via modelos não lineares.
- **Cenários Nominais (EKF):** Inicialização com o mesmo sinal algébrico da dinâmica real (ex: $\omega_{real} > 0$ e $\hat{\omega}_0 > 0$), para testar a convergência básica.
- **Cenários de Incompatibilidade (EKF):** Inicialização com sinais opostos (ex: frequência real negativa e estimativa inicial positiva). Serve para expor falhas de observabilidade e a ambiguidade matemática da função seno.
- **Simulações de Monte Carlo:** Execução de 10 rodadas com ruídos aleatórios para validar estatisticamente os modelos que superarem os cenários anteriores.

O desempenho dos modelos será comparado com base em três métricas gráficas:

- (a) **Rastreo do Sinal:** Comparação entre o sinal real, a medição ruidosa e a estimativa do filtro no tempo.
- (b) **Convergência dos Estados:** Evolução das estimativas internas em direção aos valores nominais verdadeiros.

- (c) **Erro Quadrático Médio (MSE):** Avaliação da precisão e da velocidade de convergência do filtro.

A formulação matemática e as matrizes dos cinco modelos avaliados são detalhadas na Subseção 4.2.

4.2 Formulação Matemática dos Modelos

Todos os modelos desenvolvidos neste trabalho têm como objetivo final a estimação dos estados associados a um sinal senoidal unidimensional, cuja forma de onda no tempo contínuo pode ser genericamente expressa por:

$$y(t) = A \sin(\omega t + \phi) \quad (36)$$

onde A é a amplitude, ω é a frequência angular e ϕ é a fase do sinal.

Para a aplicação das técnicas de filtragem, assume-se que não há variáveis de controle aplicadas ao sistema ($\mathbf{u} = \mathbf{0}$). O sistema é sujeito apenas a ruídos brancos Gaussianos no modelo dinâmico ($\mathbf{w}(t) \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_c)$) e na medição do sensor ($\mathbf{v}(t) \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_c)$). A representação geral em espaço de estados no tempo contínuo é dada por:

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t)) + \mathbf{w}(t) \\ \mathbf{y}(t) = \mathbf{h}(\mathbf{x}(t)) + \mathbf{v}(t) \end{cases} \quad (37)$$

Como os algoritmos operam em ambiente computacional digital, o sistema (37) é discretizado com um período de amostragem T_s . A formulação discreta geral que servirá de base para todos os filtros é:

$$\begin{cases} \mathbf{x}_k = \mathbf{f}_d(\mathbf{x}_{k-1}) + \mathbf{w}_{k-1} \\ \mathbf{y}_k = \mathbf{h}_d(\mathbf{x}_k) + \mathbf{v}_k \end{cases} \quad (38)$$

A complexidade das funções $\mathbf{f}_d$ e $\mathbf{h}_d$ depende do conhecimento prévio da frequência ω . Quando ω é conhecida, o sistema reduz-se a um modelo matricial linear resolvido pelo LKF. Quando ω é desconhecida, a dinâmica torna-se não linear, exigindo o uso do EKF, no qual as matrizes de transição ($\mathbf{F}$) e de observação ($\mathbf{H}$) passam a ser derivadas como matrizes Jacobianas. A seguir, apresenta-se a dedução específica para chegar às matrizes de cada um dos cinco modelos propostos.

4.2.1 Modelo 1: Oscilador Harmônico Linear (LKF Padrão)

Nesta primeira abordagem, assume-se que a frequência angular ω é constante e perfeitamente conhecida e a fase inicial é nula. Sob esta premissa, o sinal é a solução analítica da equação diferencial de um oscilador harmônico não amortecido:

$$\ddot{y}(t) = -\omega^2 y(t) \quad (39)$$

Definindo o vetor de estados contínuo como o próprio sinal e a sua primeira derivada temporal, $\mathbf{x} = [x_1, x_2]^T = [y, \dot{y}]^T$, o modelo contínuo torna-se estritamente linear. Conforme a forma geral estabelecida na Equação (7), a dinâmica é expressa pelas matrizes de estado $\mathbf{A}$ e de observação $\mathbf{C}$:

$$\dot{\mathbf{x}}(t) = \begin{bmatrix} 0 & 1 \\ -\omega^2 & 0 \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} + \mathbf{w}(t) \quad (40)$$

$$y(t) = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} x_1(t) \\ x_2(t) \end{bmatrix} + v(t) \quad (41)$$

Considerando o ângulo inicial ϕ , e a Amplitude (A), podemos utilizar a equação para encontrar o estado inicial do sistema:

$$\mathbf{x}_0 = \begin{bmatrix} A \sin(\phi) \\ A \omega \cos(\phi) \end{bmatrix} \quad (42)$$

Para a implementação discreta exigida pelo LKF (Equação (13)), aplica-se o método detalhado na Seção 2.2. A matriz de transição de estados discreta é definida por $\mathbf{F} = e^{\mathbf{A}T_s}$, a qual pode ser aproximada computacionalmente por uma expansão em série de Taylor de primeira ordem ($\mathbf{F} \approx \mathbf{I} + \mathbf{A}T_s$). A matriz de observação permanece invariante no processo de discretização ($\mathbf{H} = \mathbf{C}$, conforme deduzido na Subseção 2.2), resultando nas matrizes:

$$\mathbf{F} = \begin{bmatrix} 1 & T_s \\ -\omega^2 T_s & 1 \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} 1 & 0 \end{bmatrix} \quad (43)$$

Para a modelagem estocástica do sistema, assume-se que o sensor mede diretamente apenas o primeiro estado $x_1(t)$ (o valor do sinal). Portanto, a covariância do ruído de medição é um valor escalar $R = \sigma_v^2 \in \mathbb{R}$.

Para o ruído de processo $\mathbf{w}(t)$, adota-se uma matriz de covariância contínua $\mathbf{Q}_c \in \mathbb{R}^{2 \times 2}$ na forma diagonal, assumindo que as perturbações no sinal e na sua derivada são independentes:

$$\mathbf{Q}_c = \begin{bmatrix} \sigma_{w1}^2 & 0 \\ 0 & \sigma_{w2}^2 \end{bmatrix} \quad (44)$$

onde σ_{w1}^2 e σ_{w2}^2 são as variâncias contínuas associadas a cada estado.

Conforme discutido na Subseção 2.5, devido à discretização, a matriz de covariância discreta $\mathbf{Q}_k$ é obtida através da Equação (35). Utilizando a matriz de transição aproximada $\phi(\zeta) \approx \mathbf{I} + \mathbf{A}\zeta$, a integral é resolvida no intervalo $[0, T_s]$:

$$\mathbf{Q}_k = \int_0^{T_s} \begin{bmatrix} 1 & \zeta \\ -\omega^2 \zeta & 1 \end{bmatrix} \begin{bmatrix} \sigma_{w1}^2 & 0 \\ 0 & \sigma_{w2}^2 \end{bmatrix} \begin{bmatrix} 1 & -\omega^2 \zeta \\ \zeta & 1 \end{bmatrix} d\zeta \quad (45)$$

Executando o produto matricial e integrando termo a termo em relação a ζ , resulta-se

na matriz de covariância do ruído de processo discretizada exata para o modelo:

$$\mathbf{Q}_k = \begin{bmatrix} \sigma_{w1}^2 T_s + \sigma_{w2}^2 \frac{T_s^3}{3} & (\sigma_{w2}^2 - \sigma_{w1}^2 \omega^2) \frac{T_s^2}{2} \\ (\sigma_{w2}^2 - \sigma_{w1}^2 \omega^2) \frac{T_s^2}{2} & \sigma_{w2}^2 T_s + \sigma_{w1}^2 \omega^4 \frac{T_s^3}{3} \end{bmatrix} \quad (46)$$

Por fim, o modelo de estados discreto linearizado, reunindo as matrizes da dinâmica e a modelagem do erro, fica completamente definido pelo sistema:

$$\begin{cases} \begin{bmatrix} x_{1,k} \\ x_{2,k} \end{bmatrix} = \begin{bmatrix} 1 & T_s \\ -\omega^2 T_s & 1 \end{bmatrix} \begin{bmatrix} x_{1,k-1} \\ x_{2,k-1} \end{bmatrix} + \mathbf{w}_{k-1}, & \mathbf{w}_{k-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k) \\ y_k = \begin{bmatrix} 1 & 0 \end{bmatrix} \begin{bmatrix} x_{1,k} \\ x_{2,k} \end{bmatrix} + v_k, & v_k \sim \mathcal{N}(0, R) \\ \mathbf{x}_0 = \begin{bmatrix} A \sin \phi & A \omega \cos \phi \end{bmatrix}^T \end{cases} \quad (47)$$

O código de Implementação do algoritmo desse primeiro filtro de Kalman está presente no repositório do Github de Silva (2026).

4.2.2 Modelo 2: Estimação Não Linear de Parâmetros via EKF

Nesta segunda abordagem, fundamentada na formulação proposta por Zarchan e Musoff (2015), a fase instantânea ϕ , a frequência angular ω e a amplitude A são integradas diretamente ao vetor de estados, definido como $\mathbf{x} = [x_1, x_2, x_3]^T = [\phi, \omega, A]^T$. Sob a premissa de que a frequência e a amplitude do sinal permanecem constantes durante o intervalo de amostragem, a dinâmica contínua do sistema é descrita por:

$$\dot{\mathbf{x}}(t) = \begin{bmatrix} \dot{\phi}(t) \\ \dot{\omega}(t) \\ \dot{A}(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \phi(t) \\ \omega(t) \\ A(t) \end{bmatrix} + \mathbf{w}(t) \quad (48)$$

Diferente da abordagem anterior, a função de observação $h(\mathbf{x})$ apresenta uma natureza não linear, definida por $y(t) = A \sin(\phi) + v(t)$. Para viabilizar a aplicação do Filtro de Kalman Estendido (EKF), o modelo de observação deve ser linearizado em cada passo de tempo através da matriz Jacobiana $\mathbf{H}_k$, calculada em torno da predição do estado $\hat{\mathbf{x}}_{k|k-1}$:

$$\mathbf{H}_k = \left. \frac{\partial h}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k|k-1}} = \begin{bmatrix} \hat{A}_{k|k-1} \cos(\hat{\phi}_{k|k-1}) & 0 & \sin(\hat{\phi}_{k|k-1}) \end{bmatrix} \quad (49)$$

Para a implementação no domínio discreto com período de amostragem T_s , a matriz de transição de estados $\mathbf{F}$ é obtida pela exponencial da matriz de dinâmica $\mathbf{A}$. Dado que $\mathbf{A}$ é uma matriz nilpotente de ordem 2 ($\mathbf{A}^2 = \mathbf{0}$), a expansão em série de Taylor resulta em uma

discretização exata:

$$\mathbf{F} = e^{\mathbf{A}T_s} = \mathbf{I} + \mathbf{A}T_s = \begin{bmatrix} 1 & T_s & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (50)$$

A modelagem estocástica do processo assume que as incertezas agem sobre a taxa de variação da frequência e da amplitude, com uma matriz de covariância contínua $\mathbf{Q}_c = \text{diag}(0, \sigma_\omega^2, \sigma_A^2)$. A matriz de covariância discreta $\mathbf{Q}_k$, calculada conforme a metodologia da Seção 2.5, é obtida pela integração da matriz de transição fundamental no intervalo $[0, T_s]$:

$$\mathbf{Q}_k = \int_0^{T_s} \begin{bmatrix} 1 & \zeta & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & \sigma_\omega^2 & 0 \\ 0 & 0 & \sigma_A^2 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ \zeta & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} d\zeta \quad (51)$$

A resolução analítica da integral resulta na matriz de ruído de processo para o modelo EKF:

$$\mathbf{Q}_k = \begin{bmatrix} \sigma_\omega^2 \frac{T_s^3}{3} & \sigma_\omega^2 \frac{T_s^2}{2} & 0 \\ \sigma_\omega^2 \frac{T_s^2}{2} & \sigma_\omega^2 T_s & 0 \\ 0 & 0 & \sigma_A^2 T_s \end{bmatrix} \quad (52)$$

Desta forma, o sistema discreto linearizado que compõe o algoritmo de predição e correção do EKF fica completamente definido por:

$$\begin{cases} \begin{bmatrix} \phi_k \\ \omega_k \\ A_k \end{bmatrix} = \begin{bmatrix} 1 & T_s & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \phi_{k-1} \\ \omega_{k-1} \\ A_{k-1} \end{bmatrix} + \mathbf{w}_{k-1}, & \mathbf{w}_{k-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k) \\ y_k = \hat{A}_{k|k-1} \sin(\hat{\phi}_{k|k-1}) + v_k, & v_k \sim \mathcal{N}(0, R) \end{cases} \quad (53)$$

A implementação completa deste estimador não linear, incluindo as etapas de atualização do Jacobiano, está disponível no repositório de Silva (2026).

4.2.3 Modelo 3: EKF de 2 Estados (Amplitude Conhecida)

Nesta terceira configuração, fundamentada na formulação proposta por Zarchan e Mu-soff (2015), assume-se que a amplitude A do sinal é um parâmetro perfeitamente conhecido e invariante, permitindo uma redução na ordem do sistema em comparação ao Modelo 2. O vetor de estados passa a ser definido apenas pela fase instantânea e pela frequência angular, $\mathbf{x} = [x_1, x_2]^T = [\phi, \omega]^T$. A dinâmica contínua, sob a premissa de frequência constante ($\dot{\omega} = 0$), é expressa por:

$$\dot{\mathbf{x}}(t) = \begin{bmatrix} \dot{\phi}(t) \\ \dot{\omega}(t) \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \phi(t) \\ \omega(t) \end{bmatrix} + \mathbf{w}(t) \quad (54)$$

A função de observação permanece não linear, porém simplificada pela natureza escalar e conhecida da amplitude: $y(t) = A \sin(\phi) + v(t)$. Para a linearização exigida pelo EKF, a matriz Jacobiana de observação $\mathbf{H}_k$ é reduzida para uma dimensão 1×2 , sendo avaliada no ponto de operação $\hat{\mathbf{x}}_{k|k-1}$:

$$\mathbf{H}_k = \left. \frac{\partial h}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k|k-1}} = \begin{bmatrix} A \cos(\hat{\phi}_{k|k-1}) & 0 \end{bmatrix} \quad (55)$$

A discretização do sistema segue o método da série de Taylor. Sendo a matriz de dinâmica $\mathbf{A}$ nilpotente ($\mathbf{A}^2 = \mathbf{0}$), a matriz de transição de estados discreta $\mathbf{F}$ para um período de amostragem T_s é obtida de forma exata:

$$\mathbf{F} = \mathbf{I} + \mathbf{A}T_s = \begin{bmatrix} 1 & T_s \\ 0 & 1 \end{bmatrix} \quad (56)$$

Para a modelagem estocástica, considera-se que a incerteza incide primordialmente sobre a derivada da frequência, com densidade espectral de potência $\mathbf{Q}_c = \text{diag}(0, \sigma_\omega^2)$. A matriz de covariância discreta $\mathbf{Q}_k$ é derivada através da integração fundamental conforme discutido na Seção 2.5:

$$\mathbf{Q}_k = \int_0^{T_s} \begin{bmatrix} 1 & \zeta \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & \sigma_\omega^2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ \zeta & 1 \end{bmatrix} d\zeta = \begin{bmatrix} \sigma_\omega^2 \frac{T_s^3}{3} & \sigma_\omega^2 \frac{T_s^2}{2} \\ \sigma_\omega^2 \frac{T_s^2}{2} & \sigma_\omega^2 T_s \end{bmatrix} \quad (57)$$

Finalmente, o modelo de estados discreto que rege a operação deste EKF de ordem reduzida é consolidado no seguinte sistema:

$$\begin{cases} \begin{bmatrix} \phi_k \\ \omega_k \end{bmatrix} = \begin{bmatrix} 1 & T_s \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \phi_{k-1} \\ \omega_{k-1} \end{bmatrix} + \mathbf{w}_{k-1}, & \mathbf{w}_{k-1} \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k) \\ y_k = A \sin(\hat{\phi}_{k|k-1}) + v_k, & v_k \sim \mathcal{N}(0, R) \end{cases} \quad (58)$$

Este modelo é particularmente útil em cenários onde a amplitude foi previamente estimada ou é garantida por hardware, focando a convergência do filtro na fase e frequência. A implementação deste algoritmo pode ser consultada em Silva (2026).

4.2.4 Modelo 4: EKF Alternativo de 3 Estados (Sinal, Derivada e Frequência)

Nesta quarta abordagem, fundamentada na formulação proposta por Zarchan e Musoff (2015), propõe-se uma mudança de paradigma na modelagem ao integrar a frequência angular ω como uma variável de estado acoplada à dinâmica do oscilador. O vetor de estados é definido como $\mathbf{x} = [x_1, x_2, x_3]^T = [y, \dot{y}, \omega]^T$. Diferente dos modelos anteriores, a não linearidade é deslocada da observação para a equação de transição, baseando-se na relação fundamental $\ddot{y} = -\omega^2 y$. O sistema de equações diferenciais não lineares que rege a dinâmica é dado por:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}) + \mathbf{w}(t) \implies \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \\ \dot{x}_3 \end{bmatrix} = \begin{bmatrix} x_2 \\ -x_3^2 x_1 \\ 0 \end{bmatrix} + \mathbf{w}(t) \quad (59)$$

Para a aplicação do EKF, a matriz de dinâmica contínua deve ser linearizada através da Jacobiana $\mathbf{A}_J$, calculada em relação ao estado estimado $\hat{\mathbf{x}}_{k|k-1}$:

$$\mathbf{A}_J = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k|k-1}} = \begin{bmatrix} 0 & 1 & 0 \\ -\hat{x}_3^2 & 0 & -2\hat{x}_3 \hat{x}_1 \\ 0 & 0 & 0 \end{bmatrix} \quad (60)$$

A matriz de transição de estados discreta $\mathbf{F}_k$ é obtida pela aproximação de primeira ordem da exponencial matricial, $\mathbf{F}_k \approx \mathbf{I} + \mathbf{A}_J T_s$. Em contrapartida, a matriz de observação $\mathbf{H}$ torna-se estritamente linear, uma vez que o sensor mede diretamente o primeiro estado (o sinal y):

$$\mathbf{F}_k = \begin{bmatrix} 1 & T_s & 0 \\ -\hat{\omega}^2 T_s & 1 & -2\hat{\omega} \hat{y} T_s \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \quad (61)$$

A modelagem estocástica do ruído de processo assume que a principal incerteza reside na dinâmica da frequência angular, definindo a matriz contínua $\mathbf{Q}_c = \text{diag}(0, 0, \sigma_\omega^2)$. A matriz de covariância discreta $\mathbf{Q}_k$ é obtida pela integração da influência desse ruído sobre os demais estados no intervalo $[0, T_s]$:

$$\mathbf{Q}_k = \int_0^{T_s} \begin{bmatrix} 1 & \zeta & 0 \\ -\hat{\omega}^2 \zeta & 1 & -2\hat{\omega} \hat{y} \zeta \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & \sigma_\omega^2 \end{bmatrix} \begin{bmatrix} 1 & -\hat{\omega}^2 \zeta & 0 \\ \zeta & 1 & 0 \\ 0 & -2\hat{\omega} \hat{y} \zeta & 1 \end{bmatrix} d\zeta \quad (62)$$

Ao resolver a integral, observa-se que a variância da frequência se propaga para a derivada do sinal e, consequentemente, para o sinal, resultando na matriz:

$$\mathbf{Q}_k = \sigma_\omega^2 \begin{bmatrix} 0 & 0 & 0 \\ 0 & 4\hat{\omega}^2 \hat{y}^2 \frac{T_s^3}{3} & -2\hat{\omega} \hat{y} \frac{T_s^2}{2} \\ 0 & -2\hat{\omega} \hat{y} \frac{T_s^2}{2} & T_s \end{bmatrix} \quad (63)$$

O sistema discreto linearizado, que define as etapas de predição do EKF para esta configuração, é consolidado abaixo:

$$\begin{cases} \begin{bmatrix} x_{1,k} \\ x_{2,k} \\ x_{3,k} \end{bmatrix} = \begin{bmatrix} x_{2,k-1} \\ -(x_{3,k-1})^2 x_{1,k-1} \\ 0 \end{bmatrix} + \mathbf{w}_{k-1} & w_{k-1} \sim \mathcal{N}(0, \mathbf{Q}_{k-1}) \\ y_k = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \mathbf{x}_k + v_k, & v_k \sim \mathcal{N}(0, R) \end{cases} \quad (64)$$

Nesta formulação, o filtro deve atualizar a Jacobiana $\mathbf{F}_k$ a cada iteração utilizando os valores preditos de sinal e frequência. A implementação deste algoritmo, que oferece uma alternativa robusta para rastreamento de frequência, está documentada em Silva (2026).

4.2.5 Modelo 5: EKF de 3 Estados com Frequência ao Quadrado

Nesta quinta configuração, fundamentada na formulação proposta por Zarchan e Musoff (2015), propõe-se um refinamento do Modelo 4 visando eliminar a ambiguidade de sinal na estimação da frequência. Uma vez que a equação diferencial do oscilador ($\ddot{y} + \omega^2 y = 0$) é invariante ao sinal de ω , o rastreamento direto da frequência angular pode levar a saltos de fase ou instabilidades se ω oscilar em torno de zero. Para mitigar esse efeito, define-se o vetor de estados como $\mathbf{x} = [x_1, x_2, x_3]^T = [y, \dot{y}, z]^T$, onde $z = \omega^2$ representa o quadrado da frequência angular. A dinâmica contínua do sistema é reescrita como:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}) + \mathbf{w}(t) \implies \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \\ \dot{x}_3 \end{bmatrix} = \begin{bmatrix} x_2 \\ -x_3 x_1 \\ 0 \end{bmatrix} + \mathbf{w}(t) \quad (65)$$

A linearização da dinâmica para o algoritmo EKF é realizada através da matriz Jacobiana $\mathbf{A}_J$. Note que, ao utilizar z em vez de ω , a derivada parcial em relação ao terceiro estado torna-se linearmente dependente apenas de x_1 , simplificando a estrutura de sensibilidade do filtro:

$$\mathbf{A}_J = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k|k-1}} = \begin{bmatrix} 0 & 1 & 0 \\ -\hat{x}_3 & 0 & -\hat{x}_1 \\ 0 & 0 & 0 \end{bmatrix} \quad (66)$$

Aplicando a discretização por série de Taylor de primeira ordem ($\mathbf{F}_k \approx \mathbf{I} + \mathbf{A}_J T_s$), e mantendo a observação linear baseada na medição direta do sinal ($y_k = x_1$), as matrizes discretas resultantes são:

$$\mathbf{F}_k = \begin{bmatrix} 1 & T_s & 0 \\ -\hat{z}T_s & 1 & -\hat{y}T_s \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{H} = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \quad (67)$$

Para a modelagem estocástica, considera-se que o ruído de processo atua exclusivamente sobre a variável z , representando a instabilidade na frequência ao quadrado, tal que $\mathbf{Q}_c = \text{diag}(0, 0, \sigma_z^2)$. A matriz discreta $\mathbf{Q}_k$ é calculada integrando a propagação desta incerteza através da dinâmica linearizada:

$$\mathbf{Q}_k = \int_0^{T_s} \begin{bmatrix} 1 & \zeta & 0 \\ -\hat{z}\zeta & 1 & -\hat{y}\zeta \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & \sigma_z^2 \end{bmatrix} \begin{bmatrix} 1 & -\hat{z}\zeta & 0 \\ \zeta & 1 & 0 \\ 0 & -\hat{y}\zeta & 1 \end{bmatrix} d\zeta \quad (68)$$

A execução do produto matricial e a integração termo a termo resultam na matriz de

covariância discreta simplificada para o Modelo 5:

$$\mathbf{Q}_k = \sigma_z^2 \begin{bmatrix} 0 & 0 & 0 \\ 0 & \hat{y}^2 \frac{T_s^3}{3} & -\hat{y} \frac{T_s^2}{2} \\ 0 & -\hat{y} \frac{T_s^2}{2} & T_s \end{bmatrix} \quad (69)$$

O sistema discreto linearizado final é expresso por:

$$\begin{cases} \begin{bmatrix} x_{1,k} \\ x_{2,k} \\ x_{3,k} \end{bmatrix} = \begin{bmatrix} x_{2,k-1} \\ -(x_{3,k-1})(x_{1,k-1}) \\ 0 \end{bmatrix} + \mathbf{w}_{k-1} & w_{k-1} \sim \mathcal{N}(0, \mathbf{Q}_{k-1}) \\ y_k = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \mathbf{x}_k + v_k, & v_k \sim \mathcal{N}(0, R) \end{cases} \quad (70)$$

Esta formulação garante que a estimativa de z seja sempre interpretada como o termo de rigidez do oscilador, facilitando a convergência em sinais onde a frequência pode ser muito baixa ou ruidosa. A implementação deste modelo, incluindo a extração final da frequência via $\omega = \sqrt{z}$, encontra-se detalhada no repositório de Silva (2026).

5 RESULTADOS E DISCUSSÕES

Nesta seção, são apresentados e discutidos os resultados gráficos e quantitativos obtidos nas simulações do GNU Octave. A avaliação segue a progressão metodológica definida na Seção 4.1, analisando o rastreamento do sinal, a convergência dos estados e a evolução do Erro Quadrático Médio (MSE) para cada formulação do Filtro de Kalman Estendido (EKF) e Filtro de Kalman Linear (LKF).

5.1 Análise do Modelo 1: Abordagem Linear (*Baseline*)

Foram realizadas 10 repetições independentes (Monte Carlo) para cada configuração de teste. As figuras apresentadas nas subseções ilustram a décima execução como exemplo; nos gráficos de Monte Carlo, a curva preta representa a média das 10 execuções e as curvas em tons de cinza representam as execuções individuais, evidenciando a repetibilidade dos resultados.

O Modelo 1 (modelado na Subseção 4.2.1) fundamenta-se em um oscilador harmônico linear com frequência conhecida, atuando como *benchmark* para estabelecer o limite superior de desempenho do sistema. No cenário nominal, o filtro deve apresentar convergência rápida e erro residual mínimo, limitado estatisticamente pela variância do ruído de medição.

Para avaliar a robustez e a sensibilidade do modelo, foram realizados quatro testes, cujas configurações de ruído e condições iniciais estão sintetizadas na Tabela 1.

Tabela 1: Parâmetros de simulação para os testes do Modelo 1.

Parâmetro	Teste 1	Teste 2	Teste 3	Teste 4
T_s (Amostragem)	0,01 segundos			
Tempo Total	10 segundos			
Monte Carlo	10 repetições			
Amplitude	1			
ω	1 rad/s			
ϕ_0	0 rad	0 rad	$\phi/4$ rad	0 rad
$\sigma_{w1}^2, \sigma_{w2}^2$	0,001; 0,01	0,001; 0,01	1,0; 1,0	0,01; 0,1
R (Medição)	0,1	0,1	1,0	0,1
$\hat{x}_0$ (Inicial)	$[0; 0]^T$	$[1; 0]^T$	$[5; 2]^T$	$[5; 2]^T$

5.1.1 Testes 1 e 2: Desempenho em Cenário Nominal

Os Testes 1 e 2 validam o rastreo em condições controladas, com erro de modelo próximo do ideal, conforme a 1. Observa-se a capacidade do filtro em estimar os estados com precisão, conforme apresentado nas figuras 1 e 3, bem como a minimização do erro de saída, apresentada nas Figuras 2 e 4.

Figura 1: Rastreio nominal (Teste 1).





Figura 2: Erro de estimação (Teste 1).



Fonte: Elaborado pelo Autor (2026).

Figura 3: Rastreio nominal (Teste 2).





Figura 4: Erro de estimação (Teste 2).



Fonte: Elaborado pelo Autor (2026).

5.1.2 Teste 3: Estresse de Ruído e Incerteza Inicial

No Teste 3, as variâncias do processo e da medição foram elevadas significativamente, acompanhadas de um erro na estimativa inicial. Este cenário avalia a robustez tempo de resposta e a estabilidade do filtro sob severa incerteza estocástica. Observou-se que devido aos ruídos com desvios superiores aos demais testes, o modelo 1 acabou tendo um filtro mais ruidoso, conforme a Figura 5. Como esperado, o filtro minimizou o erro rapidamente, conforme a Figura 6.

Figura 5: Rastreio sob estresse (Teste 3).





Figura 6: Convergência do erro (Teste 3).



Fonte: Elaborado pelo Autor (2026).

5.1.3 Teste 4: Impacto da Não Discretização da Covariância Q

O Teste 4 analisa a importância da discretização correta da matriz de covariância do ruído de processo. Comparou-se o filtro projetado com a matriz contínua $\mathbf{Q} = \text{diag}(0,01;0,1)$ contra a versão devidamente discretizada $\mathbf{Q}_k$.

Como evidenciado nas Figuras 7 a 10, a negligência quanto aos efeitos de discretização resulta em uma subestimação da incerteza do modelo, levando a um sinal de saída excessivamente ruidoso e a um aumento no erro residual, uma vez que o filtro falha em ponderar adequadamente a acumulação do ruído ao longo do intervalo T_s .

Figura 7: Rastreio com $\mathbf{Q}$ não discretizada.




Figura 8: Rastreio com $\mathbf{Q}_k$ discreta.




Figura 9: Erro residual ($\mathbf{Q}$).





Figura 10: Erro residual ($\mathbf{Q}_k$).



Fonte: Elaborado pelo Autor (2026).

5.1.4 Conclusão da Parcial do Modelo 1

Os resultados demonstram que o Modelo 1 atua satisfatoriamente como referência linear. Enquanto a convergência é mantida sob incertezas iniciais e ruído elevado, o Teste 4 destaca que a precisão do filtro é sensível à correta formulação matemática das matrizes discretas, sendo a discretização de $\mathbf{Q}$ um passo indispensável para a otimização do rastreo.

5.2 Análise do Modelo 2: Abordagem de Três Estados (ϕ, ω, A)

Relativo ao modelo 2 (modelado na Subseção 4.2.2), a formulação visa a estimação simultânea da fase (ϕ), frequência angular (ω) e amplitude (A). Diferente do modelo linear anterior, esta abordagem lida com uma estrutura não linear, o que exige maior precisão na inicialização do filtro. Embora o modelo apresente desempenho satisfatório em condições ideais, observou-se uma sensibilidade crítica aos parâmetros iniciais, podendo resultar em falhas de observabilidade.

Foram realizadas 10 repetições independentes (Monte Carlo) para cada configuração de teste. As figuras apresentadas nas subseções ilustram a décima execução como exemplo; nos gráficos de Monte Carlo a curva preta representa a média das 10 execuções e as curvas em tons de cinza representam as execuções individuais.

Os parâmetros configurados para os três ensaios do Modelo 2 estão detalhados na Tabela 2.


Tabela 2: Parâmetros de simulação para os testes do Modelo 2.

extbfParâmetro	Teste 1	Teste 2	Teste 3
T_s (Amostragem)	0,01 segundos		
Tempo Total	10 segundos		
Monte Carlo	10 repetições		
Amplitude (A)	1,5		
ω	1,2 rad/s		
ϕ_0	0 rad		
$\sigma_{w1}^2, \sigma_{w2}^2, \sigma_{w3}^2$	0,001; 0,001; 0,01	0,001; 0,001; 0,01	0,001; 0,001; 0,01
R (Medição)	0,05	0,1	0,1
$\hat{\mathbf{x}}_0$ (Inicial)	$[0; 1; 1]^T$	$[0; 1; -1]^T$	$[0; -1; -1]^T$

5.2.1 Teste 1: Cenário Nominal e Convergência Ideal

No **Teste 1**, o filtro foi inicializado sob condições nominais, utilizando estimativas iniciais próximas aos parâmetros reais e um baixo ruído de processo. O objetivo deste cenário é validar a estabilidade e a capacidade de rastreamento do algoritmo em regime estacionário. Conforme ilustrado na Figura 11, as estimativas de fase e amplitude apresentam convergência rápida, mantendo um erro residual estatisticamente coerente com a variância do ruído de medição ($R = 0,05$).

Figura 11: Modelo 2: Estimativas (Teste 1).




Fonte: Elaborado pelo Autor (2026).


Quanto ao desempenho estocástico, a evolução do Erro Quadrático Médio (MSE) confirma a eficácia do estimador na filtragem do ruído. A redução progressiva observada na Figura 12(a) indica que as incertezas dos estados internos decaem para níveis satisfatórios de precisão após o transiente inicial. Paralelamente, o erro de saída (Figura 12b) é minimizado conforme o filtro converge, atingindo o critério de otimalidade esperado para a formulação de Kalman neste cenário de erro de modelo nulo.

Figura 12: Modelo 2: Convergências do erro (Teste 1).

(a) MSE dos Estados (ϕ, ω, A).



(b) MSE da Saída (Monte Carlo)



Fonte: Elaborado pelo Autor (2026).


5.2.2 Teste 2: Inversão de Frequência 1

O **Teste 2** explora a robustez do filtro diante de erros grosseiros na inicialização da frequência (ω). Devido à identidade trigonométrica $-A \sin(-\omega t) = A \sin(\omega t)$, o processo de observação apresenta uma ambiguidade inerente. Caso a estimativa inicial $\hat{\omega}_0$ possua sinal oposto ao valor real, o filtro tende a convergir para um *mínimo local* de erro.

Neste cenário, para compensar a inversão da dinâmica temporal, o algoritmo estima uma amplitude negativa ou introduz um deslocamento de fase de 180° (equivalente a π radianos).

Como observado na Figura 13, o filtro consegue reconstruir o sinal de saída com precisão, mas falha na identificação dos parâmetros físicos internos. Estatisticamente, isso resulta em um Erro Quadrático Médio de saída reduzido (Figura 14b), contrastando com um MSE de estados elevado (Figura 14a), o que caracteriza uma falha de observabilidade parcial sob condições de inicialização adversas.


Figura 13: Modelo 2: Estimativas de estado e sinal (Teste 2).




Fonte: Elaborado pelo Autor (2026).

Figura 14: Modelo 2: Análise de convergência e erro (Teste 2).

(a) MSE dos Estados (ϕ , ω , A).



(b) MSE da Saída (Monte Carlo)



Fonte: Elaborado pelo Autor (2026).


5.2.3 Teste 3: Inversão de Frequência 2

O **Teste 3** avalia o comportamento do filtro em cenários de forte incompatibilidade entre o modelo interno e a dinâmica real. As estimativas transientes, apresentadas na Figura 15, revelam a dificuldade inicial do EKF em sincronizar com a frequência portadora quando o erro de inicialização ultrapassa os limites de linearidade da Jacobiana.

A análise do Erro Quadrático Médio na Figura 16 demonstra que, embora o filtro busque a minimização do erro de saída para garantir o rastreamento do sinal, o custo computacional e o tempo de convergência dos estados internos são significativamente superiores aos observados

no Teste 1. Este comportamento reforça a sensibilidade do Modelo 2 às condições de contorno, evidenciando a necessidade de modelos mais adaptativos, como os que serão discutidos nas seções subsequentes.


Figura 15: Modelo 2: Estimativas de estado e sinal (Teste 3).




Fonte: Elaborado pelo Autor (2026).

Figura 16: Modelo 2: Análise de convergência e erro (Teste 3).

(a) MSE dos Estados (ϕ, ω, A).



(b) MSE da Saída (Monte Carlo).



Fonte: Elaborado pelo Autor (2026).

5.2.4 Conclusão Parcial do Modelo 2

Os resultados obtidos nas simulações do Modelo 2 corroboram as conclusões apresentadas por Zarchan e Musoff (2015), evidenciando que o desempenho deste EKF é estritamente dependente da acurácia da inicialização. Verificou-se que, em regimes onde a frequência real e a estimativa inicial compartilham o mesmo sinal algébrico ($\text{sgn}(\omega_{real}) = \text{sgn}(\hat{\omega}_0)$), o filtro apresenta uma convergência estável e fisicamente coerente dos estados de amplitude e fase.

Contudo, os cenários de incompatibilidade (Teste 2 e 3) revelaram a fragilidade do modelo frente às ambiguidades da função seno. Assim como reportado pelo autor, observou-se que o filtro converge para *mínimos locais* não físicos quando os sinais são opostos; embora o

rastreamento do sinal de saída seja mantido, a integridade dos estados internos é comprometida por inversões de sinal na amplitude ou deslocamentos espúrios de fase.

Em suma, a experiência prática ratifica que a escolha da representação dos estados no Modelo 2 limita a observabilidade global do sistema. Os resultados semelhantes aos da literatura confirmam que, apesar de funcional para rastreamento básico, este modelo carece de robustez para aplicações onde a direção da dinâmica (*frequência positiva ou negativa*) não é conhecida a priori, justificando a exploração de arquiteturas mais resilientes, como os Modelos 4 e 5.

5.3 Análise do Modelo 3: Redução de Ordem e Estabilização (ϕ, ω)

Foram realizadas 10 repetições independentes (Monte Carlo) para cada configuração de teste. As figuras apresentadas nas subseções ilustram a décima execução como exemplo; nos gráficos de Monte Carlo a curva preta representa a média das 10 execuções e as curvas em tons de cinza representam as execuções individuais.

O Modelo 3 (modelado na Subseção 4.2.3) foi proposto para mitigar as falhas de observabilidade identificadas na abordagem anterior. Ao assumir a amplitude A como uma constante conhecida e positiva, o filtro é reduzido para dois estados (ϕ, ω). Esta simplificação elimina a ambiguidade matemática $-A \sin(-\omega t) = A \sin(\omega t)$, uma vez que, com A fixo, apenas a convergência para a frequência angular com o sinal correto minimiza o erro quadrático médio.

Os parâmetros utilizados para validar a robustez desta abordagem estão consolidados na Tabela 3. Conforme modelado na sessão 4.2.3, adotou-se um $\sigma_{w1}^2 = 0$.

Tabela 3: Parâmetros de simulação para os testes do Modelo 3.


Parâmetro	Teste 1	Teste 2	Teste 3
T_s (Amostragem)	0,01 segundos		
Tempo Total	10 segundos		
Monte Carlo	10 repetições		
Amplitude (A)	1,5		
ω	1,2 rad/s	1,2 rad/s	-1,2 rad/s
ϕ_0	0 rad		
$\sigma_{w1}^2, \sigma_{w2}^2$	0; 0,001	0; 0,001	0; 0,001
R (Medição)	0,1	0,1	0,1
$\hat{x}_0$ (Inicial)	$[0; 1]^T$	$[0; -1]^T$	$[0; 1]^T$

5.3.1 Teste 1: Desempenho em Cenário Nominal

No cenário nominal, o Modelo 3 apresenta uma convergência superior ao Modelo 2, com menor tempo de acomodação para a frequência angular. A ausência da amplitude como estado a ser estimado reduz o acoplamento não linear, resultando em um rastreo mais limpo e estável (conforme a Figura 17). A diminuição dos erros quadráticos médios é observado na

Figura 18.


Figura 17: Modelo 3: Estimativas (Teste 1).




Fonte: Elaborado pelo Autor (2026).

Figura 18: Modelo 3: Convergências do erro (Teste 1).

(a) MSE dos Estados (ϕ, ω)



(b) MSE de Saída (Monta Carlo)



Fonte: Elaborado pelo Autor (2026).


5.3.2 Teste 2: Robustez à Inversão de Sinais e Ambiguidade

No cenário de inversão de frequência (Teste 2), o Modelo 3 demonstra uma robustez estrutural superior ao Modelo 2. Ao remover a amplitude do vetor de estados, elimina-se o acoplamento não linear que permitia a convergência para mínimos locais não físicos (como a amplitude negativa observada anteriormente). Sem esse "grau de liberdade" espúrio, o filtro é forçado a ajustar a frequência angular e a fase de forma mais direta, resultando em um rastreamento mais limpo e estável, como ilustrado na Figura 19.

A análise do Erro Quadrático Médio (Figura 20) confirma que a simplificação do modelo de estados acelera a convergência. O erro de saída decai de forma mais abrupta, indicando que

a estrutura do Modelo 3 lida de forma mais eficiente com a ambiguidade matemática do sinal de seno.


Figura 19: Modelo 4: Estimativas (Teste 2).




Fonte: Elaborado pelo Autor (2026).

Figura 20: Modelo 3: Convergências do erro (Teste 2).

(a) MSE dos Estados (ϕ, ω)



(b) MSE de Saída (Monta Carlo)



Fonte: Elaborado pelo Autor (2026).


5.3.3 Teste 3: Convergência em Condições de Desajuste Acentuado

Os resultados do Teste 3 ratificam a superioridade do Modelo 3 no que tange à resposta em regime transiente. Observa-se uma redução significativa no tempo de acomodação da frequência angular (ω) em comparação às arquiteturas precedentes, mesmo sob condições de severo desajuste inicial. A estabilidade do rastreamento, evidenciada na Figura 21, sugere que a redução da ordem do vetor de estados mitiga a propagação de incertezas espúrias através das Jacobianas de predição, conferindo maior robustez ao algoritmo.

A análise das curvas de erro na Figura 22 revela que a minimização do Erro Quadrático Médio (MSE) ocorre de forma assintótica e suave, apresentando um *overshoot* desprezível nas estimativas de estado. Este fenômeno valida a hipótese de que, ao tratar a amplitude como um

parâmetro invariante e conhecido, o filtro elimina um grau de liberdade não linear crítico. Consequentemente, o esforço computacional do EKF é concentrado na convergência da dinâmica temporal (frequência e fase), resultando em uma estimativa mais precisa e menos suscetível a instabilidades numéricas inerentes a modelos de maior dimensionalidade.


Figura 21: Modelo 3: Estimativas (Teste 3).




Fonte: Elaborado pelo Autor (2026).

Figura 22: Modelo 3: Convergências do erro (Teste 3).

(a) MSE dos Estados (ϕ, ω)



(b) MSE de Saída (Monta Carlo)



Fonte: Elaborado pelo Autor (2026).

5.3.4 Conclusão Parcial do Modelo 3

Os resultados do Teste 3 ratificam a superioridade do Modelo 3 no que tange à resposta em regime transiente. Observa-se uma redução significativa no tempo de acomodação da frequência angular (ω) em comparação às arquiteturas precedentes, mesmo sob condições de severo desajuste inicial. A estabilidade do rastreamento, evidenciada na Figura 21, sugere que a redução da ordem do vetor de estados mitiga a propagação de incertezas espúrias através das Jacobianas de predição, conferindo maior robustez ao algoritmo.

A análise das curvas de erro na Figura 22 revela que a minimização do Erro Quadrático Médio (MSE) ocorre de forma assintótica e suave, apresentando um *overshoot* desprezível nas estimativas de estado. Este fenômeno valida a hipótese de que, ao tratar a amplitude como um parâmetro invariante e conhecido, o filtro elimina um grau de liberdade não linear crítico. Consequentemente, o esforço computacional do EKF é concentrado na convergência da dinâmica temporal (frequência e fase), resultando em uma estimativa mais precisa e menos suscetível a instabilidades numéricas inerentes a modelos de maior dimensionalidade.

5.4 Análise do Modelo 4: Estados Dinâmicos $(x, \dot{x}, \omega)$

Foram realizadas 10 repetições independentes (Monte Carlo) para cada configuração de teste. As figuras apresentadas nas subseções ilustram a décima execução como exemplo; nos gráficos de Monte Carlo a curva preta representa a média das 10 execuções e as curvas em tons de cinza representam as execuções individuais.

Para o modelo 4 (modelado na Subseção 4.2.4), a transição para coordenadas dinâmicas (posição e velocidade do oscilador) proporcionou um incremento significativo na estabilidade do rastreamento em ambientes ruidosos. Nesta topologia, o filtro estima a frequência angular como um estado variante, porém fundamentado na equação diferencial $\ddot{x} + \omega^2 x = 0$.

Os testes realizados nesse modelo estão definidos seguindo a Tabela 4.

Tabela 4: Parâmetros de simulação para os testes do Modelo 4.

Parâmetro	Teste 1	Teste 2	Teste 3
T_s (Amostragem)	0,01 segundos		
Tempo Total	10 segundos		
Monte Carlo	10 repetições		
Amplitude (A)	1,5		
ω	1,2 rad/s		
ϕ_0	0 rad		
$\sigma_{w1}^2, \sigma_{w2}^2, \sigma_{w3}^2$	0,001; 0,001; 0,01	0,001; 0,001; 0,1	0,5; 0,5; 2,0
R (Medição)	0,1	0,1	2,0
$\hat{\mathbf{x}}_0$ (Inicial)	$[0; 1; 1]^T$	$[0; 1; 1]^T$	$[10; 10; 10]^T$


5.4.1 Teste 1: Desempenho em Cenário Nominal

No cenário nominal, o Modelo 4 apresenta oscilações transientes características nas estimativas da derivada ($\dot{y}$) e da frequência angular (ω). Este fenômeno decorre do forte acoplamento dinâmico no vetor de estados: como a predição da velocidade depende da precisão instantânea da posição (y), qualquer erro residual na estimativa de amplitude propaga-se diretamente para $\dot{y}$, o que, por conseguinte, instabiliza temporariamente o cálculo de ω através da Jacobiana adaptativa.

Diferente dos modelos anteriores, a convergência aqui é um processo iterativo de ajuste

mútuo entre as variáveis físicas. As Figuras 23 e 24 ilustram este comportamento, demonstrando que, após o período de sincronismo inicial, o filtro estabiliza e o Erro Quadrático Médio (MSE) decai para níveis condizentes com o limite ótimo de filtragem, validando a formulação dinâmica do estimador.


Figura 23: Modelo 4: Estimativas (Teste 1).




Fonte: Elaborado pelo Autor (2026).

Figura 24: Modelo 4: Convergências do erro (Teste 1).

(a) MSE dos Estados ($x, \dot{x}, \omega$)



(b) MSE de saída (Monte Carlo)




5.4.2 Teste 2: Resolução da Ambiguidade de Sinal

O **Teste 2** do Modelo 4 revela uma propriedade fundamental de sua formulação dinâmica: a invariância ao sinal da frequência angular inicial ($\hat{\omega}_0$). Ao inicializar o filtro com uma velocidade angular negativa, observa-se uma trajetória de convergência qualitativamente semelhante à do Teste 1. Este fenômeno ocorre porque a equação de transição de estados utiliza o termo quadrático da frequência (ω^2) para definir a aceleração do sistema ($\ddot{y} = -\omega^2 y$).

Matematicamente, a função de custo do filtro não diferencia sinais opostos de ω , uma vez que ambos produzem a mesma dinâmica de oscilação para o sinal y . Consequentemente,

o modelo converge para o *mínimo quadrático* mais próximo da estimativa inicial, validando a estabilidade do Modelo 4 mesmo em cenários de incerteza de fase ou direção rotacional. Esta característica torna o Modelo 4 superior ao Modelo 2, pois elimina a necessidade de inversão da amplitude ou deslocamentos espúrios de fase para compensar o sinal da frequência.


Figura 25: Modelo 4: Estimativas (Teste 2).




Fonte: Elaborado pelo Autor (2026).

Figura 26: Modelo 4: Convergências do erro (Teste 2).

(a) MSE dos Estados ($x, \dot{x}, \omega$)



(b) MSE de saída (Monte Carlo)




Fonte: Elaborado pelo Autor (2026).

5.4.3 Teste 3: Robustez à Estimativa Inicial e Transiente de Adaptação

O **Teste 3** avalia o comportamento do Modelo 4 sob condições de forte desajuste entre a estimativa inicial e os parâmetros reais do sistema. Observa-se que o filtro mantém uma instabilidade característica nas estimativas de velocidade ($\dot{y}$) e frequência angular (ω) durante o período inicial de operação. Este fenômeno é atribuído ao *tempo de acomodação* do estimador, uma vez que as Jacobianas adaptativas dependem da convergência prévia do sinal de saída para linearizar corretamente a dinâmica do oscilador.

Contudo, um resultado de destaque deste modelo é sua capacidade de convergência acelerada: mesmo com valores iniciais significativamente distantes do regime nominal, o filtro atinge a estabilidade antes da conclusão de um ciclo completo da senoide ($t < 2\pi/\omega$). Este desempenho evidencia a robustez da formulação em variáveis de estado, que consegue reajustar o ganho de Kalman (K) de forma eficiente para corrigir o erro de fase e frequência de maneira simultânea, como ilustrado na Figura 27.


Figura 27: Modelo 4: Estimativas (Teste 3).




Fonte: Elaborado pelo Autor (2026).

Figura 28: Modelo 4: Convergências do erro (Teste 3).

(a) MSE dos Estados ($x, \dot{x}, \omega$)



(b) MSE de saída (Monte Carlo)



Fonte: Elaborado pelo Autor (2026).

5.4.4 Conclusão da Parcial do Modelo 4

O autor concluiu que o Modelo 4 é eficaz em estimar os estados da senoide de forma robusta frente à inicialização. Contudo, a estimação exata do sinal e do sinal da frequência depende da coincidência do sinal da estimativa inicial com o da frequência real; em casos de incompatibilidade, o filtro estima corretamente a magnitude de ω mas erra a polaridade, devido

à presença do termo ω^2 nas equações de estado. Ainda assim, para fins de rastreamento do sinal e sua derivada, conhecer apenas a magnitude de ω é suficiente, tornando o modelo prático para aplicações onde o sinal da frequência não é crítico (ZARCHAN; MUSOFF, 2015).

5.5 Análise do Modelo 5: Resolução via Frequência ao Quadrado ($x, \dot{x}, z$)

Foram realizadas 10 repetições independentes (Monte Carlo) para cada configuração de teste. As figuras apresentadas nas subseções ilustram a décima execução como exemplo; nos gráficos de Monte Carlo a curva preta representa a média das 10 execuções e as curvas em tons de cinza representam as execuções individuais.

O Modelo 5 (modelado na Subseção 4.2.5) representa a solução definitiva para os problemas de ambiguidade encontrados nas versões anteriores. Ao redefinir o terceiro estado como o quadrado da frequência angular ($z = \omega^2$), a inobservabilidade do sinal é eliminada por construção matemática. Esta abordagem remove a não linearidade excessiva da função seno em relação à frequência, simplificando a superfície de erro do filtro.

Tabela 5: Parâmetros de simulação para os testes do Modelo 5.


Parâmetro	Teste 1	Teste 2	Teste 3
T_s (Amostragem)	0,01 segundos		
Tempo Total	10 segundos		
Monte Carlo	10 repetições		
Amplitude (A)	1.5		
ω	1.2 rad/s		
ϕ_0	0 rad		
$\sigma_{w1}^2, \sigma_{w2}^2, \sigma_{w3}^2$	0,001; 0,001; 0,01	0,001; 0,001; 0,1	0,5; 0,5; 2,0
R (Medição)	0,1	0,1	2,0
$\hat{x}_0$ (Inicial)	$[0; 1; 1]^T$	$[0; 1; -1]^T$	$[10; 10; -10]^T$

5.5.1 Teste 1: Desempenho em Cenário Nominal

No cenário nominal, o Modelo 5 demonstrou uma convergência rápida e estável para o sinal de saída, apresentando um desempenho comparável ao do Modelo 4. Adicionalmente, o rastreamento do estado correspondente à derivada do sinal ($\dot{y}$) ocorreu de forma célere e sem desvios abruptos. Embora o regime transiente ainda apresente oscilações na estimativa da frequência angular (ω), nota-se que estas se manifestam com uma amplitude significativamente atenuada em relação à arquitetura anterior.

As Figuras 31 e 32 ilustram o comportamento das estimativas de estado e a evolução da convergência do erro para o Teste 2.


Figura 29: Modelo 5: Estimativas (Teste 1).




Fonte: Elaborado pelo Autor (2026).

Figura 30: Modelo 5: Convergências do erro (Teste 1).

(a) MSE dos Estados ($x, \dot{x}, z$)



(b) MSE da Saídas (Monte Carlo)




Fonte: Elaborado pelo Autor (2026).

5.5.2 Teste 2: Resolução da Ambiguidade de Sinal

O Modelo 5 apresenta um comportamento dinâmico análogo ao do Modelo 4, porém com uma vantagem estrutural significativa: a mitigação do problema de ambiguidade de sinal. Ao estimar a frequência ao quadrado ($z = \omega^2$), a formulação contorna a incerteza direcional da inicialização, garantindo a convergência estrita para a frequência angular correta. Esse desempenho superior no rastreamento da dinâmica física pode ser observado na Figura 31.

Adicionalmente, a evolução do Erro Quadrático Médio (MSE), detalhada na Figura 32, ratifica a estabilidade global do filtro. As curvas evidenciam a minimização consistente tanto das incertezas dos estados internos ($y, \dot{y}, z$) quanto do erro de saída ao longo do regime transiente.


Figura 31: Modelo 5: Estimativas (Teste 2).




Fonte: Elaborado pelo Autor (2026).

Figura 32: Modelo 5: Convergências do erro (Teste 2).

(a) MSE dos Estados ($x, \dot{x}, z$)



(b) MSE da Saídas (Monte Carlo)




Fonte: Elaborado pelo Autor (2026).

5.5.3 Teste 3: Robustez a estimativa inicial

O Teste 3 avalia a resiliência do Modelo 5 quando submetido a condições severas de desajuste em sua inicialização. Conforme ilustrado na Figura 33, observa-se que o algoritmo demonstra uma notável capacidade de recuperação, convergindo para os parâmetros físicos reais em um intervalo de tempo inferior a um ciclo completo do sinal senoidal ($t < 2\pi/\omega$). Esse comportamento em regime transiente atesta a robustez do estimador diante de entradas adversas.

A análise das curvas de Erro Quadrático Médio, apresentadas na Figura 34, corrobora esta rápida adaptação. A convergência acelerada tanto das estimativas dos estados internos ($y, \dot{y}, z$) quanto do erro de saída valida a eficácia da matriz de covariância e do ganho de Kalman adaptativo formulados para esta arquitetura.


Figura 33: Modelo 5: Estimativas (Teste 3).




Fonte: Elaborado pelo Autor (2026).

Figura 34: Modelo 5: Convergências do erro (Teste 3).

(a) MSE dos Estados ($x, \dot{x}, z$)



(b) MSE da Saídas (Monte Carlo)



Fonte: Elaborado pelo Autor (2026).

5.5.4 Conclusão Parcial do Modelo 5

Ao redefinir o terceiro estado do filtro como a frequência angular ao quadrado ($z = \omega^2$), a formulação elimina a ambiguidade de sinal por construção matemática, simplificando significativamente a topologia da função de custo do estimador. Na prática, o desempenho estocástico e os erros de estimação mostraram-se virtualmente idênticos aos obtidos no Modelo 4. Portanto, a introdução da variável z não altera o limite inferior do Erro Quadrático Médio (MSE), mas oferece uma estrutura com observabilidade mais direta e inequivocamente atrelada à física do oscilador. Conclui-se que o Modelo 5 é altamente eficaz na estimação dos estados de sinais senoidais, sobressaindo-se por mitigar o risco de convergência para mínimos locais não físicos (ZARCHAN; MUSOFF, 2015).

5.5.5 Síntese Comparativa da Evolução dos Modelos

A progressão metodológica do Modelo 1 ao Modelo 5 corrobora a premissa de que a definição do espaço de estados é tão determinante para o sucesso da estimação quanto o próprio algoritmo do Filtro de Kalman. Constatou-se que as arquiteturas baseadas em fase explícita (Modelos 2 e 3) são inerentemente suscetíveis a descontinuidades trigonométricas e ambiguidades de sinal. Em contrapartida, as formulações baseadas na dinâmica do oscilador harmônico (Modelos 4 e 5) provaram ser substancialmente mais robustas. Especificamente, a modelagem via frequência ao quadrado (Modelo 5) consolidou-se como a abordagem mais confiável para aplicações práticas com sensores ruidosos, assegurando convergência global e a estrita validade física das estimativas. Em suma, observou-se que a convergência para o estado estacionário ocorreu em um intervalo inferior a um ciclo completo do sinal de referência. Este desempenho no regime transiente é sensível à calibração das matrizes de covariância, podendo ser otimizado mediante o ajuste fino dos parâmetros de processo e medição. Ressalta-se, contudo, que a síntese dos filtros baseou-se no conhecimento prévio da estatística dos ruídos. Em aplicações reais, onde as propriedades estocásticas são incertas, a etapa de sintonização (tuning) exige uma caracterização experimental rigorosa das variâncias para assegurar a otimalidade do estimador.

5.6 Análise Comparativa Global

A Tabela 6 sintetiza as métricas de desempenho das arquiteturas avaliadas ao longo deste estudo. O Modelo 5 consolida-se como a solução de maior destaque, promovendo um balanço ótimo entre a precisão do rastreamento em regime permanente e a imunidade total a erros grosseiros de inicialização.

Tabela 6: Comparativo global de Robustez e Precisão dos Modelos da Senoide

Modelo	MSE Sinal	Robustez Inicial	Observabilidade
1 LKF ($[y; \dot{y}]$)	Mínimo*	Alta	Total
2 EKF ($[\phi; \omega; A]$)	Alto	Baixa	Parcial
3 EKF ($[\phi; \omega]$)	Médio	Moderada	Total
4 EKF ($[y; \dot{y}; \omega]$)	Baixo	Boa	Parcial
5 EKF ($[y; \dot{y}; \omega^2]$)	Muito Baixo	Elevada	Total

Fonte: Elaborado pelo autor (2026).

* Refere-se ao limite teórico ótimo por tratar-se de um modelo linear com parâmetros conhecidos.

Tabela 7: Estimativa do MSE (inicial e convergido) e tempo até quasi-estacionário (Monte Carlo, 10 execuções).

Modelo / Teste	MSE inicial	MSE Final	Tempo. Estacionário (s)
1 LKF - Teste 1	0,06	0,001	0,3
1 LKF - Teste 2	0,06	0,001	0,3
1 LKF - Teste 3	0,25	0,005	0,5
1 LKF - Teste 4	0,08	0,002	0,4
2 EKF - Teste 1	0,06	0,002	0,5
2 EKF - Teste 2	0,20	0,010	1,0
2 EKF - Teste 3	0,40	0,020	1,5
3 EKF - Teste 1	0,05	0,001	0,4
3 EKF - Teste 2	0,06	0,001	0,4
3 EKF - Teste 3	0,08	0,002	0,5
4 EKF - Teste 1	0,20	0,010	0,6
4 EKF - Teste 2	0,25	0,015	0,7
4 EKF - Teste 3	0,60	0,030	1,2
5 EKF - Teste 1	0,15	0,005	0,5
5 EKF - Teste 2	0,18	0,006	0,6
5 EKF - Teste 3	0,50	0,020	1,0

Fonte: Elaborado pelo autor (2026).

A Tabela 7 resume as estimativas visuais do erro quadrático médio (MSE) no instante inicial e em regime convergido, bem como o tempo aproximado até o comportamento quasi-estacionário para cada modelo e teste. Observa-se, a partir dos valores apresentados, que:

- Os Modelos 1 e 3 alcançam os menores valores de MSE convergido (ordem de 10^{-3} a 10^{-2}) e apresentam tempos de evolução mais rápidos (aprox. 0,3–0,4 s), indicando convergência rápida quando as hipóteses lineares ou moderadas se mantêm.
- O Modelo 4 exibe tanto MSE inicial mais elevado quanto MSE convergido maior, além de tempos de estabilização superiores (até 1,2 s), o que sugere sensibilidade às não linearidades e pior ajuste em regime estacionário.
- O Modelo 2 apresenta comportamento intermediário: em alguns testes (ex.: Teste 3) a convergência é lenta e o MSE convergido maior, apontando para menor robustez frente a variações paramétricas.
- O Modelo 5 combina MSE convergido competitivo com tempos de convergência moderados, o que corrobora sua utilidade prática apontada anteriormente; sua performance sugere um bom compromisso entre precisão de estado e robustez numérica.

Essas conclusões, extraídas da Tabela 7, devem ser interpretadas com cautela: como indicado na legenda, os números são estimativas visuais a partir das figuras de Monte Carlo e destinam-se a dar uma intuição sobre a velocidade de evolução de cada método. Para comparações quantitativas rigorosas, recomenda-se substituir estes valores por métricas computadas diretamente a partir dos vetores de erro gerados nos scripts (saída do GNU Octave) e, preferencialmente, apresentar intervalos de confiança sobre a média Monte Carlo.

Em suma, enquanto o Modelo 1 estabelece o referencial teórico ótimo para o problema, o Modelo 5 demonstrou ser a implementação prática mais resiliente. Esta arquitetura supera com êxito as limitações intrínsecas do Filtro de Kalman Estendido (EKF) ao lidar com não linearidades severas de natureza trigonométrica, garantindo estabilidade analítica e viabilizando sua aplicação confiável em sistemas de tempo real.

6 CONCLUSÃO

Este estudo demonstrou que a eficácia do Filtro de Kalman Estendido (EKF) no rastreamento de sinais senoidais não é garantida por uma escolha arbitrária de modelagem, mas reside na convergência entre a arquitetura do espaço de estados e os requisitos específicos da aplicação. Evidenciou-se que a seleção do modelo não é um processo trivial; modelos parametrizados diretamente em fase, frequência e amplitude (Modelos 2 e 3) revelaram vulnerabilidades críticas de observabilidade, tornando-se susceptíveis a mínimos locais sob inicializações imprecisas. Portanto, cabe ao projetista realizar uma análise criteriosa da topologia do sistema, compreendendo que a robustez estrutural precede os ajustes paramétricos.

Neste contexto, a transição para modelos baseados na dinâmica do oscilador harmônico representou um avanço significativo. O **Modelo 5** consolidou-se como a abordagem superior ao definir o estado como a frequência angular ao quadrado ($z = \omega^2$). Esta estratégia permite a linearização parcial das relações de estado e elimina, por construção matemática, a ambiguidade de sinal, garantindo um rastreamento estável e fisicamente coerente mesmo sob condições iniciais adversas ou ruidosas.

Paralelamente à estrutura do modelo, observou-se que a funcionalidade plena do algoritmo é estritamente condicionada à definição precisa das matrizes de covariância do ruído de processo (Q) e de medição (R). Embora nesta pesquisa a suposição de valores ótimos tenha sido facilitada pela natureza controlada dos testes, em cenários práticos de instrumentação, essa definição assume um caráter empírico e complexo. Este processo, tecnicamente denominado *sintonização* (ou *tuning*) do Filtro de Kalman, constitui um dos maiores desafios da engenharia de controle, exigindo do projetista uma compreensão profunda do balanço entre a rapidez de resposta e a imunidade ao ruído.

Em suma, o trabalho conclui que o sucesso na extração de informações de sensores ruidosos depende de um compromisso entre uma estrutura de estados que minimize singularidades e uma sintonização rigorosa das estatísticas de ruído. O Modelo 5 provou ser a ferramenta mais resiliente para superar as não linearidades intrínsecas ao rastreamento senoidal, estabelecendo-se como uma base confiável para o desenvolvimento de sensores inteligentes e sistemas de processamento de sinais em tempo real.

REFERÊNCIAS

BROWN, R. G.; HWANG, P. Y. C. *Introduction to Random Signals and Applied Kalman Filtering: with MATLAB Exercises*. 4th. ed. Hoboken, New Jersey: John Wiley & Sons, 2012. ISBN 9780470609699.

GAUSS, C. F. *Theory of the Motion of the Heavenly Bodies Moving about the Sun in Conic Sections*. Boston: Little, Brown and Company, 1857. Originalmente publicado em latim em 1809 como "Theoria motus corporum coelestium".

GELB, A. et al. *Applied Optimal Estimation*. Cambridge, Massachusetts: MIT Press, 1974. ISBN 9780262570480.

KALMAN, R. E. A new approach to linear filtering and prediction problems. *Transactions of the ASME—Journal of Basic Engineering*, v. 82, n. 1, p. 35–45, 1960.

OGATA, K. *Engenharia de Controle Moderno*. 5. ed. São Paulo: Pearson Prentice Hall, 2010.

SILVA, S. J. A. *Atividades da Disciplinas Sistemas Inteligentes - UFCG 2026*. [S.l.]: GitHub, 2026. <<https://github.com/SauloJose/SistemasInteligentes2026>>. Acesso em: 18 mar. 2026.

SIMON, D. *Optimal State Estimation: Kalman, H Infinity, and Nonlinear Approaches*. Hoboken, New Jersey: John Wiley & Sons, 2006. ISBN 9780471715429.

SORENSEN, H. W. Least-squares estimation: from Gauss to Kalman. *IEEE Spectrum*, v. 7, n. 7, p. 63–68, 1970.

ZARCHAN, P.; MUSOFF, H. Fundamentals of kalman filtering: A practical approach. In: _____. 4th. ed. Reston, Virginia: American Institute of Aeronautics and Astronautics (AIAA), 2015. (Progress in Astronautics and Aeronautics), cap. 10: Tracking a Sine Wave, p. 421–441. ISBN 9781624102707.

A SOLUÇÃO DA EQUAÇÃO DE ESTADOS HOMOGÊNEA

Considere a forma homogênea da equação de estados no domínio do tempo contínuo:

$$\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) \quad (71)$$

Para o caso escalar, definido por $\dot{x}(t) = ax(t)$, a solução geral para $t > t_0$ é dada por:

$$x(t) = e^{a(t-t_0)}x(t_0) \quad (72)$$

Dessa forma, espera-se que a solução para a forma vetorial apresente uma estrutura semelhante. O ponto de partida consiste em expandir o termo exponencial e^x em sua série de potências de Taylor:

$$e^x = \exp(x) = \left(1 + x + \frac{x^2}{2!} + \dots + \frac{x^k}{k!} + \dots\right) = \sum_{n=0}^{\infty} \frac{x^n}{n!}, \quad \forall x \in \mathbb{R} \quad (73)$$

Aplicando esta expansão ao caso escalar da solução do sistema, temos:

$$x(t) = \left(\sum_{n=0}^{\infty} \frac{a^n(t-t_0)^n}{n!}\right)x(t_0) \quad (74)$$

Considerando o caso em que $t_0 = 0$, temos

$$x(t) = \left(\sum_{n=0}^{\infty} \frac{(at)^n}{n!}\right)x(0) \quad (75)$$

Assume-se, por hipótese, que a solução para o caso vetorial descrito na Equação (71) também possa ser expressa como uma série de potências de matrizes:

$$\mathbf{x}(t) = \mathbf{b}_0 + \mathbf{b}_1 t + \mathbf{b}_2 t^2 + \dots + \mathbf{b}_k t^k + \dots \quad (76)$$

Substituindo a Equação (76) em (71), obtém-se:

$$\frac{d}{dt} \left(\sum_{k=0}^{\infty} \mathbf{b}_k t^k \right) = \mathbf{A} \left(\sum_{k=0}^{\infty} \mathbf{b}_k t^k \right) \quad (77)$$

Calculando a derivada temporal do lado esquerdo e expandindo os termos:

$$\mathbf{b}_1 + 2\mathbf{b}_2 t + 3\mathbf{b}_3 t^2 + \dots + k\mathbf{b}_k t^{k-1} + \dots = \mathbf{A}\mathbf{b}_0 + \mathbf{A}\mathbf{b}_1 t + \mathbf{A}\mathbf{b}_2 t^2 + \dots \quad (78)$$

Ao igualar os coeficientes das potências de t correspondentes, resulta no seguinte sis-

tema de equações lineares:

$$\begin{cases} \mathbf{b}_1 = \mathbf{A}\mathbf{b}_0 \\ 2\mathbf{b}_2 = \mathbf{A}\mathbf{b}_1 \\ 3\mathbf{b}_3 = \mathbf{A}\mathbf{b}_2 \\ \vdots \\ k\mathbf{b}_k = \mathbf{A}\mathbf{b}_{k-1} \end{cases} \quad (79)$$

Este sistema define uma relação recursiva para os coeficientes $\mathbf{b}_k$, dada por:

$$\mathbf{b}_k = \frac{\mathbf{A}\mathbf{b}_{k-1}}{k} \quad (80)$$

Ao desenvolver a recursão, observa-se o surgimento do fatorial no denominador:

$$\mathbf{b}_k = \frac{\mathbf{A}}{k} \left(\frac{\mathbf{A}\mathbf{b}_{k-2}}{k-1} \right) = \frac{\mathbf{A}^2}{k(k-1)} \mathbf{b}_{k-2} = \dots = \frac{\mathbf{A}^k}{k!} \mathbf{b}_0 \quad (81)$$

Substituindo os coeficientes $\mathbf{b}_k$ na série original e isolando o vetor constante $\mathbf{b}_0$:

$$\mathbf{x}(t) = \left(\mathbf{I} + \mathbf{A}t + \frac{\mathbf{A}^2 t^2}{2!} + \dots + \frac{\mathbf{A}^k t^k}{k!} + \dots \right) \mathbf{b}_0 \quad (82)$$

Empregando a notação de somatório, a expressão torna-se:

$$\mathbf{x}(t) = \left(\sum_{n=0}^{\infty} \frac{\mathbf{A}^n t^n}{n!} \right) \mathbf{b}_0 \quad (83)$$

Ao avaliar a solução para o instante inicial $t = 0$, verifica-se que $\mathbf{x}(0) = \mathbf{b}_0$. Portanto, a solução da equação homogênea é:

$$\mathbf{x}(t) = \left(\sum_{n=0}^{\infty} \frac{(\mathbf{A}t)^n}{n!} \right) \mathbf{x}(0) \quad (84)$$

Esta série de potências matriciais é definida como a matriz exponencial, denotada por $\exp(\mathbf{A}t)$ ou $e^{\mathbf{A}t}$. Assim, a solução final assume a forma compacta:

$$\mathbf{x}(t) = e^{\mathbf{A}t} \mathbf{x}(0) \quad (85)$$

Este resultado é formalmente equivalente à solução encontrada para o caso escalar, estendendo o conceito de exponencial para operadores matriciais.

B SOLUÇÃO GERAL DE ESTADOS NÃO-HOMOGÊNEA COM RUÍDO DE PROCESSO

O caso mais abrangente na modelagem ocorre quando consideramos as incertezas do sistema, representadas pelo vetor de ruído de processo $\mathbf{w}(t)$. A equação de transição de estados assume, então, a seguinte forma:

$$\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t) + \mathbf{w}(t) \quad (86)$$

Uma estratégia eficiente para resolver esta equação diferencial consiste em agrupar os termos que envolvem o vetor de estados $\mathbf{x}(t)$ e utilizar o fator integrante matricial $e^{-\mathbf{A}t}$:

$$\dot{\mathbf{x}}(t) - \mathbf{A}\mathbf{x}(t) = \mathbf{B}\mathbf{u}(t) + \mathbf{w}(t) \quad (87)$$

Multiplicando ambos os lados da igualdade à esquerda pelo fator integrante:

$$e^{-\mathbf{A}t} [\dot{\mathbf{x}}(t) - \mathbf{A}\mathbf{x}(t)] = e^{-\mathbf{A}t} \mathbf{B}\mathbf{u}(t) + e^{-\mathbf{A}t} \mathbf{w}(t) \quad (88)$$

Observa-se que o lado esquerdo da igualdade corresponde exatamente à derivada temporal do produto entre a matriz exponencial e o vetor de estados, visto que $\frac{d}{dt} (e^{-\mathbf{A}t}) = -\mathbf{A}e^{-\mathbf{A}t}$. Assim, a equação simplifica-se para:

$$\frac{d}{dt} (e^{-\mathbf{A}t} \mathbf{x}(t)) = e^{-\mathbf{A}t} \mathbf{B}\mathbf{u}(t) + e^{-\mathbf{A}t} \mathbf{w}(t) \quad (89)$$

Integrando ambos os lados em relação a uma variável auxiliar τ , no intervalo de t_0 a t :

$$\int_{t_0}^t \frac{d}{d\tau} (e^{-\mathbf{A}\tau} \mathbf{x}(\tau)) d\tau = \int_{t_0}^t (e^{-\mathbf{A}\tau} \mathbf{B}\mathbf{u}(\tau) + e^{-\mathbf{A}\tau} \mathbf{w}(\tau)) d\tau \quad (90)$$

Pelo Teorema Fundamental do Cálculo, o lado esquerdo resulta na diferença da função avaliada nos limites de integração:

$$e^{-\mathbf{A}t} \mathbf{x}(t) - e^{-\mathbf{A}t_0} \mathbf{x}(t_0) = \int_{t_0}^t e^{-\mathbf{A}\tau} \mathbf{B}\mathbf{u}(\tau) d\tau + \int_{t_0}^t e^{-\mathbf{A}\tau} \mathbf{w}(\tau) d\tau \quad (91)$$

Isolando o termo que contém $\mathbf{x}(t)$ e multiplicando toda a equação à esquerda por $e^{\mathbf{A}t}$, obtemos:

$$\mathbf{x}(t) = e^{\mathbf{A}t} e^{-\mathbf{A}t_0} \mathbf{x}(t_0) + e^{\mathbf{A}t} \int_{t_0}^t e^{-\mathbf{A}\tau} \mathbf{B}\mathbf{u}(\tau) d\tau + e^{\mathbf{A}t} \int_{t_0}^t e^{-\mathbf{A}\tau} \mathbf{w}(\tau) d\tau \quad (92)$$

Dado que a matriz exponencial $e^{\mathbf{A}t}$ é independente da variável de integração τ , ela pode ser deslocada para o interior dos integrandos. Combinando as exponenciais através da proprie-

dade $e^{\mathbf{M}}e^{\mathbf{N}} = e^{\mathbf{M}+\mathbf{N}}$ (válida pois $\mathbf{A}t$ e $-\mathbf{A}\tau$ comutam), chega-se à solução geral:

$$\mathbf{x}(t) = e^{\mathbf{A}(t-t_0)}\mathbf{x}(t_0) + \int_{t_0}^t e^{\mathbf{A}(t-\tau)}\mathbf{B}\mathbf{u}(\tau)d\tau + \int_{t_0}^t e^{\mathbf{A}(t-\tau)}\mathbf{w}(\tau)d\tau \quad (93)$$

A Equação (93) demonstra que a evolução do estado do sistema é composta pela superposição de três parcelas: a resposta à entrada nula (dependente apenas da condição inicial), a resposta determinística ao estado nulo (resultante da convolução com o sinal de controle) e a resposta estocástica (resultante da acumulação do ruído de processo no intervalo considerado). Observe também que caso $\mathbf{w}(t) = \mathbf{0}$, a Equação 93 decai na Equação 94, que seria o caso ideal, sem erros no processo do modelo.

$$\mathbf{x}(t) = e^{\mathbf{A}(t-t_0)}\mathbf{x}(t_0) + \int_{t_0}^t e^{\mathbf{A}(t-\tau)}\mathbf{B}\mathbf{u}(\tau)d\tau \quad (94)$$

C LINEARIZAÇÃO DA DINÂMICA DO ERRO DE ESTIMAÇÃO PARA O FILTRO DE KALMAN ESTENDIDO

A fundamentação para a linearização de sistemas dinâmicos não lineares no contexto da filtragem estendida baseia-se na expansão em Série de Taylor de primeira ordem. Para uma função vetorial de múltiplas variáveis $\mathbf{h}(\mathbf{z})$, a expansão em torno de um ponto de operação nominal $\mathbf{z}_0$ é definida por:

$$\mathbf{h}(\mathbf{z}) \approx \mathbf{h}(\mathbf{z}_0) + \left. \frac{\partial \mathbf{h}}{\partial \mathbf{z}} \right|_{\mathbf{z}=\mathbf{z}_0} (\mathbf{z} - \mathbf{z}_0) \quad (95)$$

Considere o modelo de estados do sistema definido na Equação (5). No Filtro de Kalman Estendido (EKF), não linearizamos o sistema em torno de um ponto de equilíbrio estático, mas sim em torno da própria trajetória nominal estimada, dada por $(\hat{\mathbf{x}}(t), \mathbf{u}(t))$.

Para tal, definem-se as variáveis de desvio (ou perturbação) como a diferença entre o estado verdadeiro e o estado nominal:

$$\Delta \mathbf{x}(t) = \mathbf{x}(t) - \hat{\mathbf{x}}(t) \quad (96)$$

Aplicando a expansão de Taylor (95) na equação diferencial não linear do sistema e desprezando os termos de ordem superior, obtemos:

$$\dot{\mathbf{x}}(t) \approx \mathbf{f}(\hat{\mathbf{x}}(t), \mathbf{u}(t), t) + \mathbf{F}(t)\Delta \mathbf{x}(t) + \mathbf{w}(t) \quad (97)$$

Sabendo que a dinâmica da trajetória nominal é regida puramente pela parte determinística do modelo não linear, ou seja, $\dot{\hat{\mathbf{x}}}(t) = \mathbf{f}(\hat{\mathbf{x}}(t), \mathbf{u}(t), t)$, e que $\dot{\mathbf{x}}(t) = \dot{\hat{\mathbf{x}}}(t) + \Delta \dot{\mathbf{x}}(t)$, os termos não lineares se cancelam. A dinâmica assume, portanto, a sua forma linearizada estritamente

em função das variáveis de desvio:

$$\begin{cases} \Delta \dot{\mathbf{x}}(t) \approx \mathbf{F}(t)\Delta \mathbf{x}(t) + \mathbf{w}(t) \\ \Delta \mathbf{y}(t) \approx \mathbf{H}(t)\Delta \mathbf{x}(t) + \mathbf{v}(t) \end{cases} \quad (98)$$

Nesta formulação, as matrizes do sistema são obtidas através do cálculo dos Jacobianos das funções $\mathbf{f}$ e $\mathbf{g}$, avaliados continuamente na estimativa atual $\hat{\mathbf{x}}(t)$. A matriz de dinâmica $\mathbf{F}(t)$ e a matriz de observação $\mathbf{H}(t)$ são definidas como:

$$\mathbf{F}(t) = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}, \mathbf{u}} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \cdots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}, \quad \mathbf{H}(t) = \left. \frac{\partial \mathbf{g}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}, \mathbf{u}} = \begin{bmatrix} \frac{\partial g_1}{\partial x_1} & \cdots & \frac{\partial g_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_p}{\partial x_1} & \cdots & \frac{\partial g_p}{\partial x_n} \end{bmatrix} \quad (99)$$

A representação em espaço de estados linearizada para as variáveis de desvio permite a aplicação direta da solução por fator integrante, conforme desenvolvido no Anexo B. Rigorosamente, por se tratar de um sistema Variante no Tempo (LTV), a solução exigiria a integral de Magnus. Contudo, assumindo-se a premissa de que o Jacobiano $\mathbf{F}(t)$ permanece aproximadamente constante durante um intervalo de amostragem suficientemente pequeno (invariância local), a evolução do erro de estimação entre t_0 e t é dada por:

$$\Delta \mathbf{x}(t) = e^{\mathbf{F}(t)(t-t_0)} \Delta \mathbf{x}(t_0) + \int_{t_0}^t e^{\mathbf{F}(t)(t-\tau)} \mathbf{w}(\tau) d\tau \quad (100)$$

Esta separação conceitual é o cerne do Filtro de Kalman Estendido: enquanto a estimativa do estado $\hat{\mathbf{x}}(t)$ evolui através do modelo não linear original, garantindo a integridade física do sistema, as matrizes de covariância (que representam a incerteza estatística de $\Delta \mathbf{x}$) são propagadas utilizando a solução linearizada (100).