



Universidade Federal
de Campina Grande

SISTEMAS INTELIGENTES

Implementação e Análise do Algoritmo de Sintonia Adaptativa do Filtro de Kalman Aplicado à Localização Robótica

Professor: Dr. Antônio Marcus Nogueira Lima

Aluno: Saulo José Almeida Silva

saulo.jose.silva@ee.ufcg.edu.br

Sumário

1. Introdução e Problema

2. Metodologia de Testes

3. Resultados

1. Análise do modelo EKF de Falek et al. 2020.
2. Análise do Algoritmo de Zhang et al. 2020.
3. Adaptação do Algoritmo para caso EKF

4. Conclusões

1. REFERÊNCIAS

On the Identification of Noise Covariances and Adaptive Kalman Filtering: A New Look at a 50 Year-Old Problem

LINGYI ZHANG¹, DAVID SIDOTI², ADAM BIENKOWSKI¹,
KRISHNA R. PATTIPATI¹, (Life Fellow, IEEE),
YAAKOV BAR-SHALOM¹, (Life Fellow, IEEE),
AND DAVID L. KLEINMAN¹, (Life Fellow, IEEE)

¹Department of Electrical and Computer Engineering, University of Connecticut, Storrs, CT 06269, USA

²U.S. Naval Research Laboratory, Marine Meteorology Division, Monterey, CA 93943, USA

Corresponding author: Lingyi Zhang (lingyi.zhang@uconn.edu)

Computer application for testing Kalman filter

Patrycja Fałek*, Piotr Kaniewski#

Military University of Technology, ul. gen. Sylwestra Kaliskiego 2, 00-908 Warsaw, Poland

Identification of Optimum Filter Steady-State Gain for Systems with Unknown Noise Covariances

BURIAN CAREW, MEMBER, IEEE, AND PIERRE R. BÉLANGER, MEMBER, IEEE

Weak in the NEES?: Auto-tuning Kalman Filters with Bayesian Optimization

Zhaozhong Chen, Christoffer Heckman
Department of Computer Science
University of Colorado Boulder
430 UCB
Boulder, CO 80309
email: Christoffer.Heckman@colorado.edu

Simon Julier
Department of Computer Science
University College London
66–72 Gower Street,
London WC1E 6BT, UK
email: s.julier@ucl.ac.uk

Nisar Ahmed
Smead Aerospace Engineering Sciences
University of Colorado Boulder
429 UCB
Boulder, CO 80309
email: Nisar.Ahmed@colorado.edu


1. INTRODUÇÃO E PROBLEMA

Computer application for testing Kalman filter

Patrycja Falek*, Piotr Kaniewski#

Military University of Technology, ul. gen. Sylwestra Kaliskiego 2, 00-908 Warsaw, Poland

- 1) **Restrição de Movimento:** O objeto desloca-se exclusivamente no plano bidimensional OXY , não sendo modelada a componente de altitude ou posição vertical.
- 2) **Discretização Temporal:** Assume-se que os dados de medição são amostrados a uma taxa constante, com intervalo de amostragem T_s segundos.
- 3) **Geometria de Referência:** As grandezas medidas correspondem às distâncias euclidianas d_i entre o objeto (em coordenadas (x, y)) e bases estacionárias (âncoras) localizadas em coordenadas conhecidas (X_i, Y_i) .




1. INTRODUÇÃO E PROBLEMA

Computer application for testing Kalman filter

Patrycja Falek*, Piotr Kaniewski#

Military University of Technology, ul. gen. Sylwestra Kaliskiego 2, 00-908 Warsaw, Poland

- 4) **Capacidade de Sensoriamento:** O sistema comporta o processamento de medições provenientes de até quatro bases simultaneamente.
- 5) **Modelagem de Incerteza:** Os erros associados ao processo de medição são modelados como processos estocásticos gaussianos.
- 6) **Dinâmica do Sistema:** Para a estimativa via Filtro de Kalman, a cinemática do objeto pode ser descrita pelos modelos de movimento de Posição-Velocidade (PV) ou Posição-Velocidade-Aceleração (PVA).



1. INTRODUÇÃO E PROBLEMA

1 – Modelar os Sistemas (Espaço de Estados)

Modelo Não-Linear

$$\begin{cases} \mathbf{x}_k = \mathbf{F} \mathbf{x}_{k-1} + \mathbf{w}_{k-1} \\ \mathbf{z}_k = \mathbf{h}(\mathbf{x}_k) + \mathbf{v}_k \end{cases}$$

Ruído do Modelo

Ruído da Medição


Modelo Linear

$$\begin{cases} \dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t) + \mathbf{B}\mathbf{u}(t) + \mathbf{w}(t) \\ \mathbf{y}(t) = \mathbf{C}\mathbf{x}(t) + \mathbf{D}\mathbf{u}(t) + \mathbf{v}(t) \end{cases}$$

Ruídos Gaussianos

$$\begin{aligned} (\mathbf{w}(t) &\sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_c)) \\ (\mathbf{v}(t) &\sim \mathcal{N}(\mathbf{0}, \mathbf{R}_c)) \end{aligned}$$

Diagrama



Equações do Processo iterativo

$$\begin{cases} \hat{\mathbf{x}}_{k|k-1} = \mathbf{f}(\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{u}_{k-1}) \\ \mathbf{P}_{k|k-1} = \mathbf{F}_{k-1} \mathbf{P}_{k-1|k-1} \mathbf{F}_{k-1}^T + \mathbf{Q} \\ \mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R})^{-1} \\ \hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k [\mathbf{y}_k - \mathbf{h}(\hat{\mathbf{x}}_{k|k-1})] \\ \mathbf{P}_{k|k} = (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} \end{cases}$$

$$\mathbf{H}_k = \left. \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k|k-1}}$$

$$\mathbf{F}_k = \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k|k-1}}$$

1. INTRODUÇÃO E PROBLEMA

Computer application for testing Kalman filter

Patrycja Falek*, Piotr Kaniewski#

Military University of Technology, ul. gen. Sylwestra Kaliskiego 2, 00-908 Warsaw, Poland

Modelo não-linear

$$\mathbf{x}_k = \mathbf{F} \mathbf{x}_{k-1} + \mathbf{w}_{k-1}$$

$$\mathbf{z}(k) = \underbrace{\begin{bmatrix} \sqrt{(X_1 - x(k))^2 + (Y_1 - y(k))^2} \\ \sqrt{(X_2 - x(k))^2 + (Y_2 - y(k))^2} \\ \sqrt{(X_3 - x(k))^2 + (Y_3 - y(k))^2} \\ \sqrt{(X_4 - x(k))^2 + (Y_4 - y(k))^2} \end{bmatrix}}_{\mathbf{h}(\mathbf{x}(k))} + \underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}(k)}$$

Jacobianas

$$\mathbf{H}(k) = \begin{bmatrix} \frac{\partial d_1}{\partial x} & \frac{\partial d_1}{\partial y} & 0 & 0 & 0 & 0 \\ \frac{\partial d_2}{\partial x} & \frac{\partial d_2}{\partial y} & 0 & 0 & 0 & 0 \\ \frac{\partial d_3}{\partial x} & \frac{\partial d_3}{\partial y} & 0 & 0 & 0 & 0 \\ \frac{\partial d_4}{\partial x} & \frac{\partial d_4}{\partial y} & 0 & 0 & 0 & 0 \end{bmatrix} \quad \begin{aligned} \frac{\partial d_i}{\partial x} &= \frac{-(X_i - x)}{\sqrt{(X_i - x)^2 + (Y_i - y)^2}} \\ \frac{\partial d_i}{\partial y} &= \frac{-(Y_i - y)}{\sqrt{(X_i - x)^2 + (Y_i - y)^2}} \end{aligned}$$

$$d_i = \sqrt{(X_i - x)^2 + (Y_i - y)^2} + v_i$$

Modelos de Estado

PVA: $\mathbf{x}(k) = [x \quad y \quad v_x \quad v_y \quad a_x \quad a_y]^T$

PV: $\mathbf{x}(k) = [x \quad y \quad v_x \quad v_y]^T$

1. INTRODUÇÃO E PROBLEMA

Computer application for testing Kalman filter

Patrycja Falek*, Piotr Kaniewski#

Military University of Technology, ul. gen. Sylwestra Kaliskiego 2, 00-908 Warsaw, Poland

Modelo não-linear


$$\mathbf{x}_k = \mathbf{F} \mathbf{x}_{k-1} + \mathbf{w}_{k-1}$$

$$\mathbf{z}(k) = \underbrace{\begin{bmatrix} \sqrt{(X_1 - x(k))^2 + (Y_1 - y(k))^2} \\ \sqrt{(X_2 - x(k))^2 + (Y_2 - y(k))^2} \\ \sqrt{(X_3 - x(k))^2 + (Y_3 - y(k))^2} \\ \sqrt{(X_4 - x(k))^2 + (Y_4 - y(k))^2} \end{bmatrix}}_{\mathbf{h}(\mathbf{x}(k))} + \underbrace{\begin{bmatrix} v_1 \\ v_2 \\ v_3 \\ v_4 \end{bmatrix}}_{\mathbf{v}(k)}$$

Modelos de Estado

PVA: $\mathbf{x}(k) = [x \ y \ v_x \ v_y \ a_x \ a_y]^T$

PV: $\mathbf{x}(k) = [x \ y \ v_x \ v_y]^T$




1. INTRODUÇÃO E PROBLEMA

Computer application for testing Kalman filter

Patrycja Falek*, Piotr Kaniewski#

Military University of Technology, ul. gen. Sylwestra Kaliskiego 2, 00-908 Warsaw, Poland

**COMO MENSURAR
CORRETAMENTE AS
PROPRIEDADES ESTATÍSTICAS
DOS RUÍDOS (Q e R)?**



1. INTRODUÇÃO E PROBLEMA

On the Identification of Noise Covariances and Adaptive Kalman Filtering: A New Look at a 50 Year-Old Problem

LINGYI ZHANG¹, DAVID SIDOTI², ADAM BIENKOWSKI¹,
KRISHNA R. PATTIPATI¹, (Life Fellow, IEEE),
YAAKOV BAR-SHALOM¹, (Life Fellow, IEEE),
AND DAVID L. KLEINMAN¹, (Life Fellow, IEEE)

¹Department of Electrical and Computer Engineering, University of Connecticut, Storrs, CT 06269, USA

²U.S. Naval Research Laboratory, Marine Meteorology Division, Monterey, CA 93943, USA

Corresponding author: Lingyi Zhang (lingyi.zhang@uconn.edu)

1) INOVAÇÕES

- Condições Necessárias e Suficientes para a Identificabilidade de um Sistema;
- Algoritmo de 6 passos para Identificação das Matrizes de Covariância desconhecidas;

2) ESTRATÉGIAS

- Análise das covariâncias resíduos inovações e pós-processamento;
- Função Objetiva Nova;
- Estimação do Peso ótimo com gradiente descendente Adaptativo

3) RESTRIÇÕES

- Apenas para **Sistemas Lineares Invariantes no Tempo** com modelo dinâmico de Gauss-Markov;

$$\begin{cases} \mathbf{x}_k &= \mathbf{F} \mathbf{x}_{k-1} + \mathbf{\Gamma} \mathbf{w}_{k-1} \\ \mathbf{z}_k &= \mathbf{H} \mathbf{x}_k + \mathbf{v}_k \end{cases}$$

1. INTRODUÇÃO E PROBLEMA


On the Identification of Noise Covariances and Adaptive Kalman Filtering: A New Look at a 50 Year-Old Problem

LINGYI ZHANG¹, DAVID SIDOTI², ADAM BIENKOWSKI¹,
KRISHNA R. PATTIPATI¹, (Life Fellow, IEEE),
YAAKOV BAR-SHALOM¹, (Life Fellow, IEEE),
AND DAVID L. KLEINMAN¹, (Life Fellow, IEEE)

¹Department of Electrical and Computer Engineering, University of Connecticut, Storrs, CT 06269, USA

²U.S. Naval Research Laboratory, Marine Meteorology Division, Monterey, CA 93943, USA

Corresponding author: Lingyi Zhang (lingyi.zhang@uconn.edu)



1. INTRODUÇÃO E PROBLEMA

On the Identification of Noise Covariances and Adaptive Kalman Filtering: A New Look at a 50 Year-Old Problem

LINGYI ZHANG¹, DAVID SIDOTI², ADAM BIENKOWSKI¹,
KRISHNA R. PATTIPATI¹, (Life Fellow, IEEE),
YAAKOV BAR-SHALOM¹, (Life Fellow, IEEE),
AND DAVID L. KLEINMAN¹, (Life Fellow, IEEE)

¹Department of Electrical and Computer Engineering, University of Connecticut, Storrs, CT 06269, USA

²U.S. Naval Research Laboratory, Marine Meteorology Division, Monterey, CA 93943, USA

Corresponding author: Lingyi Zhang (lingyi.zhang@uconn.edu)

Passo 1: Sequencia de ajuste e pós-ajuste :

$$\begin{cases} \hat{\mathbf{x}}(k+1|k) = \mathbf{F} \hat{\mathbf{x}}(k|k) \\ \boldsymbol{\nu}(k+1) = \mathbf{z}(k+1) - \mathbf{H} \hat{\mathbf{x}}(k+1|k) \\ \hat{\mathbf{x}}(k+1|k+1) = \hat{\mathbf{x}}(k+1|k) + \mathbf{W} \boldsymbol{\nu}(k+1) \\ \boldsymbol{\mu}(k+1) = \mathbf{z}(k+1) - \mathbf{H} \hat{\mathbf{x}}(k+1|k+1) \end{cases}$$

Passo 2: Cálculo das Covariâncias de Inovação e pós-ajuste

$$\hat{\mathbf{C}}(i) = \frac{1}{N-M} \sum_{j=1}^{N-M} \boldsymbol{\nu}(j) \boldsymbol{\nu}(j+i)^{\top}$$

Passo 3: Estimação do Ganho W

Função Objetivo:

$$J = \frac{1}{2} \text{tr} \left\{ \sum_{i=1}^{M-1} \boldsymbol{\Theta}(i) \mathbf{X} \mathbf{E}^2 \mathbf{X}^{\top} \right\} \quad J(\mathbf{W}) = \frac{1}{2} \text{tr} \left\{ \sum_{i=1}^{M-1} \mathbf{E} \hat{\mathbf{C}}(i)^{\top} \mathbf{E}^2 \hat{\mathbf{C}}(i) \mathbf{E} \right\}$$

$$\nabla_{\mathbf{W}} J = \sum_{i=1}^{M-1} \boldsymbol{\Phi}(i)^{\top} \mathbf{E}^2 \hat{\mathbf{C}}(i) \mathbf{E}^2 \hat{\mathbf{C}}(0) + \mathbf{F}^{\top} \mathbf{Z} \mathbf{F} \mathbf{X} - \sum_{i=1}^{M-1} \sum_{\ell=0}^{i-2} \left[\hat{\mathbf{C}}(\ell+1) \mathbf{E}^2 \hat{\mathbf{C}}(i)^{\top} \mathbf{E}^2 \mathbf{H} \bar{\mathbf{F}}^{i-\ell-2} \right]^{\top}$$

Gradiente Descendente de passo Adaptativo

$$\mathbf{W}^{(r+1)} = \mathbf{W}^{(r)} - \alpha^{(r)} \nabla_{\mathbf{W}} J(\mathbf{W}^{(r)})$$

$$\alpha^{(r)} = \begin{cases} 0.5 \alpha^{(r-1)}, & \text{se } J^{(r)} > J^{(r-1)} \\ \max(1.1 \alpha^{(r-1)}, \bar{c}), & \text{caso contrário} \end{cases}$$

1. INTRODUÇÃO E PROBLEMA

On the Identification of Noise Covariances and Adaptive Kalman Filtering: A New Look at a 50 Year-Old Problem

LINGYI ZHANG¹, DAVID SIDOTI², ADAM BIENKOWSKI¹,
KRISHNA R. PATTIPATI¹, (Life Fellow, IEEE),
YAAKOV BAR-SHALOM¹, (Life Fellow, IEEE),
AND DAVID L. KLEINMAN¹, (Life Fellow, IEEE)

¹Department of Electrical and Computer Engineering, University of Connecticut, Storrs, CT 06269, USA

²U.S. Naval Research Laboratory, Marine Meteorology Division, Monterey, CA 93943, USA

Corresponding author: Lingyi Zhang (lingyi.zhang@uconn.edu)

Passo 4: Estimação de R

$$S = \frac{1}{N} \sum_{k=1}^N \nu(k) \nu(k)^\top$$

$$G = \frac{1}{N} \sum_{k=1}^N \mu(k) \mu(k)^\top$$

$$R = (I_{n_z} - HW)S$$

$$R = \frac{1}{2} (\mathbb{E}[\mu \nu^\top] + \mathbb{E}[\nu \mu^\top])$$

$$G = RS^{-1}R$$

$$R = \frac{1}{2} (G + S - HWSW^\top H^\top)$$

$$R = \frac{1}{2} (G(I - W^\top H^\top)^{-1} + (I - HW)^{-1}G)$$

Passo 5: Estimação de Q e P:

$$\Gamma Q \Gamma^\top \approx W S W^\top$$

$$P = \bar{F}^\top P \bar{F} + W R W^\top + (I - W H) \Gamma Q \Gamma^\top (I - W H)^\top$$

$$P = \left[(F P F^\top + \Gamma Q \Gamma^\top)^{-1} + H^\top R^{-1} H \right]^{-1}$$

$$Q = \Gamma^\dagger D (\Gamma^\dagger)^\top$$

Passo 6: Condições de Parada

$$|J_{\text{best}}^{(r)} - J_{\text{best}}^{(r-1)}| < \zeta_J,$$

$$\frac{\|W^{(r)} - W^{(r-1)}\|_F}{\|W^{(r-1)}\|_F} < \zeta_W$$

$$\frac{\|Q^{(r)} - Q^{(r-1)}\|_F}{\|Q^{(r-1)}\|_F} < \zeta_Q$$

$$\frac{\|R^{(r)} - R^{(r-1)}\|_F}{\|R^{(r-1)}\|_F} < \zeta_R$$

1. INTRODUÇÃO E PROBLEMA

OBJETIVO DO ESTUDO

- ✓ Estudar dos Artigos de Zhang et al. (2020) e Falek (2020);
- ✓ Desenvolver os Algoritmos em Python;
- ✓ Pensar numa **Adaptação para o Algoritmo** de Identificação das covariâncias desconhecidas para um Caso EKF;
- ✓ Aplicar esse algoritmo Adaptado na situação descrita por Falek e analisar os resultados;

1. INTRODUÇÃO E PROBLEMA

OBJETIVO DO ESTUDO

- **Adaptação:**

1) Aproximar o Gradiente por uma diferença Finita;

$$[\nabla_{\mathbf{W}} J]_{i,j} \approx \frac{J(\mathbf{W} + \epsilon \mathbf{E}_{i,j}) - J(\mathbf{W} - \epsilon \mathbf{E}_{i,j})}{2\epsilon}$$

2) Utilizar os valores Médios dos Jacobianos no Processo para simular um sistema Linear

$$\hat{\mathbf{F}} = \frac{1}{N} \sum_{k=1}^N \left. \frac{\partial \mathbf{f}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_k}, \quad \hat{\mathbf{H}} = \frac{1}{N} \sum_{k=1}^N \left. \frac{\partial \mathbf{h}}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_k}$$

2. METODOLOGIA DE TESTES

Modelos Avaliados

- Utilizou-se como Base o Modelo PVA (Position-Velocity-Aceleration)
- Avaliou um Filtro de Kalman Estendido em três trajetórias (Quadrada Circular e Curva)

Avaliação do Algoritmo de Zhang

1. Avaliar 3 testes diferentes e considerar o NIS (Normalized Inovation Squared) para cada caso

Tabela II MATRIZES DO SISTEMA E COVARIÂNCIAS VERDADEIRAS DE RUÍDO UTILIZADAS NOS EXEMPLOS						
Exemplo	F		H		R	R _{true}
Neethling [5]	$\begin{bmatrix} 0.8 & 1.0 \\ -0.4 & 0.0 \end{bmatrix}$		$\begin{bmatrix} 1.0 & 0.0 \end{bmatrix}$		$\begin{bmatrix} 1.0 \\ 1.0 \end{bmatrix}$	$\begin{bmatrix} 0.5 \\ 1.0 \end{bmatrix}$
Odelson [6]	$\begin{bmatrix} 0.9 & 0.0 & 0.0 \\ 1.0 & 0.9 & 0.0 \\ 0.0 & 0.0 & 0.9 \end{bmatrix}$		$\begin{bmatrix} 0.0 & 1.0 & 0.0 \\ 0.0 & 0.0 & 1.0 \end{bmatrix}$		$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$	$\begin{bmatrix} 0.1 & 0 & 0 \\ 0 & 0.2 & 0 \\ 0 & 0 & 0.1 \end{bmatrix}$
Mehra [7]	$\begin{bmatrix} 0.75 & -1.74 & -0.3 & 0.0 & -0.15 \\ 0.09 & 0.91 & -0.0015 & 0.0 & -0.008 \\ 0.0 & 0.0 & 0.95 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.55 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.905 \end{bmatrix}$		$\begin{bmatrix} 1.0 & 0.0 & 0.0 & 0.0 & 1.0 \\ 0.0 & 1.0 & 0.0 & 1.0 & 0.0 \end{bmatrix}$		$\begin{bmatrix} 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 \\ 24.64 & 0.0 & 0.0 \\ 0.0 & 0.835 & 0.0 \\ 0.0 & 0.0 & 1.83 \end{bmatrix}$	$\begin{bmatrix} 0.1 & 0 & 0 \\ 0 & 0.2 & 0 \\ 0 & 0 & 0.1 \end{bmatrix}$

Fonte: Elaborado pelo autor (2026).

Tabela III
COORDENADAS DAS ANTENAS (ESTAÇÕES BASE)

Estação Base	Coordenadas (X, Y) [m]
Antena 1 (S_1)	(0, 0)
Antena 2 (S_2)	(600, 600)
Antena 3 (S_3)	(0, 600)
Antena 4 (S_4)	(600, 0)

Fonte: Elaborado pelo autor (2026).

Tabela IV
PARÂMETROS GEOMÉTRICOS DAS TRAJETÓRIAS SIMULADAS

Parâmetro	Valor
Trajетória Quadrada	
Origem (X_0, Y_0)	(100, 100) m
Aresta do Quadrado	400 m
Velocidade Linear (v)	50 m/s
Trajетória Circular	
Origem Ref. (X_0, Y_0)	(100, 100) m
Caixa Delimitadora	400 m
Velocidade Linear (v)	50 m/s
Trajетória Curvilínea (tanh)	
Ponto Inicial (X_i, Y_i)	(100, 100) m
Ponto Final (X_f, Y_f)	(500, 500) m
Amplitude no eixo Y	200 m
Fator de Suavidade (s)	6, 0
Duração Total (D)	100 s

Fonte: Elaborado pelo autor (2026).

2. METODOLOGIA DE TESTES

Modelos Avaliados

- Utilizou-se como Base o Modelo PVA (Position-Velocity-Aceleration)
- Avaliou um Filtro de Kalman Estendido em três trajetórias (Quadrada Circular e Curva)

Avaliação do Algoritmo de Zhang

1. Avaliar 3 testes diferentes e considerar o NIS (Normalized Innovation Squared) para cada caso

$$\boldsymbol{\nu}_k = \mathbf{z}_k - \mathbf{H}\hat{\mathbf{x}}_{k|k-1}$$

$$\epsilon_k = \boldsymbol{\nu}_k^\top \mathbf{S}_k^{-1} \boldsymbol{\nu}_k$$

Sob a hipótese de que o filtro está corretamente sintonizado e os ruídos são gaussianos, a variável ϵ_k segue uma distribuição Qui-quadrado (χ^2) com n_z graus de liberdade, onde n_z é a dimensão do vetor de medição.

Para uma análise de desempenho global, utiliza-se a média do NIS ao longo de um horizonte de N amostras. O valor esperado da média deve aproximar-se do número de medições:

$$E[\bar{\epsilon}] = E\left[\frac{1}{N} \sum_{k=1}^N \epsilon_k\right] = n_z \quad (80)$$

- **Consistente:** Se $\bar{\epsilon} \approx n_z$, o filtro é considerado estatisticamente consistente.
- **Otimista:** Se $\bar{\epsilon} > n_z$, as inovações são maiores do que a incerteza prevista por $\mathbf{S}_k$, indicando que o filtro subestima os erros reais.
- **Conservador:** Se $\bar{\epsilon} < n_z$, as inovações são menores do que o previsto, sugerindo que as matrizes de ruído fornecidas são excessivamente altas.




2. METODOLOGIA DE TESTES

Avaliação do Algoritmo Adaptado

- Avaliar se há convergência com a estratégia citada;
- Analisar Viabilidade Computacional



3. RESULTADOS

Modelos Simulados de Trajetória



3. RESULTADOS

Modelos Simulados de Trajetória



3. RESULTADOS

Modelos Simulados de Trajetória




Tabela IX
ANÁLISE ESTATÍSTICA DOS ERROS DE ESTIMAÇÃO

Traj.	Var.	Bias X (μ_x)	Bias Y (μ_Y)	RMS	DP (σ)
Quadrada	P (m)	-0,021	-0,032	0,717	0,716
	V (m/s)	0,006	0,037	2,328	2,328
	A (m/s ²)	0,012	-0,373	1,692	1,650
Circular	P (m)	-0,021	-0,032	0,717	0,716
	V (m/s)	0,006	0,037	2,328	2,328
	A (m/s ²)	0,012	-0,373	1,692	1,650
Curva S	P (m)	-0,001	0,018	0,655	0,655
	V (m/s)	0,006	0,002	1,002	1,002
	A (m/s ²)	-0,037	0,001	0,556	0,555

Nota: P: Posição; V: Velocidade; A: Aceleração.

3. RESULTADOS

Avaliação do Algoritmo Adaptado – Caso Neethling



Exemplo	F	H	Γ	Q _{true}	R _{true}
Neethling [5]	$\begin{bmatrix} 0.8 & 1.0 \\ -0.4 & 0.0 \end{bmatrix}$	$\begin{bmatrix} 1.0 & 0.0 \end{bmatrix}$	$\begin{bmatrix} 1.0 \\ 1.0 \end{bmatrix}$	$\begin{bmatrix} 0.5 \end{bmatrix}$	$\begin{bmatrix} 1.0 \end{bmatrix}$

Parâmetro / Matriz	Valor Verdadeiro	Valor Estimado
Amostras (<i>N</i>)	10.000	
Custo Mínimo <i>J(W)</i>	—	0,006197
Posto de <i>I</i>	2 (Identificável)	
Q (Processo)	$\begin{bmatrix} 0, 500 \end{bmatrix}$	$\begin{bmatrix} 0, 635 \end{bmatrix}$
R (Medição)	$\begin{bmatrix} 1, 000 \end{bmatrix}$	$\begin{bmatrix} 0, 967 \end{bmatrix}$
W (Ganho)	$\begin{bmatrix} 0, 620 \\ 0, 100 \end{bmatrix}$	$\begin{bmatrix} 0, 638 \\ 0, 197 \end{bmatrix}$
S (Inovação)	$\begin{bmatrix} 2, 629 \end{bmatrix}$	$\begin{bmatrix} 2, 655 \end{bmatrix}$

Fonte: Elaborado pelo autor (2026).

3. RESULTADOS

Avaliação do Algoritmo Adaptado – Caso Neethling



3. RESULTADOS

Avaliação do Algoritmo Adaptado – Caso Mehra

Mehra [7]	$\begin{bmatrix} 0.75 & -1.74 & -0.3 & 0.0 & -0.15 \\ 0.09 & 0.91 & -0.0015 & 0.0 & -0.008 \\ 0.0 & 0.0 & 0.95 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.55 & 0.0 \\ 0.0 & 0.0 & 0.0 & 0.0 & 0.905 \end{bmatrix}$	$\begin{bmatrix} 1.0 & 0.0 & 0.0 & 0.0 & 1.0 \\ 0.0 & 1.0 & 0.0 & 1.0 & 0.0 \end{bmatrix}$	$\begin{bmatrix} 0.0 & 0.0 & 0.0 \\ 0.0 & 0.0 & 0.0 \\ 24.64 & 0.0 & 0.0 \\ 0.0 & 0.835 & 0.0 \\ 0.0 & 0.0 & 1.83 \end{bmatrix}$	$\begin{bmatrix} 0.1 & 0 & 0 \\ 0 & 0.2 & 0 \\ 0 & 0 & 0.1 \end{bmatrix}$	$\begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}$
-----------	--	--	--	---	--

Fonte: Elaborado pelo autor (2026).



Tabela VIII
RESULTADOS DA ESTIMAÇÃO ADAPTATIVA: CASO MEHRA [7]

Parâmetro / Matriz	Valor Verdadeiro	Valor Estimado
Amostras (<i>N</i>)	—	100.000
Custo Mínimo <i>J(W)</i>	—	0,011406
Posto de <i>I</i>	—	9 (Identificável)
Q (Processo)	$\begin{bmatrix} 0.1 & 0 & 0 \\ 0 & 0.2 & 0 \\ 0 & 0 & 0.1 \end{bmatrix}$	$\begin{bmatrix} 0.127 & -0.027 & 0.023 \\ -0.027 & 0.188 & -0.231 \\ 0.023 & -0.231 & 0.284 \end{bmatrix}$
R (Medição)	$\begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}$	$\begin{bmatrix} 0.584 & 0.169 \\ 0.169 & 0.474 \end{bmatrix}$
W (Ganho)	$\begin{bmatrix} 0.906 & 0.362 \\ 0.004 & 0.214 \\ -2.564 & -0.951 \\ 0.000 & 0.177 \\ 0.030 & -0.357 \end{bmatrix}$	$\begin{bmatrix} 0.905 & 0.728 \\ -0.007 & 0.237 \\ -2.854 & -1.510 \\ -0.005 & 0.223 \\ 0.020 & -0.886 \end{bmatrix}$
S (Inovação)	$\begin{bmatrix} 7.978 & 0.062 \\ 0.062 & 0.822 \end{bmatrix}$	$\begin{bmatrix} 8.033 & 0.048 \\ 0.048 & 0.848 \end{bmatrix}$

Fonte: Elaborado pelo autor (2026).

3. RESULTADOS

Avaliação do Algoritmo Adaptado – Caso Mehra



3. RESULTADOS

Análise do Algoritmo Adaptado para as situações das Trajetórias

[Exibição por Código]

4. CONCLUSÕES

- ❑ O algoritmo desenvolvido por Zhang et al. (2020) funciona corretamente, como ele já o demonstrou;
- ❑ A Adaptação que utilizei não funciona, pois há o acúmulo de erros ao tomar o valor médio em trajetórias complexas;
- ❑ A Adaptação com Gradiente por diferenças finitas teve resultados satisfatórios;
- ❑ É necessário mais estudo no assunto para garantir uma resposta definitiva para os casos não-lineares, contudo, já existem soluções utilizando otimizações Bayesianas;

Weak in the NEES?: Auto-tuning Kalman Filters with Bayesian Optimization

Zhaozhong Chen, Christoffer Heckman
Department of Computer Science
University of Colorado Boulder
430 UCB
Boulder, CO 80309
email: Christoffer.Heckman@colorado.edu

Simon Julier
Department of Computer Science
University College London
66-72 Gower Street,
London WC1E 6BT, UK
email: s.julier@ucl.ac.uk

Nisar Ahmed
Smead Aerospace Engineering Sciences
University of Colorado Boulder
429 UCB
Boulder, CO 80309
email: Nisar.Ahmed@colorado.edu

REFERÊNCIAS

1. BAR-SHALOM, Y.; LI, X. R.; KIRUBARAJAN, T. Estimation with applications to tracking and navigation. New York: John Wiley & Sons, 2001.
2. CAREW, B.; BÉLANGER, P. R. Identification of optimum filter steady-state gain for systems with unknown noise covariances. IEEE Transactions on Automatic Control, v. 18, n. 6, p. 582-592, dez. 1973.
3. CHEN, Z.; HECKMAN, C.; JULIER, S. Weak in the NEES?: Auto-tuning Kalman filters with Bayesian optimization. In: INTERNATIONAL CONFERENCE ON INFORMATION FUSION (FUSION), 21., 2018. Proceedings... [S. l.]: IEEE, 2018.
4. CHEN, Z. et al. Kalman filter auto-tuning through enforcing chi-squared normalized error distributions with Bayesian optimization. arXiv preprint arXiv:2306.07225, 2023.
5. FAŁEK, P.; KANIEWSKI, P. Computer application for testing Kalman filter. Journal of Automation, Mobile Robotics & Intelligent Systems, v. 14, n. 2, p. 3-10, 2020.
6. KALMAN, R. E. A new approach to linear filtering and prediction problems. Journal of Basic Engineering, v. 82, n. 1, p. 35-45, 1960.
7. MEHRA, R. K. On the identification of variance and adaptive Kalman filtering. IEEE Transactions on Automatic Control, v. 15, n. 2, p. 175-184, abr. 1970.
8. NEETHLING, C.; WILLEMS, J. L. The use of the innovations sequence to determine the state covariance matrix of a linear time-invariant system. Automatica, v. 10, n. 3, p. 337-341, 1974.
9. ODELSO, B. J.; RAJAMANI, M. R.; RAWLINGS, J. B. A new pose for adaptive Kalman filtering: the monitoring and estimation of control performance. Control Engineering Practice, v. 14, n. 3, p. 303-314, 2006.
10. SILVA, S. J. A. Atividades da Disciplina Sistemas Inteligentes - UFCG 2026. GitHub: 2026. Disponível em: <https://github.com/SauloJose/SistemasInteligentes2026>.
11. THRUN, S.; BURGARD, W.; FOX, D. Probabilistic robotics. Cambridge, MA: MIT Press, 2005.
12. ZHANG, L. et al. On the identification of noise covariances and adaptive Kalman filtering: a new look at a 50-year-old problem. IEEE Access, v. 8, p. 59362-59388, 2020. DOI: 10.1109/ACCESS.2020.2982407.



Universidade Federal
de Campina Grande

Obrigado!

Saulo José Almeida Silva.
saulo.jose.silva@ee.ufcg.edu.br