



Universidade Federal
de Campina Grande

SISTEMAS INTELIGENTES

Detecção de Falhas em processo industriais: Análise Comparativa de Abordagens baseadas em SVD e Redes Autoencodificadas

Professor: Dr. Antônio Marcus Nogueira Lima

Aluno: Saulo José Almeida Silva

saulo.jose.silva@ee.ufcg.edu.br

Sumário

1. Introdução e Problemática

- Definição de falhas
- Processo de Tennessee Eastman

2. Metodologia de Testes

- Métodos utilizados
- Estatísticas Utilizadas
- Processo de treino e teste
- Coeficientes para Análise

3. Resultados

- FDRs e FDAs


4. Conclusões

- Refinamento
- Trabalhos futuros

1. INTRODUÇÃO E PROBLEMÁTICA

DEFINIÇÃO DE FALHAS


Uma falha em um processo é o **desvio, interrupção ou mau funcionamento** de uma etapa planejada, que resulta em um desempenho abaixo do esperado ou impede que o objetivo final seja atingido. Em essência, é quando o processo falha em entregar o resultado previsto, a qualidade exigida ou o serviço no tempo certo.







1. INTRODUÇÃO E PROBLEMÁTICA

DEFINIÇÃO DO PROCESSO

Diagrama P&D: Tennessee Eastman Process (TEP)



Processo Realizado:



Tópicos importantes:

- 41 variáveis instrumentadas (XMEAS)
 - 22 variáveis contínuas
 - 19 analisadores químicos
- 12 Variáveis manipuladas (XMV);
- 21 Falhas de Processo catalogadas (IDV)

Base de Dados:

- **Condições normais de operação:** Arquivos d00.dat e d00_te.dat

1. INTRODUÇÃO E PROBLEMÁTICA

DEFINIÇÃO DO PROCESSO

As **Falhas de Processo** são produzidas e utilizadas no benchmark, sendo elas do tipo Degrau, Variação Aleatória, Deriva lenta, travamento e de origem desconhecida.

Base de Dados:

➤ **Treino e teste das falhas da falha {i}:**

Arquivos $d\{i\}.dat$ e $d\{i\}_{te}.dat$

IDV	Descrição da falha	Tipo
1	Razão A/C na alimentação, composição de B constante	Degrau (Step)
2	Composição de B, razão A/C constante	Degrau
3	Temperatura de alimentação de D	Degrau
4	Temperatura de entrada da água de resfriamento do reator	Degrau
5	Temperatura de entrada da água de resfriamento do condensador	Degrau
6	Perda de alimentação de A	Degrau
7	Perda de pressão no header de C – disponibilidade reduzida	Degrau
8	Composição das alimentações A, B e C	Variação aleatória
9	Temperatura de alimentação de D	Variação aleatória
10	Temperatura de alimentação de C	Variação aleatória
11	Temperatura de entrada da água de resfriamento do reator	Variação aleatória
12	Temperatura de entrada da água de resfriamento do condensador	Variação aleatória
13	Cinética da reação	Deriva lenta (slow drift)
14	Válvula de água de resfriamento do reator	Travamento (sticking)
15	Válvula de água de resfriamento do condensador	Travamento
16	Desconhecida	Desconhecida
17	Desconhecida	Desconhecida
18	Desconhecida	Desconhecida
19	Desconhecida	Desconhecida
20	Desconhecida	Desconhecida
21	Válvula fixa na posição de regime permanente	Posição constante

1. INTRODUÇÃO E PROBLEMÁTICA

OBJETIVO DO ESTUDO

- ✓ Realizar um estudo comparativo entre técnicas de previsão de falhas;
- ✓ Verificar qual é a melhor técnica e a melhor aplicação da mesma;

2. METODOLOGIA DE TESTES

MÉTODOS UTILIZADOS

Métodos	Aspecto Temporal	Abordagem	Estrutura dos Dados	Variáveis Utilizadas no Processo
PCA, ICA	Estático	Não Supervisionada	Bloco Único (X)	Concentra as 22 medições ($XMEAS_{1-22}$) e 11 manipuladas (XMV_{1-11}) em uma única matriz, sem diferenciação de alvos.
DPCA, MICA	Dinâmico	Não Supervisionada	Bloco Único (X) com <i>Lags</i>	Mesmas 33 variáveis ($XMEAS$ e XMV), porém acrescidas de suas componentes de atraso temporal.
PAE	Estático	Não Supervisionada	Bloco Único (X)	Concentra as 22 medições ($XMEAS_{1-22}$) e 11 manipuladas (XMV_{1-11}) para mapear de forma não-linear a distribuição de normalidade no espaço latente.
FDA	Estático	Supervisionada	Entrada $\rightarrow$ Classes	Utiliza as 33 variáveis de processo como preditoras para discriminar os rótulos (classes discretas) de falha.
PLS, MPLS	Estático	Supervisionada	Entrada $\rightarrow$ Saída	Mapeia a correlação entre as 33 variáveis preditoras (X) e a variável contínua de qualidade $XMEAS_{35}$ (Y).
TPLS	Dinâmico/Estático	Supervisionada	Entrada $\rightarrow$ Saída	Realiza a decomposição ortogonal separando as variações de X que são correlacionadas e ortogonais a $XMEAS_{35}$.

2. METODOLOGIA DE TESTES

MÉTODOS UTILIZADOS

PCA – Análise de Componentes Principais

DPCA – Análise de Componentes Principais Dinâmica

PLS – Mínimos Quadrados Parciais

TPLS – Mínimos Quadrados Parciais com Informação Temporal

MPLS – Mínimos Quadrados Parciais Multivariados

ICA – Análise de Componentes Independentes

MICA – Análise de Componentes Independentes Multivariada

FDA – Análise Discriminante de Fisher

PAE – Autoencoder Probabilístico

2. METODOLOGIA DE TESTES

MÉTODOS UTILIZADOS



2. METODOLOGIA DE TESTES

MÉTODOS UTILIZADOS

		Estratégia de Aprendizado		
		Não-Supervisionado	Supervisionado	Deep Generative
Abordagem Temporal	Estático	PCA Decomposição de variância ortogonal. ICA Separação de fontes independentes.	FDA Maximização de margem entre classes conhecidas. PLS / MPLS Regressão focada em uma variável de qualidade do produto.	PAE Autoencoder Probabilístico mapeando espaço latente não-linear.
	Dinâmico	DPCA & MICA Matrizes expandidas com memória temporal (lags).	TPLS Supervisão orientada combinada com lags temporais.	

2. METODOLOGIA DE TESTES

ESTATÍSTICAS UTILIZADAS

Estatística T^2 de Hotelling

Indicador da variação de uma nova medição dentro do que o modelo espera que aconteça. Ou seja, analisa modificações internas.

$$T_k^2 = \mathbf{t}_k^\top \mathbf{\Lambda}^{-1} \mathbf{t}_k$$

O limite, sob hipótese nula de operação normal é:

$$T_{\text{lim}}^2 = \frac{a(n-1)}{n-a} F_\alpha(a, n-a)$$

SPE - Erro Quadrático de Predição (Estatística Q)

Mede o erro residual, ou seja, aquilo que o modelo não conseguiu explicar ou reconstruir.

$$Q_k = \|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2 = \|\mathbf{x}_k - \mathbf{x}_k \mathbf{P}_a \mathbf{P}_a^\top\|^2$$


Limite do resíduo, dentro do que é esperado por ele.

$$Q_{\text{lim}} = \theta_1 \left[\frac{c_\alpha \sqrt{2\theta_2 h_0^2}}{\theta_1} + 1 + \frac{\theta_2 h_0 (h_0 - 1)}{\theta_1^2} \right]^{1/h_0}$$

onde $\theta_k = \sum_{i=a+1}^p \lambda_i^k$ e $h_0 = 1 - \frac{2\theta_1 \theta_3}{3\theta_2^2}$.

2. METODOLOGIA DE TESTES

ESTATÍSTICAS UTILIZADAS



2. METODOLOGIA DE TESTES

ESTATÍSTICAS UTILIZADAS

Estatística I^2 (Componentes Independentes)

Utilizada no contexto de Análise de Componentes Independentes (ICA). Equivale ao T^2 , mas para processos que não são **gaussianos**.

Mensura a variação no subespaço do modelo.

$$I_k^2 = \mathbf{s}_{k,d}^\top \mathbf{s}_{k,d}$$

Seu limite é dado por uma função quantil empírica obtida a partir dos dados de treinamento.

$$I_{\text{lim}}^2 = f_{\text{KDE}}(\mathbf{I}_{\text{train}}^2, \alpha)$$

Estatística D (índice Combinado)

Utilizada na Classificação supervisionada (FDA). A estatística D é utilizada com o treino de “normal” e “com falha”, classificando se se parece com um processo de falha de acordo com o histórico conhecido.

$$D_k = \frac{T_k^2}{T_{\text{lim}}^2} + \frac{Q_k}{Q_{\text{lim}}}$$

Seu limite é dado por uma distribuição Chi-quadrado

$$D_{\text{lim}} = g \cdot \chi_\alpha^2(h)$$

$$g = \frac{\sigma_D^2}{2\mu_D}, \quad h = \frac{2\mu_D^2}{\sigma_D^2}$$

2. METODOLOGIA DE TESTES

COEFICIENTES DE ANÁLISE

		Valor Predito	
		Sim	Não
Real	Sim	Verdadeiro Positivo (TP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (TN)

2. METODOLOGIA DE TESTES

COEFICIENTES DE ANÁLISE

FDR : Fault Detection Rate –Taxa de Detecção de Falhas

Também conhecida como **sensibilidade**, mede a capacidade do sistema de identificar uma falha quando ela realmente acontece.

$$FDR = \frac{VP}{VP + FN}$$

Verdadeiros Positivos

Falsos Positivos

2. METODOLOGIA DE TESTES

COEFICIENTES DE ANÁLISE


FAR: Fault Detection Rate – Taxa de Detecção de Falhas

Mede a probabilidade de o sistema dar um “alarme falso”, ou seja, acusar uma falha quando o processo está operando de forma **perfeitamente normal**.

$$FAR = \frac{FP}{VN + FP}$$

Falsos Positivos

Verdadeiros Negativos

The diagram shows the formula FAR = FP / (VN + FP). The terms 'FP' and 'VN' are circled in red. A red arrow points from the 'FP' circle to the text 'Falsos Positivos' above and to the right. Another red arrow points from the 'VN' circle to the text 'Verdadeiros Negativos' below and to the left.

2. METODOLOGIA DE TESTES

PROCESSO DE TREINO E TESTE



3. RESULTADOS

FDRs MÉDIOS DOS MODELOS

Método	FDR Média	FAR (%)
PAE	75,50%	17,08%
MPLS	74,94%	10,31%
TPLS	74,91%	10,42%
ICA	72,98%	6,98%
DPCA	72,95%	6,56%
PLS	72,95%	12,19%
PCA	71,34%	5,62%
MICA	64,51%	0,52%
FDA	56,05%	1,15%

PAE:

- ✓ **MAIOR** taxa de previsão (75,5%) (sensibilidade);
- ✓ Gera muitos alarmes falsos;

MPLS:

- ✓ Alta taxa de previsão (~75%)
- ✓ Foca principalmente em proteger a qualidade do produto;

DPCA:

- ✓ Melhor Equilíbrio (FDR: 72,95% e FAR: 65,56%)
- ✓ Permite filtrar ruídos rápidos e passageiros;

MICA:

- ✓ Taxa de previsão considerável (64,5%)
- ✓ **MENOR** chance de gerar alarmes falsos (0,52%)

3. RESULTADOS

FDA MÉDIOS POR FALTA

Falha	PCA	DPCA	PLS	TPLS	MPLS	ICA	MICA	FDA	PAE
IDV(01)	99,90%	99,90%	99,90%	99,90%	99,90%	99,90%	99,80%	98,90%	99,90%
IDV(02)	98,80%	98,90%	98,90%	98,90%	98,80%	98,90%	97,90%	96,90%	98,60%
IDV(03)	12,90%	12,10%	12,10%	17,60%	13,60%	14,90%	3,40%	1,50%	31,10%
IDV(04)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	97,50%	100,00%	98,10%
IDV(05)	33,60%	37,10%	37,10%	37,40%	36,50%	35,90%	26,20%	99,90%	50,50%
IDV(06)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%
IDV(07)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	21,80%	100,00%
IDV(08)	98,00%	98,00%	98,00%	98,40%	98,50%	98,10%	97,10%	57,60%	99,10%
IDV(09)	8,40%	10,10%	10,10%	16,10%	13,50%	10,60%	1,60%	1,20%	27,10%
IDV(10)	60,50%	63,00%	63,00%	77,20%	90,00%	63,10%	41,10%	65,60%	66,80%
IDV(11)	78,90%	84,20%	84,20%	81,90%	81,00%	81,10%	64,20%	65,90%	79,00%
IDV(12)	99,10%	99,10%	99,10%	99,40%	99,50%	99,20%	99,00%	81,90%	99,80%
IDV(13)	95,40%	95,40%	95,40%	95,20%	95,20%	95,40%	94,40%	58,80%	95,80%
IDV(14)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	92,60%	100,00%
IDV(15)	14,10%	16,90%	16,90%	24,60%	21,10%	18,00%	5,50%	1,50%	28,70%
IDV(16)	55,20%	58,00%	58,00%	65,50%	80,40%	58,90%	29,00%	6,90%	64,60%
IDV(17)	95,20%	96,20%	96,20%	95,90%	95,20%	96,00%	90,40%	81,40%	94,90%
IDV(18)	90,50%	90,50%	90,50%	91,60%	90,90%	90,60%	89,60%	85,90%	92,10%
IDV(19)	42,10%	53,90%	53,90%	43,60%	33,90%	51,40%	22,90%	2,00%	30,00%
IDV(20)	63,40%	66,40%	66,40%	68,90%	65,90%	65,50%	49,60%	54,90%	72,40%
IDV(21)	52,10%	52,20%	52,20%	61,10%	59,80%	55,00%	45,50%	1,80%	56,90%
MÉDIA	71,34%	72,95%	72,95%	74,91%	74,94%	72,98%	64,51%	56,05%	75,50%

- Forte Detecção (FDR > 95%)
- Detecção Moderada (50 < FDR < 95%)
- Difícil Detecção (FDR < 50 %)

OBS: Com as piores taxas de detecção.

Falhas IDV(03), IDV(05), IDV(09), IDV(15)

3. RESULTADOS

FDA MÉDIOS

IDV	Descrição da falha	Tipo
1	Razão A/C na alimentação, composição de B constante	Degrau (Step)
2	Composição de B, razão A/C constante	Degrau
3	Temperatura de alimentação de D	Degrau
4	Temperatura de entrada da água de resfriamento do reator	Degrau
5	Temperatura de entrada da água de resfriamento do condensador	Degrau
6	Perda de alimentação de A	Degrau
7	Perda de pressão no header de C – disponibilidade reduzida	Degrau
8	Composição das alimentações A, B e C	Variação aleatória
9	Temperatura de alimentação de D	Variação aleatória
10	Temperatura de alimentação de C	Variação aleatória
11	Temperatura de entrada da água de resfriamento do reator	Variação aleatória
12	Temperatura de entrada da água de resfriamento do condensador	Variação aleatória
13	Cinética da reação	Deriva lenta (slow drift)
14	Válvula de água de resfriamento do reator	Travamento (sticking)
15	Válvula de água de resfriamento do condensador	Travamento
16	Desconhecida	Desconhecida
17	Desconhecida	Desconhecida
18	Desconhecida	Desconhecida
19	Desconhecida	Desconhecida
20	Desconhecida	Desconhecida
21	Válvula fixa na posição de regime permanente	Posição constante

OBS: Com as piores taxas de detecção.

Falhas IDV(03), IDV(05), IDV(09), IDV(15)

4. CONCLUSÕES

Requisito Operacional	Algoritmo Recomendado	FDR Médio	FAR Médio	Principal Trade-off
Infraestrutura Crítica (Zero Alarme Falso)	MICA	64,5%	0,52%	Sacrifica a detecção de derivas sutis para manter a operação ininterrupta.
Monitoramento Geral (Balanced Score)	DPCA	72,9%	6,56%	O melhor custo-benefício computacional. Estável, robusto e interpretável.
Linha de Produção (Foco em Qualidade)	MPLS	74,9%	10,3%	Requer rótulos constantes de saída laboratorial (Y) para calibração contínua.
Segurança de Processo (Capturar Tudo)	PAE (Deep Learning)	75,5%	17,0%	Exige poder computacional pesado e operadores tolerantes à investigação de alarmes.

4. CONCLUSÕES

TRABALHOS FUTUROS

- Métodos híbridos e ensembles
- Abordagens de aprendizado profundo
- Métodos de kernel
- Aprendizado por transferência
- Implementação em tempo real
- Análise de causa raiz

REFERÊNCIAS

- DAYAL, B. S.; MACGREGOR, J. F. Improved PLS algorithms. **Journal of Chemometrics**, v. 11, n. 1, p. 73-85, 1997.
- DOWNS, J. J.; VOGEL, E. F. A plant-wide industrial process control problem. **Computers & Chemical Engineering**, v. 17, n. 3, p. 245–255, 1993.
- FAVOREEL, W.; DE MOOR, B.; VAN OVERSCHEE, P. Subspace state space system identification for industrial processes. **Journal of Process Control**, v. 10, n. 2-3, p. 149-155, 2000.
- GAVISH, M.; DONOHO, D. L. The optimal hard threshold for singular values is $4\sqrt{3}$. **IEEE Transactions on Information Theory**, v. 60, n. 8, p. 5040-5053, 2014.
- GERMANO, A. *et al.* Detecção de falhas no processo Tennessee Eastman utilizando métricas de tipicidade e excentricidade. In: INTERNATIONAL CONFERENCE ON CONTROL, AUTOMATION AND SYSTEMS (ICCAS), 13., 2016. **Proceedings [...]**. [S. l.: s. n.], 2016. p. 1000–1005.

REFERÊNCIAS

- GERON, A. **Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems**. 2. ed. [S. l.]: O'Reilly Media, Inc., 2019.
- GERTLER, J. **Fault detection and diagnosis in engineering systems**. New York: Marcel Dekker, 1998.
- ISERMANN, R. **Fault-diagnosis applications: Model-aided diagnosis and fault-tolerant control**. Berlin, Heidelberg: Springer-Verlag, 2011.
- SILVA, S. J. A. **Atividade 3 - Identificação de Falhas (Sistemas Inteligentes 2026)**. Repositório GitHub, 2026. Disponível em: <https://github.com/SauloJose/SistemasInteligentes2026/tree/main/Atividade%203%20-%20Identifica%C3%A7%C3%A3o%20de%20Falhas>. Acesso em: 18 maio 2026.
- SPINA, D. E. *et al.* Comparison of autoencoder architectures for fault detection in industrial processes. **Digital Chemical Engineering**, v. 12, p. 100162, 2024.
- VENKATASUBRAMANIAN, V. *et al.* A review of process fault detection and diagnosis: Part I. Quantitative model-based methods. **Computers & Chemical Engineering**, v. 27, n. 3, p. 293-311, 2003.
- YIN, S. *et al.* A comparison study of basic data-driven fault diagnosis and process monitoring methods on the benchmark Tennessee Eastman process. **Journal of Process Control**, v. 22, n. 9, p. 1567-1581, 2012.



Universidade Federal
de Campina Grande

Obrigado!

Saulo José Almeida Silva.
saulo.jose.silva@ee.ufcg.edu.br