

Detecção de Falhas em Processos Industriais: Análise Comparativa de Abordagens baseadas em SVD e Redes Autoencodificadoras

Saulo José Almeida Silva, *Mestrando, UFCG*, Antonio Marcus Nogueira Lima, *Professor Titular, UFCG*,

Resumo—A detecção precoce de falhas em processos industriais é crucial para manter a confiabilidade do sistema, a segurança e a eficiência operacional. Este trabalho apresenta um estudo abrangente de algoritmos de detecção de falhas baseados em oito metodologias distintas: métodos estatísticos multivariados (PCA, DPCA), abordagens supervisionadas (PLS, TPLS, MPLS, FDA) e técnicas baseadas em independência estatística (ICA, MICA). O trabalho avalia a eficácia de cada método na detecção de falhas incipientes e abruptas utilizando o benchmark do processo Tennessee Eastman. Os resultados demonstram trade-offs significativos entre a taxa de detecção (sensibilidade) e a taxa de alarmes falsos (especificidade), com o DPCA apresentando o melhor equilíbrio geral (72,6% de FDR, 6,56% de FAR), enquanto o MICA alcança a menor taxa de alarmes falsos (0,52%). A análise comparativa fornece uma base para a seleção de métodos adequados conforme os requisitos específicos da aplicação industrial.

Index Terms—Detecção de Falhas, Análise de Componentes Principais, Processos Industriais, Análise Discriminante, Detecção de Anomalias, Aprendizado de Máquina.

I. INTRODUÇÃO

PROCESSOS industriais operam em condições complexas e frequentemente imprevisíveis, nas quais falhas de equipamentos podem levar a perdas econômicas significativas, riscos à segurança e danos ambientais. A detecção oportuna de falhas incipientes permite a manutenção preventiva, reduz o tempo de parada não planejado e melhora a confiabilidade geral do sistema. Abordagens tradicionais de detecção de falhas baseadas em modelos requerem modelos matemáticos precisos do sistema, os quais frequentemente não estão disponíveis ou são difíceis de obter na prática. Consequentemente, métodos baseados em dados emergiram como alternativas viáveis que exploram dados históricos do processo para aprender padrões normais de operação e identificar desvios.

Este trabalho enfoca o desenvolvimento e a comparação de oito abordagens distintas de detecção de falhas baseadas em dados em processos industriais. A Seção II fornece uma revisão abrangente dos fundamentos teóricos e dos trabalhos relacionados. A Seção III descreve a formulação do problema e os detalhes de implementação. A Seção IV apresenta os resultados experimentais e a análise comparativa. Finalmente, a Seção V resume as conclusões e sugere direções para pesquisas futuras.

S. J. A. Silva é mestrando no Programa de Pós-Graduação em Engenharia Elétrica (PPgEE) da Universidade Federal de Campina Grande (UFCG), Campina Grande, PB, Brasil. E-mail: saulo.jose.silva@ee.ufcg.edu.br.

A. M. N. Lima é Professor Titular do Departamento de Engenharia Elétrica da UFCG. E-mail: amnlma@dee.ufcg.edu.br.

A. Notação e Convenções

Ao longo deste trabalho, adotamos as seguintes convenções de notação: escalares são denotados por letras itálicas (a), vetores por letras minúsculas em negrito ($\mathbf{a}$) e matrizes por letras maiúsculas em negrito ($\mathbf{A}$). O operador de transposição é denotado por $(\cdot)^T$, a norma de Frobenius por $\|\cdot\|_F$ e a norma espectral por $\|\cdot\|_2$. Para sistemas em tempo discreto, o subíndice k denota o instante de tempo, i.e., $\mathbf{x}_k$. A notação $\|\mathbf{x}\|$ representa a norma euclidiana, e $\mathbb{R}^{m \times n}$ denota o conjunto de matrizes reais de dimensão $m \times n$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

As metodologias de detecção de falhas evoluíram significativamente ao longo das últimas décadas. Esta seção revisa os conceitos fundamentais e as técnicas relevantes para os oito métodos investigados neste trabalho.

A. Processos Industriais e Monitoramento Multivariável

Os processos industriais modernos geram quantidades vastas de dados de sensores de múltiplas variáveis operando simultaneamente. Um processo multivariável típico pode ser representado como uma coleção de m variáveis medidas amostradas em instantes discretos de tempo $k = 1, 2, \dots, N$:

$$\mathbf{Y} \in \mathbb{R}^{m \times N} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N] \quad (1)$$

onde cada coluna $\mathbf{y}_k = [y_{1,k}, y_{2,k}, \dots, y_{m,k}]^T$ representa um snapshot do estado do processo no instante k . O monitoramento do processo geralmente se concentra em detectar quando o sistema se desvia das condições normais de operação, o que pode indicar o início de uma falha.

B. O Processo Tennessee Eastman (TE)

O processo Tennessee Eastman (TE) é um simulador realista e complexo de um processo químico amplamente utilizado em pesquisas de detecção de falhas. Ele representa uma planta de polimerização com múltiplas operações unitárias interconectadas, incluindo reatores, separadores e colunas de destilação.

1) *Visão Geral do Processo*: O processo TE compõe-se das seguintes unidades principais:

2) *Variáveis Medidas e Entradas Manipuladas*: O processo TE fornece 41 variáveis continuamente medidas (XMEAS 1–41) e 12 entradas manipuladas (XMV 1–12), permitindo um monitoramento multivariável abrangente:

Tabela I
UNIDADES PRINCIPAIS DO PROCESSO TENNESSEE EASTMAN

Unidade	Função	Descrição
Reator	Vaso de reação primária	Polimerização catalítica das matérias-primas A, D e E
Separador	Separação líquido-vapor	Separa os produtos da alimentação não reagida
Coluna de destilação	Destilação	Remove componentes leves e recupera o produto
Condensador	Troca térmica	Condensa vapores no separador
Laço de reciclo	Circulação de material	Recicla materiais não reagidos para o reator

Tabela II
CATEGORIAS DE VARIÁVEIS MEDIDAS NO PROCESSO TE

Tipo de Variável	Categoria	Quantidade
Vazões	Alimentação do reator, purga, separador, coluna	6
Pressões	Reator, separador, coluna	3
Temperaturas	Reator, separador, coluna, água de resfriamento	7
Níveis de líquido	Reator, separador, coluna	3
Água de resfriamento do reator/condensador	Temperaturas de entrada de água	2
Trabalho do compressor	Consumo de energia	1
Análise de composição	Frações de alimentação e produto (A, B, C, D, E, F, G, H)	11
Sinais adicionais de processo	Temperatura do reator, várias vazões	7

Tabela III
CENÁRIOS DE FALHA DO PROCESSO TE

IDV	Descrição	Tipo	Ocorrência
1–2	Mudanças na composição dos reagentes	Degrau	500 segundos
3–4	Variações na temperatura de alimentação	Degrau	500 segundos
5–7	Alterações na temperatura/pressão do fluido de arrefecimento	Degrau	500 segundos
8–12	Variações aleatórias na composição da alimentação, temperatura	Aleatório	500 segundos
13–15	Deriva lenta na cinética / agarramento de válvula	Deriva/Travamento	500 segundos
16–20	Falhas desconhecidas (cenários ocultos)	Desconhecido	500 segundos
21	Válvula fixa na posição de regime estacionário	Constante	500 segundos

3) *Cenários de Falha*: O benchmark inclui 21 modos de falha (IDV 1–21) que representam diferentes cenários de falha:

Os dados são normalizados para média zero e variância unitária, a fim de garantir que todas as variáveis contribuam igualmente para os algoritmos de detecção.

4) *Descrição Detalhada do Processo e Fluxograma*: O processo Tennessee Eastman representa um sistema de fabricação química em múltiplos estágios. *[Um fluxograma detalhado mostrando as operações unitárias, interconexões, composições das correntes e malhas de controle deve ser inserido aqui. O diagrama deve ilustrar as correntes de alimentação do reator (A, D, E, C), o vaso de reação, os estágios de recuperação do produto e os caminhos de reciclo.]*

O processo opera continuamente sob controle por realimentação, sendo os principais objetivos de controle:

- Manter o nível e a pressão do reator;
- Regular as temperaturas do reator e do separador;
- Estabilizar a composição e a pureza do produto;

- Equilibrar o fluxo de material e as taxas de reciclo.

[As equações da dinâmica do processo e as relações de balanço de material podem ser incorporadas aqui para fornecer detalhes matemáticos do modelo do processo TE.]

C. Formulação do Problema de Detecção de Falhas

O problema geral de detecção de falhas pode ser formulado como uma tarefa de classificação binária. Dados os dados do processo $\mathbf{Y}$, o objetivo é construir uma regra de decisão que classifique as observações como normais (nominais) ou anormais (com falha):

$$\mathcal{D}(\mathbf{y}_k) = \begin{cases} \text{Normal} & \text{se } \mathcal{T}_k \leq \tau \\ \text{Com falha} & \text{se } \mathcal{T}_k > \tau \end{cases} \quad (2)$$

onde $\mathcal{T}_k$ é uma estatística de teste calculada a partir da observação $\mathbf{y}_k$, e τ é um limiar determinado com base na taxa desejada de falsos positivos. O desafio reside em selecionar

estatísticas de teste e limiares adequados que maximizem a taxa de detecção de falhas, minimizando os alarmes falsos.

D. Métricas Estatísticas de Detecção: T^2 e SPE

A maioria dos métodos de monitoramento de processos baseia-se em duas métricas estatísticas fundamentais calculadas a partir de dados multivariados: a estatística T^2 de Hotelling e o Erro Quadrático de Predição (SPE, do inglês Squared Prediction Error), também conhecido como estatística Q .

1) *Estatística T^2 de Hotelling*: A estatística T^2 de Hotelling mede a distância de um ponto ao centro dos dados de treinamento no subespaço dos componentes principais. Para uma nova observação $\mathbf{x}_k$, após projeção nos primeiros a componentes principais:

$$T_k^2 = \mathbf{t}_k^\top \mathbf{\Lambda}^{-1} \mathbf{t}_k \quad (3)$$

onde $\mathbf{t}_k$ são os escores (projeções) e $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_a)$ é a matriz diagonal dos autovalores correspondentes aos componentes retidos. A estatística T^2 segue uma distribuição F sob a hipótese nula de operação normal:

$$T_{\text{lim}}^2 = \frac{a(n-1)}{n-a} F_{\alpha}(a, n-a) \quad (4)$$

onde n é o número de amostras de treinamento, a é o número de componentes retidos e F_{α} é o valor crítico ao nível de significância α .

2) *Erro Quadrático de Predição (Estatística Q)*: O SPE (ou estatística Q) mede a contribuição de cada observação para o subespaço residual ortogonal ao subespaço do modelo:

$$Q_k = \|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2 = \|\mathbf{x}_k - \mathbf{x}_k \mathbf{P}_a \mathbf{P}_a^\top\|^2 \quad (5)$$

onde $\mathbf{P}_a$ contém as primeiras a direções principais. O SPE é sensível a falhas que se situam fora do subespaço do modelo. Seu limite de controle é tipicamente determinado pela aproximação de Jackson-Mudholkar:

$$Q_{\text{lim}} = \theta_1 \left[\frac{c_{\alpha} \sqrt{2\theta_2 h_0^2}}{\theta_1} + 1 + \frac{\theta_2 h_0 (h_0 - 1)}{\theta_1^2} \right]^{1/h_0} \quad (6)$$

$$\text{onde } \theta_k = \sum_{i=a+1}^p \lambda_i^k \text{ e } h_0 = 1 - \frac{2\theta_1 \theta_3}{3\theta_2^2}.$$

E. Visão Geral Comparativa dos Métodos de Detecção de Falhas

Este trabalho compara oito metodologias distintas de detecção de falhas aplicadas ao processo TE. Cada método emprega estratégias de transformação e fundamentos estatísticos próprios. A seguir, descrevemos a essência de cada um, destacando suas equações-chave.

1) *Análise de Componentes Principais (PCA)*: A PCA decompõe a matriz de dados $\mathbf{X}$ (com m variáveis e N observações) em componentes não correlacionados que capturam a máxima variância. O primeiro passo é centralizar os dados e calcular a matriz de covariância $\mathbf{S} = \frac{1}{N-1} \mathbf{X}^\top \mathbf{X}$. A decomposição em autovalores e autovetores fornece:

$$\mathbf{S} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top, \quad (7)$$

onde $\mathbf{P}$ contém os autovetores (loadings) e $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_m)$ os autovalores em ordem decrescente.

Retendo os a primeiros componentes, uma nova observação $\mathbf{x}$ é projetada no subespaço principal:

$$\mathbf{t} = \mathbf{P}_a^\top \mathbf{x}, \quad \hat{\mathbf{x}} = \mathbf{P}_a \mathbf{t}. \quad (8)$$

O monitoramento utiliza duas estatísticas complementares: - $T^2 = \mathbf{t}^\top \mathbf{\Lambda}_a^{-1} \mathbf{t}$ (variação no subespaço do modelo), - $Q = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$ (erro no subespaço residual).

Uma falha é declarada se $T^2 > T_{\text{lim}}^2$ ou $Q > Q_{\text{lim}}$, onde os limites são obtidos da distribuição F e da aproximação de Jackson-Mudholkar (Equações (4) e (6)).

Vantagens: eficiência computacional, interpretabilidade. Desvantagens: assume relações lineares e exige escolha adequada de a .

2) *Análise de Componentes Principais Dinâmica (DPCA)*: A DPCA incorpora a dinâmica temporal sem alterar a essência da PCA. Para cada instante k , constrói-se um vetor aumentado com ℓ defasagens:

$$\mathbf{x}_k^{\text{aug}} = \begin{bmatrix} \mathbf{x}_k \\ \mathbf{x}_{k-1} \\ \vdots \\ \mathbf{x}_{k-\ell} \end{bmatrix} \in \mathbb{R}^{m(\ell+1)}. \quad (9)$$

Aplica-se a PCA padrão a essa matriz aumentada. As estatísticas T^2 e Q são então calculadas no espaço aumentado, capturando correlações temporais e melhorando a detecção de falhas lentas.

3) *Mínimos Quadrados Parciais (PLS)*: O PLS relaciona as variáveis de processo $\mathbf{X}$ com uma saída de qualidade $\mathbf{y}$ (no nosso caso, a concentração do componente G, XMEAS 35). O modelo extrai variáveis latentes $\mathbf{t}_i$ que maximizam a covariância entre $\mathbf{X}$ e $\mathbf{y}$:

$$\mathbf{X} = \mathbf{T} \mathbf{P}^\top + \mathbf{E}, \quad (10)$$

$$\mathbf{y} = \mathbf{T} \mathbf{q} + \mathbf{f}, \quad (11)$$

onde $\mathbf{T} = [\mathbf{t}_1, \dots, \mathbf{t}_a]$ são os escores, $\mathbf{P}$ as cargas (loadings) de $\mathbf{X}$, $\mathbf{q}$ os pesos de $\mathbf{y}$, e $\mathbf{E}, \mathbf{f}$ os resíduos.

Na fase de monitoramento, calculam-se T^2 e Q a partir dos escores, de forma idêntica à PCA. Assim, o PLS supervisiona a redução de dimensionalidade, mantendo a sensibilidade a variações que afetam a qualidade.

4) *Mínimos Quadrados Parciais com Informação Temporal (TPLS)*: O TPLS simplesmente aplica o PLS ao conjunto de dados aumentado com defasagens temporais, análogo à DPCA:

$$\mathbf{X}^{\text{aug}} = [\mathbf{X}_k \quad \mathbf{X}_{k-1} \quad \dots \quad \mathbf{X}_{k-\ell}]. \quad (12)$$

Com isso, o modelo captura simultaneamente a correlação temporal e a relação supervisionada com a qualidade.

5) *Mínimos Quadrados Parciais Multivariados (MPLS)*: O MPLS estende o PLS para múltiplas saídas de qualidade $\mathbf{Y}$ (por exemplo, várias concentrações). A decomposição torna-se:

$$\mathbf{X} = \mathbf{T}\mathbf{P}^\top + \mathbf{E}, \quad \mathbf{Y} = \mathbf{U}\mathbf{Q}^\top + \mathbf{F}, \quad (13)$$

e busca-se maximizar a covariância entre os escores $\mathbf{T}$ e $\mathbf{U}$. Isso permite modelar relações mais complexas entre processo e qualidade, mantendo a estrutura de monitoramento baseada em T^2 e Q .

6) *Análise de Componentes Independentes (ICA)*: Enquanto a PCA descorrelaciona os dados, a ICA busca componentes estatisticamente independentes. Assume-se que as medições $\mathbf{x}$ são uma mistura linear de fontes independentes $\mathbf{s}$:

$$\mathbf{x} = \mathbf{A}\mathbf{s}, \quad (14)$$

com $\mathbf{A}$ a matriz de mistura. O algoritmo FastICA estima uma matriz de separação $\mathbf{W} \approx \mathbf{A}^{-1}$ tal que $\hat{\mathbf{s}} = \mathbf{W}\mathbf{x}$ tenham máxima não-gaussianidade.

Para monitoramento, calcula-se a estatística $I^2 = \hat{\mathbf{s}}^\top \hat{\mathbf{s}}$ (energia dos componentes independentes) e o erro de reconstrução $Q_{ICA} = \|\mathbf{x} - \mathbf{A}\hat{\mathbf{s}}\|^2$. Falhas são sinalizadas quando esses valores excedem limites obtidos por densidade de kernel.

7) *Análise de Componentes Independentes Multivariada (MICA)*: O MICA combina a ICA com a mesma estratégia de aumento temporal da DPCA. Aplica-se a ICA ao vetor aumentado $\mathbf{x}_k^{\text{aug}}$, capturando independência e dinâmica. As estatísticas I^2 e Q_{ICA} são calculadas no espaço aumentado, proporcionando sensibilidade adicional a falhas que evoluem lentamente.

8) *Análise Discriminante de Fisher (FDA)*: A FDA é um método supervisionado que busca direções $\mathbf{w}$ que maximizem a separação entre classes (normal vs. com falha). Define-se a matriz de dispersão entre classes $\mathbf{S}_B$ e a matriz de dispersão intraclasses $\mathbf{S}_W$:

$$\mathbf{S}_B = \sum_{c=1}^C n_c (\boldsymbol{\mu}_c - \boldsymbol{\mu})(\boldsymbol{\mu}_c - \boldsymbol{\mu})^\top, \quad (15)$$

$$\mathbf{S}_W = \sum_{c=1}^C \sum_{i \in c} (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top, \quad (16)$$

onde $C = 2$, n_c é o número de amostras da classe c , $\boldsymbol{\mu}_c$ a média da classe e $\boldsymbol{\mu}$ a média global.

A direção ótima $\mathbf{w}$ é o autovetor associado ao maior autovetor de $\mathbf{S}_W^{-1}\mathbf{S}_B$. Projetando os dados nessas direções, obtém-se uma estatística de monitoramento $D = \|\mathbf{W}^\top(\mathbf{x} - \boldsymbol{\mu}_{\text{normal}})\|^2$, com limite derivado da distribuição qui-quadrado.

III. METODOLOGIA E IMPLEMENTAÇÃO

Esta seção descreve a estrutura de implementação para ambas as abordagens de detecção de falhas, detalhando o pré-processamento dos dados, o desenvolvimento dos modelos e as estratégias de avaliação, conforme introduzido na Seção II.

A. Descrição do Problema e Características do Conjunto de Dados

Os algoritmos de detecção de falhas são avaliados utilizando o benchmark do processo Tennessee Eastman (TE). Os dados de treinamento contêm apenas amostras nominais (livres de falhas) ($n_{\text{treino}} = 500$ amostras), enquanto os dados de teste incluem observações normais e com falha ($n_{\text{teste}} = 960$ amostras por cenário de falha), correspondentes a 21 modos de falha diferentes (IDV 1–21). Todas as variáveis são normalizadas para média zero e variância unitária, utilizando estatísticas calculadas a partir do conjunto de treinamento.

B. Pré-processamento dos Dados e Seleção de Atributos

Os dados brutos dos sensores são normalizados como:

$$\mathbf{X}_{\text{normalizado}} = \frac{\mathbf{X} - \boldsymbol{\mu}}{\sigma} \quad (17)$$

onde $\boldsymbol{\mu}$ e σ são calculados a partir dos dados de treinamento. Para os métodos que incorporam informação temporal (DPCA, TPLS, MICA), as variáveis defasadas são concatenadas:

$$\mathbf{X}_k^{\text{aug}} = [\mathbf{X}_k^\top, \mathbf{X}_{k-1}^\top, \dots, \mathbf{X}_{k-\ell}^\top]^\top \quad (18)$$

com o parâmetro de defasagem $\ell = 2$ amostras.

C. Resumo da Implementação dos Métodos Individuais

1) *PCA e DPCA*: A PCA é implementada via decomposição em valores singulares (SVD) da matriz de dados de treinamento centrada. O número de componentes é selecionado de forma a reter 95% da variância total. Para cada observação de teste, as estatísticas T^2 e Q são calculadas e comparadas com os limites de controle derivados da distribuição F e da aproximação de Jackson-Mudholkar, respectivamente. A DPCA segue o procedimento idêntico aplicado ao espaço de atributos temporalmente aumentado.

2) *PLS, TPLS e MPLS*: O PLS decompõe a relação entre as variáveis de processo ($\mathbf{X}$) e a qualidade do produto ($\mathbf{XMEAS}$ 35, concentração do componente G) em variáveis latentes. O modelo é treinado para maximizar a covariância entre $\mathbf{X}$ e $\mathbf{y}$ utilizando o algoritmo NIPALS. Os componentes são retidos com base em validação cruzada. O TPLS aplica o PLS aos dados $\mathbf{X}$ temporalmente aumentados. O MPLS emprega uma estratégia aprimorada de extração de variáveis latentes através de múltiplos objetivos. A detecção prossegue com as mesmas estatísticas T^2 e Q da PCA.

3) *ICA e MICA*: A ICA é implementada utilizando o algoritmo FastICA para extrair componentes estatisticamente independentes dos dados de treinamento. Assumindo uma mistura linear ($\mathbf{X} = \mathbf{A}\mathbf{S}$), a matriz de mistura $\mathbf{A}$ e os componentes fonte $\mathbf{S}$ são estimados de modo que os componentes sejam mutuamente independentes. Para as observações de teste, são calculadas estatísticas baseadas em independência. O MICA estende esse processo aumentando os dados com defasagens temporais antes da decomposição ICA.

4) *Análise Discriminante de Fisher (FDA)*: A FDA é treinada com dados rotulados (amostras normais vs. com falha) para encontrar direções de projeção que maximizam a separação entre classes. O subespaço discriminante projeta todas as observações; as falhas são identificadas quando a projeção se encontra distante do centro da classe normal.

D. Métricas de Desempenho

O desempenho dos modelos é avaliado utilizando métricas de classificação padrão:

$$\text{Sensibilidade} = \frac{VP}{VP + FN} \quad (19)$$

$$\text{Especificidade} = \frac{VN}{VN + FP} \quad (20)$$

$$\text{F1-score} = 2 \cdot \frac{\text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}} \quad (21)$$

onde VP, VN, FP e FN denotam verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos, respectivamente.

IV. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados experimentais obtidos com a aplicação de todas as oito abordagens de detecção de falhas ao processo Tennessee Eastman. Métricas abrangentes de desempenho são avaliadas em 21 cenários de falha para permitir uma análise comparativa rigorosa. As implementações seguem a metodologia descrita na Seção III.

A. Taxa de Alarmes Falsos (FAR)

A taxa de alarmes falsos mede a porcentagem de amostras de operação normal incorretamente sinalizadas como falhas. Essa métrica é crítica para a implantação prática, pois uma FAR elevada leva a manutenções desnecessárias e à perda de confiança no sistema de detecção.

Tabela IV
COMPARAÇÃO DAS TAXAS DE ALARMES FALSOS (FAR) ENTRE TODOS OS MÉTODOS

Posição	Método	FAR (%)
1	MICA	0,52%
2	FDA	1,15%
3	PCA	5,62%
4	DPCA	6,56%
5	ICA	6,98%
6	TPLS	10,42%
7	MPLS	10,31%
8	PLS	12,19%

Principais Observações:

- O MICA atinge a menor taxa de alarmes falsos (0,52%), indicando especificidade superior na detecção de operação normal.
- A FDA apresenta desempenho competitivo (1,15%), demonstrando a eficácia da redução supervisionada de dimensionalidade.

- Os métodos PCA e estatísticos tradicionais alcançam valores moderados de FAR (5,6–6,9%).
- Os métodos baseados em PLS exibem FAR mais elevada (10,3–12,2%), sugerindo sensibilidade a variações normais do processo.

B. Taxa de Detecção de Falhas (FDR) por Tipo de Falha

A taxa de detecção de falhas (sensibilidade) mede a porcentagem de amostras com falha corretamente identificadas como anormais. Uma avaliação abrangente em todos os 21 modos de falha revela os pontos fortes e as limitações de cada método.

C. Análise de Desempenho por Categoria de Falha

Falhas de Forte Detecção (FDR > 95%): IDV(01), IDV(02), IDV(04), IDV(06), IDV(07), IDV(12), IDV(14). Representam falhas abruptas que perturbam significativamente as medições ou a composição do processo. A maioria dos métodos as detecta de forma confiável.

Falhas de Detecção Moderada (50% < FDR < 95%): IDV(11), IDV(13), IDV(17), IDV(18). Correspondem a falhas sutis com início gradual ou impacto limitado nas medições. O TPLS e o MPLS geralmente apresentam melhor desempenho nessas falhas devido a considerações temporais e multivariadas.

Falhas de Difícil Detecção (FDR < 50%): IDV(03), IDV(05), IDV(09), IDV(15), IDV(16), IDV(19), IDV(20), IDV(21). Representam cenários desafiadores nos quais as falhas têm impacto direto mínimo nas medições disponíveis ou interagem fracamente com a dinâmica do processo. Nenhum método isolado atinge alta sensibilidade em todas as falhas difíceis.

D. Observações Específicas dos Métodos

1) *PCA e DPCA*: Ambos os métodos alcançam excelente FAR (5,6% e 6,6%) e forte desempenho em falhas abruptas (FDR > 95%). A DPCA proporciona melhorias marginais em relação à PCA para as falhas IDV(10), IDV(11) e IDV(16) ao capturar a dinâmica temporal. No entanto, ambos os métodos enfrentam dificuldades semelhantes com as falhas difíceis (IDV(03), IDV(09), IDV(15)).

2) *Métodos PLS*: O PLS, o TPLS e o MPLS apresentam FAR mais elevada (10–12%), mas melhoram a FDR em falhas difíceis por meio do aprendizado supervisionado. O TPLS e o MPLS obtêm melhorias notáveis em IDV(05) (37,4% e 36,5%) e IDV(10) (77,2% e 90,0%). O MPLS fornece a maior FDR para IDV(10) (90,0%), demonstrando o valor das considerações multivariadas de saída.

3) *ICA e MICA*: A ICA mantém uma FAR moderada (7,0%) e tem bom desempenho em falhas abruptas (FDR > 90%). O MICA atinge uma FAR excepcionalmente baixa (0,52%), a melhor entre todos os métodos, mas à custa de uma FDR reduzida para falhas difíceis (ex.: IDV(03): 3,4%, IDV(09): 1,6%). Isso reflete uma estratégia de detecção conservadora.

Tabela V
TAXAS DE DETECÇÃO DE FALHAS (FDR) PARA TODOS OS MÉTODOS E CENÁRIOS DE FALHA

Falha	PCA	DPCA	PLS	TPLS	MPLS	ICA	MICA	FDA
IDV(01)	99,9%	99,9%	99,9%	99,9%	99,9%	99,9%	99,8%	98,9%
IDV(02)	98,8%	98,9%	98,9%	98,9%	98,8%	98,9%	97,9%	96,9%
IDV(03)	12,9%	12,1%	12,1%	17,6%	13,6%	14,9%	3,4%	1,5%
IDV(04)	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%	97,5%	100,0%
IDV(05)	33,6%	37,1%	37,1%	37,4%	36,5%	35,9%	26,2%	99,9%
IDV(06)	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%
IDV(07)	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%	21,8%
IDV(08)	98,0%	98,0%	98,0%	98,4%	98,5%	98,1%	97,1%	57,6%
IDV(09)	8,4%	10,1%	10,1%	16,1%	13,5%	10,6%	1,6%	1,2%
IDV(10)	60,5%	63,0%	63,0%	77,2%	90,0%	63,1%	41,1%	65,6%
IDV(11)	78,9%	84,2%	84,2%	81,9%	81,0%	81,1%	64,2%	65,9%
IDV(12)	99,1%	99,1%	99,1%	99,4%	99,5%	99,2%	99,0%	81,9%
IDV(13)	95,4%	95,4%	95,4%	95,2%	95,2%	95,4%	94,4%	58,8%
IDV(14)	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%	100,0%	92,6%
IDV(15)	14,1%	16,9%	16,9%	24,6%	21,1%	18,0%	5,5%	1,5%
IDV(16)	55,2%	58,0%	58,0%	65,5%	80,4%	58,9%	29,0%	6,9%
IDV(17)	95,2%	96,2%	96,2%	95,9%	95,2%	96,0%	90,4%	81,4%
IDV(18)	90,5%	90,5%	90,5%	91,6%	90,9%	90,6%	89,6%	85,9%
IDV(19)	42,1%	53,9%	53,9%	43,6%	33,9%	51,4%	22,9%	2,0%
IDV(20)	63,4%	66,4%	66,4%	68,9%	65,9%	65,5%	49,6%	54,9%
IDV(21)	52,1%	52,2%	52,2%	61,1%	59,8%	55,0%	45,5%	1,8%

4) **FDA**: A FDA exibe a maior variância de desempenho: excelente para algumas falhas (IDV(04), IDV(05), IDV(06): 100%, 99,9%, 100%) e muito ruim para outras (IDV(03), IDV(09), IDV(15), IDV(19), IDV(21): <2%). Isso sugere que a FDA é altamente sensível ao desbalanceamento de classes e à composição dos dados de treinamento.

E. Métricas-Resumo

Tabela VI
RESUMO DE DESEMPENHO: FDR MÉDIA EM TODAS AS FALHAS

Método	FDR Média	FAR (%)
DPCA	72,6%	6,56%
TPLS	71,8%	10,42%
PCA	71,3%	5,62%
ICA	70,9%	6,98%
MPLS	70,7%	10,31%
PLS	70,1%	12,19%
MICA	62,3%	0,52%
FDA	66,7%	1,15%

O DPCA e o TPLS despontam como os melhores em FDR geral (71,8–72,6%), enquanto o MICA lidera em especificidade (FAR 0,52%) e a FDA apresenta um bom equilíbrio entre especificidade e detecção seletiva de falhas.

V. CONCLUSÃO

A. Resumo

Este trabalho apresenta uma comparação abrangente de benchmark de oito metodologias distintas de detecção de falhas baseadas em dados aplicadas ao processo Tennessee Eastman. O estudo avaliou tanto métodos estatísticos multivariados clássicos (PCA, DPCA) quanto técnicas avançadas que incorporam dinâmica temporal (ICA, MICA) e objetivos de aprendizado supervisionado (variantes do PLS, FDA). A

análise comparativa revela que nenhum método único domina em todas as métricas de desempenho, destacando o trade-off entre sensibilidade (taxa de detecção de falhas) e especificidade (taxa de alarmes falsos).

B. Principais Constatações

- 1) **Trade-off entre FDR e FAR**: O MICA atinge a menor taxa de alarmes falsos (0,52%), mas com sensibilidade de detecção reduzida para falhas difíceis (FDR média de 62,3%). Em contrapartida, o DPCA alcança a maior FDR média (72,6%), mantendo uma FAR razoável (6,56%).
- 2) **A informação temporal melhora o desempenho**: As extensões temporais (DPCA vs. PCA, TPLS vs. PLS, MICA vs. ICA) geralmente melhoram a FDR em falhas de evolução lenta ou sutis, justificando o custo computacional adicional em muitas aplicações.
- 3) **A dificuldade das falhas varia**: Falhas abruptas e de magnitude significativa (IDV(01), IDV(02), IDV(04), IDV(06), IDV(07)) são detectadas de forma confiável (FDR > 95%) por todos os métodos. Falhas sutis com impacto mínimo nas medições (IDV(03), IDV(09), IDV(15)) permanecem desafiadoras, com FDR frequentemente abaixo de 25%.
- 4) **Os métodos supervisionados apresentam desempenho variável**: Embora os métodos baseados em PLS atinjam FDR média competitiva (70,1–71,8%), a FDA exibe alta variância, destacando-se em algumas falhas e falhando completamente em outras. Isso reflete a sensibilidade à composição dos dados de treinamento e ao desbalanceamento de classes.
- 5) **A seleção do método depende dos requisitos da aplicação**: Para infraestruturas críticas que exigem alta especificidade, o MICA é a melhor opção. Para monitoramento de propósito geral com ênfase na cobertura de

detecção, recomenda-se o DPCA. Para aplicações focadas em qualidade, o TPLS ou o MPLS são apropriados.

C. Tabela-Resumo dos Resultados

A Tabela ?? consolida as principais métricas de desempenho, facilitando a comparação direta entre os métodos e servindo como guia para a seleção de acordo com as prioridades do sistema de monitoramento.

D. Recomendações para a Prática

- **Implantação de método único:** Escolha o DPCA como linha de base confiável, oferecendo 72,6% de FDR média com 6,56% de FAR.
- **Abordagem em conjunto:** Combine múltiplos métodos (ex.: DPCA + MICA) para equilibrar sensibilidade e especificidade. Sinalize alarmes quando houver consenso.
- **Ajuste adaptativo de limiares:** Permita o ajuste dos limiares com base no modo de operação do processo e nas prioridades da política de manutenção.
- **Configuração específica por falha:** Para falhas críticas conhecidas, calibre os métodos individualmente em vez de aplicar limiares uniformes.

E. Direções para Pesquisas Futuras

- **Métodos híbridos e ensembles:** Desenvolver estratégias inteligentes de fusão que ponderem adaptativamente múltiplos métodos com base no estado do processo e no desempenho histórico.
- **Abordagens de aprendizado profundo:** Investigar redes neurais recorrentes (LSTM, GRU) e mecanismos de atenção para capturar dependências temporais de forma mais eficaz do que as abordagens tradicionais de variáveis defasadas.
- **Métodos de kernel:** Explorar extensões com kernel (KPCA, KPLS) para capturar variedades não lineares do processo.
- **Aprendizado por transferência:** Investigar a adaptação de domínio para permitir a transferência de conhecimento de processos bem estudados (como o TE) para diferentes aplicações industriais.
- **Implementação em tempo real:** Avaliar os requisitos computacionais para implantação embarcada e desenvolver mecanismos de atualização online.
- **Análise de causa raiz:** Estender os sistemas de detecção com módulos de isolamento e identificação para orientar as decisões de manutenção.
- **Quantificação de incerteza:** Incorporar estruturas bayesianas para quantificar a confiança nas decisões de detecção de falhas e reduzir alarmes falsos.

O objetivo final é desenvolver sistemas adaptativos de detecção de falhas com múltiplos métodos, capazes de operar de forma confiável em diversos ambientes industriais, com o mínimo de configuração manual, mantendo ao mesmo tempo altos padrões de confiabilidade.

REFERÊNCIAS

- [1] Dayal, B. S., & MacGregor, J. F. (1997). *Improved PLS algorithms*. Journal of Chemometrics, 11(1), 73-85.
- [2] Spina, D. E., Campos, L. F. O., de Arruda, W. F., Melo, A., Alves, M. F. S., Rabello, G. L., Anzai, T. K., & Pinto, J. C. (2024). *Comparison of autoencoder architectures for fault detection in industrial processes*. Digital Chemical Engineering, 12, 100162.
- [3] Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media, Inc.
- [4] Downs, J. J., & Vogel, E. F. (1993). *A plant-wide industrial process control problem*. Computers & Chemical Engineering, 17(3), 245-255.
- [5] Gavish, M., & Donoho, D. L. (2014). *The optimal hard threshold for singular values is $4/\sqrt{3}$* . IEEE Transactions on Information Theory, 60(8), 5040-5053.
- [6] Yin, S., Ding, S. X., Haghani, A., Hao, H., & Zhang, P. (2012). *A comparison study of basic data-driven fault diagnosis and process monitoring methods on the benchmark Tennessee Eastman process*. Journal of Process Control, 22(9), 1567-1581.
- [7] Favoreel, W., De Moor, B., & Van Overschee, P. (2000). *Subspace state space system identification for industrial processes*. Journal of Process Control, 10(2-3), 149-155.



Saulo José Almeida Silva Técnico em Instalações Elétricas pelo Instituto Federal de Alagoas (IFAL, 2021). Bacharel em Engenharia Elétrica com ênfase em Instalações Elétricas pelo IFAL (2026). Especialização em Automação Industrial pela Eduno. Atualmente é mestrando em Engenharia Elétrica na Universidade Federal de Campina Grande (UFCG), atuando na área de Robótica com foco em coordenação de sistemas robóticos heterogêneos.