

Detecção de Falhas em Processos Industriais: Análise Comparativa de Abordagens baseadas em SVD e Redes Autoencodificadoras

Saulo José Almeida Silva, *Mestrando, UFCG*,

Resumo—A detecção precoce de falhas em processos industriais é crucial para manter a confiabilidade do sistema, a segurança e a eficiência operacional. Este trabalho apresenta um estudo abrangente de algoritmos de detecção de falhas baseados em oito metodologias distintas: métodos estatísticos multivariados (PCA, DPCA), abordagens supervisionadas (PLS, TPLS, MPLS, FDA), técnicas baseadas em independência estatística (ICA, MICA) e um autoencoder probabilístico (PAE). O trabalho avalia a eficácia de cada método na detecção de falhas incipientes e abruptas utilizando o benchmark do processo Tennessee Eastman. Os resultados demonstram trade-offs significativos entre a taxa de detecção (sensibilidade) e a taxa de alarmes falsos (especificidade). O PAE alcança a maior sensibilidade geral (75,5% de FDR), porém com a maior taxa de alarmes falsos (17,08%). O DPCA oferece o melhor equilíbrio entre sensibilidade e especificidade (72,95% de FDR e 6,56% de FAR), enquanto o MICA obtém a menor taxa de alarmes falsos (0,52%), ideal para aplicações que priorizam a especificidade. A análise comparativa fornece uma base robusta para a seleção de métodos adequados conforme os requisitos específicos de cada aplicação industrial.

Index Terms—Detecção de Falhas, Análise de Componentes Principais, Processos Industriais, Análise Discriminante, Detecção de Anomalias, Aprendizado de Máquina.

I. INTRODUÇÃO

PROCESSOS industriais operam em condições complexas e frequentemente imprevisíveis [8], nas quais falhas de equipamentos podem levar a perdas econômicas significativas, riscos à segurança e danos ambientais. A detecção oportuna de falhas incipientes permite a manutenção preventiva [11], reduz o tempo de parada não planejado e melhora a confiabilidade geral do sistema. Abordagens tradicionais de detecção de falhas baseadas em modelos requerem modelos matemáticos precisos do sistema [6], os quais frequentemente não estão disponíveis ou são difíceis de obter na prática. Consequentemente, métodos baseados em dados emergiram como alternativas viáveis [11] que exploram dados históricos do processo para aprender padrões normais de operação e identificar desvios.

Este trabalho enfoca o desenvolvimento e a comparação de oito abordagens distintas de detecção de falhas baseadas em dados em processos industriais. A Seção II fornece uma revisão abrangente dos fundamentos teóricos e dos trabalhos relacionados, incluindo métodos multivariados [12] e técnicas

avancadas de aprendizado de máquina. A Seção III descreve a formulação do problema e os detalhes de implementação. A Seção IV apresenta os resultados experimentais e a análise comparativa. Finalmente, a Seção V resume as conclusões e sugere direções para pesquisas futuras.

A. Notação e Convenções

Ao longo deste trabalho, adotamos as seguintes convenções de notação: escalares são denotados por letras itálicas (a), vetores por letras minúsculas em negrito ($\mathbf{a}$) e matrizes por letras maiúsculas em negrito ($\mathbf{A}$). O operador de transposição é denotado por $(\cdot)^T$, a norma de Frobenius por $\|\cdot\|_F$ e a norma espectral por $\|\cdot\|_2$. Para sistemas em tempo discreto, o subíndice k denota o instante de tempo, i.e., $\mathbf{x}_k$. A notação $\|\mathbf{x}\|$ representa a norma euclidiana, e $\mathbb{R}^{m \times n}$ denota o conjunto de matrizes reais de dimensão $m \times n$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

As metodologias de detecção de falhas evoluíram significativamente ao longo das últimas décadas [12]. Esta seção revisa os conceitos fundamentais e as técnicas relevantes para os oito métodos investigados neste trabalho, apresentando uma comparação compatível com estudos benchmarks pretritos.

A. Processos Industriais e Monitoramento Multivariável

Os processos industriais modernos geram quantidades vastas de dados de sensores de múltiplas variáveis operando simultaneamente [12]. Um processo multivariável típico pode ser representado como uma coleção de m variáveis medidas amostradas em instantes discretos de tempo $k = 1, 2, \dots, N$:

$$\mathbf{Y} \in \mathbb{R}^{m \times N} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_N] \quad (1)$$

onde cada coluna $\mathbf{y}_k = [y_{1,k}, y_{2,k}, \dots, y_{m,k}]^T$ representa um snapshot do estado do processo no instante k . O monitoramento do processo geralmente se concentra em detectar quando o sistema se desvia das condições normais de operação, o que pode indicar o início de uma falha [3].

B. Definição de uma Falta num processo Industrial

Uma falta, ou falha, em um processo industrial refere-se a qualquer desvio do comportamento normal do sistema que pode levar a operação inadequada, redução de desempenho, ou até falha total do equipamento [12]. As falhas podem ser

S. J. A. Silva é mestrando no Programa de Pós-Graduação em Engenharia Elétrica (PPgEE) da Universidade Federal de Campina Grande (UFCG), Campina Grande, PB, Brasil. E-mail: saulo.jose.silva@ee.ufcg.edu.br.


A. M. N. Lima é Professor Titular do Departamento de Engenharia Elétrica da UFCG. E-mail: amnlma@dee.ufcg.edu.br.

de natureza abruptas (mudanças repentinas nos parâmetros do processo) ou incipientes (mudanças graduais ao longo do tempo). A detecção precoce de falhas é crucial para prevenir danos maiores, garantir a segurança operacional e manter a eficiência do processo.

C. O Processo Tennessee Eastman (TEP)

O *Tennessee Eastman Process* (TEP), proposto originalmente pela *Eastman Chemical Company* [2], é um *benchmark* industrial amplamente utilizado para avaliar estratégias de controle, monitoramento de processos e diagnóstico de falhas. Sua relevância decorre de sua natureza altamente não linear, forte acoplamento de variáveis e complexidade multivariável.

O processo envolve quatro reagentes gasosos (A, C, D e E), um componente inerte (B), dois produtos líquidos principais (G e H) e um subproduto líquido (F). As transformações ocorrem por meio de quatro reações paralelas e em série, irreversíveis e exotérmicas, descritas na Equação 2:



O sistema é composto por cinco unidades operacionais principais interconectadas: um reator CSTR, um condensador, um vaso separador líquido-vapor (*flash*), um compressor de reciclo e uma coluna de esgotamento (*stripper*), conforme ilustrado na Figura 1.

1) *Visão Geral do Processo*: As cinco unidades do TEP desempenham funções específicas para garantir a conversão dos reagentes e a purificação dos produtos, conforme sintetizado na Tabela I.

2) *Variáveis Medidas e Entradas Manipuladas*: Para fins de monitoramento e controle, o processo disponibiliza 12 variáveis manipuladas (XMV_{1-12}) e um total de 41 variáveis medidas continuamente. Estas últimas dividem-se em 22 medições de processo ($XMEAS_{1-22}$) e 19 medições de composição química via analisadores em linha ($XMEAS_{23-41}$), categorizadas nas Tabelas II e III.

3) *Cenários de Falha*: O *benchmark* do TEP simula 21 cenários de distúrbios e falhas operacionais (IDV_{1-21}), detalhados na Tabela IV, que servem como métricas rigorosas para algoritmos de detecção. Antes da aplicação dos métodos de diagnóstico, os dados históricos costumam ser padronizados para média zero e variância unitária [12], mitigando disparidades de escala entre as variáveis físicas.

4) *Descrição Detalhada da Dinâmica do Processo*: O TEP opera continuamente em malha fechada por realimentação, com o objetivo de reciclar materiais não consumidos, garantir a estabilidade térmica e de pressão, e assegurar metas de produção e pureza comercial. Do ponto de vista matemático, o comportamento dinâmico e estacionário da planta é governado por um sistema acoplado de equações diferenciais e algébricas não lineares (DAEs), envolvendo cerca de 50 variáveis de estado fundamentais. Essa complexidade fenomenológica torna o TEP um ambiente altamente fidedigno para validar a robustez

de novas ferramentas de ciência de dados e aprendizado de máquina.

D. Formulação do Problema de Detecção de Falhas

O problema geral de detecção de falhas pode ser formulado como uma tarefa de classificação binária [11]. Dados os dados do processo $\mathbf{Y}$, o objetivo é construir uma regra de decisão que classifique as observações como normais (nominais) ou anormais (com falha):

$$\mathcal{D}(\mathbf{y}_k) = \begin{cases} \text{Normal} & \text{se } \mathcal{T}_k \leq \tau \\ \text{Com falha} & \text{se } \mathcal{T}_k > \tau \end{cases} \quad (3)$$

onde $\mathcal{T}_k$ é uma estatística de teste calculada a partir da observação $\mathbf{y}_k$, e τ é um limiar determinado com base na taxa desejada de falsos positivos. O desafio reside em selecionar estatísticas de teste e limiares adequados que maximizem a taxa de detecção de falhas, minimizando os alarmes falsos.

E. Métricas Estatísticas de Detecção

A maioria dos métodos estatísticos de monitoramento de processos baseia-se em métricas fundamentais calculadas a partir de dados multivariados [11]. Para a avaliação do estado operacional do sistema, destacam-se quatro principais estatísticas de teste utilizadas na literatura: a estatística T^2 de Hotelling, o Erro Quadrático de Predição (SPE, também conhecido como estatística Q), a estatística I^2 baseada em componentes independentes, e o índice combinado D .

1) *Estatística T^2 de Hotelling*: A estatística T^2 de Hotelling é uma métrica fundamental em monitoramento multivariado [12]. Para uma nova observação $\mathbf{x}_k$, após projeção nos primeiros a componentes principais:

$$T_k^2 = \mathbf{t}_k^\top \mathbf{\Lambda}^{-1} \mathbf{t}_k \quad (4)$$

onde $\mathbf{t}_k$ são os escores (projeções) e $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_a)$ é a matriz diagonal dos autovalores correspondentes aos componentes retidos. A estatística T^2 segue uma distribuição F sob a hipótese nula de operação normal:

$$T_{\text{lim}}^2 = \frac{a(n-1)}{n-a} F_\alpha(a, n-a) \quad (5)$$

onde n é o número de amostras de treinamento, a é o número de componentes retidos e F_α é o valor crítico ao nível de significância α .

2) *Erro Quadrático de Predição (Estatística Q)*: O SPE (ou estatística Q) é uma métrica complementar que mede a contribuição residual não capturada pelo modelo de dimensão reduzida [12]. Essa medida indica a contribuição de cada observação para o subespaço residual ortogonal ao subespaço do modelo:

$$Q_k = \|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2 = \|\mathbf{x}_k - \mathbf{x}_k \mathbf{P}_a \mathbf{P}_a^\top\|^2 \quad (6)$$

onde $\mathbf{P}_a$ contém as primeiras a direções principais. O SPE é sensível a falhas que se situam fora do subespaço do




Figura 1. Fluxograma do processo industrial e disposição das principais malhas de controle do benchmark Tennessee Eastman (adaptado de [2]).

Tabela I
UNIDADES PRINCIPAIS DO PROCESSO TENNESSEE EASTMAN E SUAS RESPECTIVAS FUNÇÕES.

Unidade	Tipo de Equipamento	Descrição Operacional
Reator	Reator CSTR com camisa	Sedia as reações exotérmicas sob agitação mecânica e refrigeração controlada.
Condensador	Trocador de calor parcial	Resfria o vapor do reator para condensar os produtos de menor volatilidade.
Separador	Vaso de flash líquido-vapor	Separa fisicamente os gases não condensados do condensado líquido rico em produtos.
Compressor	Compressor centrífugo	Recircula os reagentes gasosos não consumidos de volta à alimentação do reator.
Stripper	Coluna de esgotamento	Purifica o produto líquido, removendo reagentes voláteis em contracorrente.

Tabela II
CATEGORIAS DE VARIÁVEIS DE MEDIÇÃO INSTRUMENTADAS ($XMEAS$) NO PROCESSO.

Tipo de Variável	Descrição e Componentes Associados	Quantidade
Vazões	Alimentações de reagentes ($A, D, E, A+C$), reciclo, alimentação total do reator, purga e fundos do separador e <i>stripper</i> .	9
Pressões	Monitoramento de pressão no reator, no separador e no <i>stripper</i> .	3
Níveis	Acúmulo de líquido no reator, no separador e na base do <i>stripper</i> .	3
Temperaturas	Controle térmico do reator, separador, topo/fundo do <i>stripper</i> e águas de resfriamento.	6
Potência	Consumo de trabalho/potência operacional do compressor de reciclo.	1
Analísadores (Composição)	Frações molares de componentes na alimentação do reator (5), gás de purga (5) e correntes de produto (4 na corrente 1 e 5 na corrente 2).	19
Total de Medições	Variáveis de processo contínuas ($XMEAS_{1-22}$) e de analisadores químicos ($XMEAS_{23-41}$).	41

Tabela III
CATEGORIAS DE VARIÁVEIS MANIPULADAS (XMV) E ATUADORES DO PROCESSO.

Tipo de Atuador / Variável	Descrição e Malhas de Controle Típicas	Quantidade
Vazões de Alimentação	Controle de carga do processo (A , D , E e mistura $A + C$). Associadas ao nível e pressão do reator e composição de entrada.	4
Abertura de Válvulas	Válvulas de reciclo do compressor, de purga (inertes/pressão) e de vapor do <i>stripper</i> (temperatura).	3
Vazões de Processo Líquido	Controle de escoamento de líquido do fundo do separador e do produto do <i>stripper</i> (controle de nível).	2
Serviços de Resfriamento	Vazão de água de resfriamento do reator (temperatura interna) e do condensador.	2
Agitação Mecânica	Velocidade de rotação do agitador do reator.	1
Total Manipuladas	Atuadores, posicionadores de válvula e setpoints de vazão (XMV_{1-12}).	12

Tabela IV
CENÁRIOS DE DISTÚRBIOS E FALHAS PROGRAMADAS (IDV_{1-21}) NO PROCESSO TE.

Código	Descrição do Distúrbio / Falha	Tipo de Fenômeno	Instante de Ocorrência
IDV(1) – IDV(2)	Mudanças de degrau na composição da alimentação	Degrau	500 segundos
IDV(3) – IDV(4)	Variações na temperatura das correntes de alimentação	Degrau	500 segundos
IDV(5) – IDV(7)	Alterações na temperatura/pressão do fluido de resfriamento	Degrau	500 segundos
IDV(8) – IDV(12)	Variações aleatórias na composição e vazão de alimentação	Ruído Aleatório	500 segundos
IDV(13) – IDV(15)	Deriva lenta na cinética de reação ou travamento de válvula	Deriva / Travamento	500 segundos
IDV(16) – IDV(20)	Falhas de natureza desconhecida (cenários ocultos)	Desconhecido	500 segundos
IDV(21)	Posição de válvula fixa em regime estacionário	Constante	500 segundos

modelo. Seu limite de controle é tipicamente determinado pela aproximação de Jackson-Mudholkar:

$$Q_{\lim} = \theta_1 \left[\frac{c_\alpha \sqrt{2\theta_2 h_0^2}}{\theta_1} + 1 + \frac{\theta_2 h_0 (h_0 - 1)}{\theta_1^2} \right]^{1/h_0} \quad (7)$$

$$\text{onde } \theta_k = \sum_{i=a+1}^p \lambda_i^k \text{ e } h_0 = 1 - \frac{2\theta_1 \theta_3}{3\theta_2^2}.$$

3) *Estatística I^2 (Componentes Independentes)*: A estatística I^2 é utilizada no contexto da Análise de Componentes Independentes (ICA) para monitorar o subespaço principal quando as variáveis apresentam comportamento não-Gaussiano [?]. Para uma nova observação $\mathbf{x}_k$, a estatística é calculada a partir dos escores independentes retidos $\mathbf{s}_{k,d}$:

$$I_k^2 = \mathbf{s}_{k,d}^\top \mathbf{s}_{k,d} \quad (8)$$

onde d é o número de componentes dominantes. Devido à não-gaussianidade dos dados, o limite de controle $I_{\lim}^2$ é estimado de forma não-paramétrica via Estimação de Densidade por Kernel (KDE) sob um nível de significância α :

$$I_{\lim}^2 = f_{\text{KDE}}(I_{\text{train}}^2, \alpha) \quad (9)$$

onde f_{KDE} representa a função quantil empírica obtida a partir dos dados de treinamento.

4) *Estatística D (Índice Combinado)*: A estatística D unifica as informações de variabilidade do subespaço principal (T^2) e do subespaço residual (Q) em uma única métrica, reduzindo a taxa de alarmes falsos redundantes [?]. O índice para a amostra k é definido por:

$$D_k = \frac{T_k^2}{T_{\lim}^2} + \frac{Q_k}{Q_{\lim}} \quad (10)$$

O limite de controle $D_{\lim}$ é obtido analiticamente através da aproximação de Box por uma distribuição Qui-Quadrado:

$$D_{\lim} = g \cdot \chi_\alpha^2(h) \quad (11)$$

Os parâmetros de escala g e os graus de liberdade efetivos h são calculados a partir da média μ_D e da variância σ_D^2 de D no conjunto de treinamento:

$$g = \frac{\sigma_D^2}{2\mu_D}, \quad h = \frac{2\mu_D^2}{\sigma_D^2} \quad (12)$$

F. Visão Geral Comparativa dos Métodos de Detecção de Falhas

Um estudo abrangente de benchmark [5], [12] é essencial para entender os pontos fortes e fracos de diferentes metodologias. Este trabalho compara oito metodologias distintas de detecção de falhas aplicadas ao processo TE, seguindo protocolos estabelecidos [11]. Cada método emprega estratégias de transformação e fundamentos estatísticos próprios. A seguir, descrevemos a essência de cada um, destacando suas equações-chave.

1) *Análise de Componentes Principais (PCA)*: A PCA é um método clássico de redução de dimensionalidade que decompõe a matriz de dados $\mathbf{X}$ (com m variáveis e N observações) em componentes não correlacionados que capturam a máxima variância [12]. O primeiro passo é centralizar

os dados e calcular a matriz de covariância $\mathbf{S} = \frac{1}{N-1} \mathbf{X}^\top \mathbf{X}$. A decomposição em autovalores e autovetores fornece:

$$\mathbf{S} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top, \quad (13)$$

onde $\mathbf{P}$ contém os autovetores (loadings) e $\mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_m)$ os autovalores em ordem decrescente.

Retendo os a primeiros componentes, uma nova observação $\mathbf{x}$ é projetada no subespaço principal:

$$\mathbf{t} = \mathbf{P}_a^\top \mathbf{x}, \quad \hat{\mathbf{x}} = \mathbf{P}_a \mathbf{t}. \quad (14)$$

O monitoramento utiliza duas estatísticas complementares: - $T^2 = \mathbf{t}^\top \mathbf{\Lambda}_a^{-1} \mathbf{t}$ (variação no subespaço do modelo), - $Q = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$ (erro no subespaço residual).

Uma falha é declarada se $T^2 > T_{\text{lim}}^2$ ou $Q > Q_{\text{lim}}$, onde os limites são obtidos da distribuição F e da aproximação de Jackson–Mudholkar (Equações (5) e (7)).

Vantagens: eficiência computacional, interpretabilidade e ampla aceitação na indústria. Desvantagens: assume relações lineares e exige escolha adequada de a [12].

2) *Análise de Componentes Principais Dinâmica (DPCA)*: A DPCA incorpora a dinâmica temporal, melhorando a capacidade de detecção de falhas lentas [3], sem alterar significativamente a essência da PCA. Para cada instante k , constrói-se um vetor aumentado com ℓ defasagens:

$$\mathbf{x}_k^{\text{aug}} = \begin{bmatrix} \mathbf{x}_k \\ \mathbf{x}_{k-1} \\ \vdots \\ \mathbf{x}_{k-\ell} \end{bmatrix} \in \mathbb{R}^{m(\ell+1)}. \quad (15)$$

Aplica-se a PCA padrão a essa matriz aumentada. As estatísticas T^2 e Q são então calculadas no espaço aumentado, capturando correlações temporais e melhorando a detecção de falhas lentas.

3) *Mínimos Quadrados Parciais (PLS)*: O PLS é um método supervisionado que relaciona as variáveis de processo $\mathbf{X}$ com uma saída de qualidade $\mathbf{y}$ (no nosso caso, a concentração do componente G, XMEAS 35) [1]. O modelo extrai variáveis latentes $\mathbf{t}_i$ que maximizam a covariância entre $\mathbf{X}$ e $\mathbf{y}$:

$$\mathbf{X} = \mathbf{T} \mathbf{P}^\top + \mathbf{E}, \quad (16)$$

$$\mathbf{y} = \mathbf{T} \mathbf{q} + \mathbf{f}, \quad (17)$$

onde $\mathbf{T} = [\mathbf{t}_1, \dots, \mathbf{t}_a]$ são os escores, $\mathbf{P}$ as cargas (loadings) de $\mathbf{X}$, $\mathbf{q}$ os pesos de $\mathbf{y}$, e $\mathbf{E}, \mathbf{f}$ os resíduos.

Na fase de monitoramento, calculam-se T^2 e Q a partir dos escores, de forma idêntica à PCA. Assim, o PLS supervisiona a redução de dimensionalidade, mantendo a sensibilidade a variações que afetam a qualidade.

4) *Mínimos Quadrados Parciais com Informação Temporal (TPLS)*: O TPLS aplica o PLS ao conjunto de dados aumentado com defasagens temporais, análogo à DPCA, capturando simultaneamente a correlação temporal e a relação supervisionada com a qualidade [1]:

$$\mathbf{X}^{\text{aug}} = [\mathbf{X}_k \quad \mathbf{X}_{k-1} \quad \dots \quad \mathbf{X}_{k-\ell}]. \quad (18)$$

5) *Mínimos Quadrados Parciais Multivariados (MPLS)*: O MPLS estende o PLS para múltiplas saídas de qualidade $\mathbf{Y}$ (por exemplo, várias concentrações), permitindo modelar relações mais complexas entre processo e qualidade [1]. A decomposição torna-se:

$$\mathbf{X} = \mathbf{T} \mathbf{P}^\top + \mathbf{E}, \quad \mathbf{Y} = \mathbf{U} \mathbf{Q}^\top + \mathbf{F}, \quad (19)$$

e busca-se maximizar a covariância entre os escores $\mathbf{T}$ e $\mathbf{U}$. Isso permite manter a estrutura de monitoramento baseada em T^2 e Q .

6) *Análise de Componentes Independentes (ICA)*: Enquanto a PCA descorrelaciona os dados, a ICA busca componentes estatisticamente independentes, oferecendo uma perspectiva complementar para identificação de padrões ocultos. Assume-se que as medições $\mathbf{x}$ são uma mistura linear de fontes independentes $\mathbf{s}$, proporcionando um modelo generativo para desacoplamento de sinais [12]:

$$\mathbf{x} = \mathbf{A} \mathbf{s}, \quad (20)$$

com $\mathbf{A}$ a matriz de mistura. O algoritmo FastICA estima uma matriz de separação $\mathbf{W} \approx \mathbf{A}^{-1}$ tal que $\hat{\mathbf{s}} = \mathbf{W} \mathbf{x}$ tenham máxima não-gaussianidade.

Para monitoramento, calcula-se a estatística $I^2 = \hat{\mathbf{s}}^\top \hat{\mathbf{s}}$ (energia dos componentes independentes) e o erro de reconstrução $Q_{\text{ICA}} = \|\mathbf{x} - \mathbf{A} \hat{\mathbf{s}}\|^2$. Falhas são sinalizadas quando esses valores excedem limites obtidos por densidade de kernel.

7) *Análise de Componentes Independentes Multivariada (MICA)*: O MICA combina a ICA com a mesma estratégia de aumento temporal da DPCA, proporcionando sensibilidade melhorada a falhas que evoluem lentamente [12]. Aplica-se a ICA ao vetor aumentado $\mathbf{x}_k^{\text{aug}}$, capturando independência e dinâmica. As estatísticas I^2 e Q_{ICA} são calculadas no espaço aumentado, proporcionando sensibilidade adicional a falhas que evoluem lentamente.

8) *Análise Discriminante de Fisher (FDA)*: A FDA é um método supervisionado clássico de classificação que busca direções $\mathbf{w}$ que maximizem a separação entre classes (normal vs. com falha), fornecendo uma fronteira de decisão ótima para detecção. Define-se a matriz de dispersão entre classes $\mathbf{S}_B$ e a matriz de dispersão intraclasse $\mathbf{S}_W$:

$$\mathbf{S}_B = \sum_{c=1}^C n_c (\boldsymbol{\mu}_c - \boldsymbol{\mu})(\boldsymbol{\mu}_c - \boldsymbol{\mu})^\top, \quad (21)$$

$$\mathbf{S}_W = \sum_{c=1}^C \sum_{i \in c} (\mathbf{x}_i - \boldsymbol{\mu}_c)(\mathbf{x}_i - \boldsymbol{\mu}_c)^\top, \quad (22)$$

onde $C = 2$, n_c é o número de amostras da classe c , $\boldsymbol{\mu}_c$ a média da classe e $\boldsymbol{\mu}$ a média global.

A direção ótima $\mathbf{w}$ é o autovetor associado ao maior autovetor de $\mathbf{S}_W^{-1} \mathbf{S}_B$. Projetando os dados nessas direções, obtém-se uma estatística de monitoramento $D = \|\mathbf{W}^\top (\mathbf{x} - \boldsymbol{\mu}_{\text{normal}})\|^2$, com limite derivado da distribuição qui-quadrado.

9) *Autoencoder Probabilístico (PAE)*: O PAE é um método não-supervisionado baseado em aprendizado profundo (frequentemente instanciado como um *Variational Autoencoder* - VAE) que modela a distribuição de probabilidade dos dados normais em um espaço latente de baixa dimensão

$\mathbf{z} \in \mathbb{R}^l$. Diferente de abordagens determinísticas, o codificador $q_\phi(\mathbf{z}|\mathbf{x})$ estima os parâmetros de uma distribuição Gaussiana, fornecendo um vetor de médias $\boldsymbol{\mu}_z$ e um vetor de log-variâncias $\log \sigma_z^2$. Para viabilizar o fluxo de gradientes via retropropagação durante o treinamento, aplica-se o truque da reparametrização, e a função de perda total $\mathcal{L}_{\text{PAE}}$ é formulada como:

$$\mathbf{z} = \boldsymbol{\mu}_z + \sigma_z \odot \boldsymbol{\epsilon}, \quad \text{com } \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}), \quad (23)$$

$$\mathcal{L}_{\text{PAE}} = \|\mathbf{x} - \hat{\mathbf{x}}\|^2 - \frac{1}{2} \sum_{j=1}^l \left(1 + \log \sigma_{zj}^2 - \mu_{zj}^2 - e^{\log \sigma_{zj}^2} \right), \quad (24)$$

onde $\odot$ denota o produto de Hadamard, $\hat{\mathbf{x}} = p_\theta(\mathbf{x}|\mathbf{z})$ é a reconstrução gerada pelo decodificador, e l é a dimensão do espaço latente. O primeiro termo de (24) minimiza o erro de reconstrução, enquanto o segundo termo penaliza o desvio da distribuição latente em relação a uma priori gaussiana padrão via Divergência de Kullback-Leibler (D_{KL}).

No monitoramento online, o modelo projeta as novas observações de teste e calcula de forma complementar as estatísticas T^2 latente e Q residual:

$$T^2 = \sum_{j=1}^l \frac{\mu_{zj}^2}{s_{zj}^2}, \quad (25)$$

$$Q = \sum_{i=1}^m (x_i - \hat{x}_i)^2, \quad (26)$$

onde s_{zj}^2 representa a variância amostral do escore latente j obtida exclusivamente no conjunto de treinamento normal e m é o número total de variáveis do processo. Os limites de controle para a detecção de anomalias são derivados da distribuição F de Snedecor para o espaço latente (T^2) e da aproximação de Box via distribuição qui-quadrado para o espaço residual (Q).

III. METODOLOGIA E IMPLEMENTAÇÃO

Esta seção descreve a estrutura de implementação para as oito abordagens de detecção de falhas, seguindo os protocolos de benchmark estabelecidos [12], detalhando o pré-processamento dos dados, o desenvolvimento dos modelos e as estratégias de avaliação, conforme introduzido na Seção II.

A. Descrição do Problema e Características do Conjunto de Dados

Os algoritmos de detecção de falhas são avaliados utilizando o benchmark do processo Tennessee Eastman (TE) [2], [12], amplamente aceito pela comunidade científica. Os dados de treinamento contém apenas amostras nominais (livres de falhas) ($n_{\text{treino}} = 500$ amostras), enquanto os dados de teste incluem observações normais e com falha ($n_{\text{teste}} = 960$ amostras por cenário de falha), correspondentes a 21 modos de falha diferentes (IDV 1–21). Todas as variáveis são normalizadas para média zero e variância unitária, utilizando estatísticas calculadas a partir do conjunto de treinamento.

B. Pré-processamento dos Dados e Seleção de Atributos

Os dados brutos dos sensores são normalizados como descrito na literatura de monitoramento [12]:

$$\mathbf{X}_{\text{normalizado}} = \frac{\mathbf{X} - \boldsymbol{\mu}}{\boldsymbol{\sigma}} \quad (27)$$

onde $\boldsymbol{\mu}$ e $\boldsymbol{\sigma}$ são calculados a partir dos dados de treinamento. Para os métodos que incorporam informação temporal (DPCA, TPLS, MICA), as variáveis defasadas são concatenadas:

$$\mathbf{X}_k^{\text{aug}} = [\mathbf{X}_k^\top, \mathbf{X}_{k-1}^\top, \dots, \mathbf{X}_{k-\ell}^\top]^\top \quad (28)$$

com o parâmetro de defasagem $\ell = 2$ amostras.

C. Fluxograma de Implementação e Treinamento dos Algoritmos

O procedimento para a implementação, treinamento e validação das metodologias baseadas em dados segue um fluxo sequencial estruturado em cinco etapas principais:

- 1) **Aquisição dos Dados:** Leitura dos arquivos brutos do *benchmark* TEP, utilizando a base `d00.dat` para representação do estado de operação normal e os arquivos `di_te.dat` (onde $i = 1, \dots, 21$) correspondentes aos cenários de falha para testes.
- 2) **Pré-processamento e Tratamento:** Centralização na média e escalonamento por variância unitária (normalização Z -score) de todas as séries temporais, mitigando discrepâncias de ordens de magnitude física entre os sensores.
- 3) **Seleção de Variáveis:** Filtragem e mapeamento das variáveis preditoras e de resposta de acordo com a arquitetura interna e objetivo de cada modelo, conforme especificados nas Tabelas II e III.
- 4) **Treinamento do Modelo:** Calibração matemática e cálculo dos limiares estatísticos críticos de controle (como as estatísticas T^2 de Hotelling e Q/SPE) utilizando exclusivamente a matriz de dados normais (`d00.dat`).
- 5) **Teste e Validação:** Submissão dos modelos treinados individualmente a cada um dos 21 arquivos de distúrbio (`di_te.dat`) para o cálculo das métricas de Taxa de Detecção de Falhas (FDR) e Taxa de Alarme Falso (FAR).

D. Resumo da Implementação dos Métodos Individuais

1) **PCA e DPCA:** A PCA é implementada via decomposição em valores singulares (SVD) da matriz de dados de treinamento centrada, usando limiares de truncação ótimos [4]. O número de componentes é selecionado de forma a reter 95% da variância total. Para cada observação de teste, as estatísticas T^2 e Q são calculadas e comparadas com os limites de controle derivados da distribuição F e da aproximação de Jackson-Mudholkar, respectivamente. A DPCA segue o procedimento idêntico aplicado ao espaço de atributos temporalmente aumentado.

Tabela V
CLASSIFICAÇÃO DOS MÉTODOS DE MONITORAMENTO SEGUNDO A ESTRUTURA TEMPORAL, ABORDAGEM E FLUXO DE VARIÁVEIS.

Métodos	Aspecto Temporal	Abordagem	Estrutura dos Dados	Variáveis Utilizadas no Processo
PCA, ICA	Estático	Não Supervisionada	Bloco Único (X)	Concentra as 22 medições ($XMEAS_{1-22}$) e 11 manipuladas (XMV_{1-11}) em uma única matriz, sem diferenciação de alvos.
DPCA, MICA	Dinâmico	Não Supervisionada	Bloco Único (X) com <i>Lags</i>	Mesmas 33 variáveis ($XMEAS$ e XMV), porém acrescidas de suas componentes de atraso temporal.
PAE	Estático	Não Supervisionada	Bloco Único (X)	Concentra as 22 medições ($XMEAS_{1-22}$) e 11 manipuladas (XMV_{1-11}) para mapear de forma não-linear a distribuição de normalidade no espaço latente.
FDA	Estático	Supervisionada	Entrada $\rightarrow$ Classes	Utiliza as 33 variáveis de processo como preditoras para discriminar os rótulos (classes discretas) de falha.
PLS, MPLS	Estático	Supervisionada	Entrada $\rightarrow$ Saída	Mapeia a correlação entre as 33 variáveis preditoras (X) e a variável contínua de qualidade $XMEAS_{35}$ (Y).
TPLS	Dinâmico/Estático	Supervisionada	Entrada $\rightarrow$ Saída	Realiza a decomposição ortogonal separando as variações de X que são correlacionadas e ortogonais a $XMEAS_{35}$.

2) *PLS, TPLS e MPLS*: O PLS decompõe a relação entre as variáveis de processo (X) e a qualidade do produto ($XMEAS_{35}$, concentração do componente G) em variáveis latentes [1]. O modelo é treinado para maximizar a covariância entre X e y utilizando o algoritmo NIPALS. Os componentes são retidos com base em validação cruzada. O TPLS aplica o PLS aos dados X temporalmente aumentados. O MPLS emprega uma estratégia aprimorada de extração de variáveis latentes através de múltiplos objetivos. A detecção prossegue com as mesmas estatísticas T^2 e Q da PCA.

3) *ICA e MICA*: A ICA é implementada utilizando o algoritmo FastICA para extrair componentes estatisticamente independentes dos dados de treinamento [12]. Assumindo uma mistura linear ($X = AS$), a matriz de mistura A e os componentes fonte S são estimados de modo que os componentes sejam mutuamente independentes. Para as observações de teste, são calculadas estatísticas baseadas em independência. O MICA estende esse processo aumentando os dados com defasagens temporais antes da decomposição ICA.

4) *Análise Discriminante de Fisher (FDA)*: A FDA é treinada com dados rotulados (amostras normais vs. com falha) para encontrar direções de projeção que maximizam a separação entre classes [12]. O subespaço discriminante projeta todas as observações; as falhas são identificadas quando a projeção se encontra distante do centro da classe normal.

5) *Autoencoder Probabilístico (PAE)*: O PAE é implementado por meio de uma arquitetura de Autoencoder Variacional (VAE) não-linear, estruturada com redes neurais multicamadas (*encoder* e *decoder*). O treinamento é realizado de forma estritamente não-supervisionada, utilizando apenas a base de dados sob condições normais de operação. O *encoder* mapeia as variáveis de processo para os parâmetros estatísticos (média μ_z e log-variância $\log \sigma_z^2$) de uma distribuição Gaussiana

no espaço latente de dimensão reduzida, utilizando o truque da reparametrização para permitir a retropropagação do erro. O *decoder* recebe o vetor latente amostrado e realiza a reconstrução das variáveis originais de processo. O modelo é otimizado via algoritmo Adam, minimizando uma função de perda composta pelo erro quadrático médio de reconstrução e pela regularização via divergência de Kullback-Leibler (D_{KL}). A detecção de falhas prossegue em tempo real através de duas métricas complementares: a estatística T^2 Latente, que quantifica a distância de Mahalanobis dos escores médios projetados sob limiar derivado da distribuição F , e a estatística Q (SPE), que avalia a magnitude dos resíduos de reconstrução utilizando limites de controle estabelecidos pela aproximação de Box e pela distribuição Qui-quadrado (χ^2).

E. Métricas de Desempenho

O desempenho dos modelos é avaliado utilizando métricas de classificação padrão:

$$\text{Sensibilidade} = \frac{VP}{VP + FN} \quad (29)$$

$$\text{Especificidade} = \frac{VN}{VN + FP} \quad (30)$$

$$F1\text{-score} = 2 \cdot \frac{\text{Precisão} \cdot \text{Sensibilidade}}{\text{Precisão} + \text{Sensibilidade}} \quad (31)$$

onde VP, VN, FP e FN denotam verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos, respectivamente.

IV. RESULTADOS E DISCUSSÃO

Esta seção apresenta os resultados experimentais obtidos com a aplicação de todas as oito abordagens de detecção

de falhas ao processo Tennessee Eastman [2], [5]. Métricas abrangentes de desempenho são avaliadas em 21 cenários de falha para permitir uma análise comparativa rigorosa. As implementações seguem a metodologia descrita na Seção III.

A. Taxa de Alarmes Falsos (FAR)

A taxa de alarmes falsos mede a porcentagem de amostras de operação normal incorretamente sinalizadas como falhas. Essa métrica é crítica para a implantação prática [12], pois uma FAR elevada leva a manutenções desnecessárias e à perda de confiança no sistema de detecção.

Tabela VI
COMPARAÇÃO DAS TAXAS DE ALARMES FALSOS (FAR) ENTRE TODOS OS MÉTODOS

Posição	Método	FAR (%)
1	MICA	0,52%
2	FDA	1,15%
3	PCA	5,62%
4	DPCA	6,56%
5	ICA	6,98%
6	MPLS	10,31%
7	TPLS	10,42%
8	PLS	12,19%
9	PAE	17,08%

Principais Observações:

- O MICA atinge a menor taxa de alarmes falsos (0,52%), indicando especificidade superior na detecção de operação normal.
- A FDA apresenta desempenho competitivo (1,15%), demonstrando a eficácia da redução supervisionada de dimensionalidade.
- Os métodos PCA e estatísticos tradicionais alcançam valores moderados de FAR (5,6–6,9%).
- Os métodos baseados em PLS exibem FAR mais elevada (10,3–12,2%), sugerindo sensibilidade a variações normais do processo.

B. Taxa de Detecção de Falhas (FDR) por Tipo de Falha

A taxa de detecção de falhas (sensibilidade) mede a porcentagem de amostras com falha corretamente identificadas como anormais [5], [12]. Uma avaliação abrangente em todos os 21 modos de falha revela os pontos fortes e as limitações de cada método, conforme detalhado na Tabela VII.

C. Análise de Desempenho por Categoria de Falha

A sensibilidade dos métodos varia significativamente conforme a natureza e a magnitude dos distúrbios. A Tabela VIII categoriza os cenários de falha do processo Tennessee Eastman com base na Taxa de Detecção de Falhas (FDR) observada.

D. Observações Específicas dos Métodos

Conforme os dados apresentados na Tabela IX, as seguintes observações são feitas.

1) *PCA e DPCA*: Ambos os métodos alcançam excelente FAR (5,6% e 6,6%) e forte desempenho em falhas abruptas ($FDR > 95\%$). A DPCA proporciona melhorias marginais em relação à PCA para as falhas IDV(10), IDV(11) e IDV(16) ao capturar a dinâmica temporal. No entanto, ambos os métodos enfrentam dificuldades semelhantes com as falhas difíceis (IDV(03), IDV(09), IDV(15)).

2) *Métodos PLS*: O PLS, o TPLS e o MPLS apresentam FAR mais elevada (10–12%), mas melhoram a FDR em falhas difíceis por meio do aprendizado supervisionado. O TPLS e o MPLS obtêm melhorias notáveis em IDV(05) (37,4% e 36,5%) e IDV(10) (77,2% e 90,0%). O MPLS fornece a maior FDR para IDV(10) (90,0%), demonstrando o valor das considerações multivariadas de saída.

3) *ICA e MICA*: A ICA mantém uma FAR moderada (7,0%) e tem bom desempenho em falhas abruptas ($FDR > 90\%$). O MICA atinge uma FAR excepcionalmente baixa (0,52%), a melhor entre todos os métodos, mas à custa de uma FDR reduzida para falhas difíceis (ex.: IDV(03): 3,4%, IDV(09): 1,6%). Isso reflete uma estratégia de detecção conservadora.

4) *FDA*: A FDA exibe a maior variância de desempenho: excelente para algumas falhas (IDV(04), IDV(05), IDV(06): 100%, 99,9%, 100%) e muito ruim para outras (IDV(03), IDV(09), IDV(15), IDV(19), IDV(21): $< 2\%$). Isso sugere que a FDA é altamente sensível ao desbalanceamento de classes e à composição dos dados de treinamento.

5) *PAE*: O PAE exibe conseguiu um FDR superior a 90% em 11 das 21 falhas (IDV(1), IDV(2), IDV(4), IDV(6)–(8), IDV(12)–(14), IDV(17) e IDV(18)) e sua menor FDR foi de 27,1% na IDV(9), tendo um resultado em média superior a todas as outras (75,5%).

E. Métricas-Resumo

Tabela IX
RESUMO DE DESEMPENHO: FDR MÉDIA EM TODAS AS FALHAS

Método	FDR Média	FAR (%)
PAE	75,50%	17,08%
MPLS	74,94%	10,31%
TPLS	74,91%	10,42%
ICA	72,98%	6,98%
DPCA	72,95%	6,56%
PLS	72,95%	12,19%
PCA	71,34%	5,62%
MICA	64,51%	0,52%
FDA	56,05%	1,15%

O PAE e o MPLS despontam como os melhores em FDR geral (74,9–75,5%), enquanto o MICA lidera em especificidade (FAR 0,52%) e a FDA apresenta um bom equilíbrio entre especificidade e detecção seletiva de falhas.

V. CONCLUSÃO

A. Resumo

Este trabalho apresenta uma comparação abrangente de benchmark de oito metodologias distintas de detecção de falhas

Tabela VII
TAXAS DE DETECÇÃO DE FALHAS (FDR) PARA TODOS OS MÉTODOS E CENÁRIOS DE FALHA

Falha	PCA	DPCA	PLS	TPLS	MPLS	ICA	MICA	FDA	PAE
IDV(01)	99,90%	99,90%	99,90%	99,90%	99,90%	99,90%	99,80%	98,90%	99,90%
IDV(02)	98,80%	98,90%	98,90%	98,90%	98,80%	98,90%	97,90%	96,90%	98,60%
IDV(03)	12,90%	12,10%	12,10%	17,60%	13,60%	14,90%	3,40%	1,50%	31,10%
IDV(04)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	97,50%	100,00%	98,10%
IDV(05)	33,60%	37,10%	37,10%	37,40%	36,50%	35,90%	26,20%	99,90%	50,50%
IDV(06)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%
IDV(07)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	21,80%	100,00%
IDV(08)	98,00%	98,00%	98,00%	98,40%	98,50%	98,10%	97,10%	57,60%	99,10%
IDV(09)	8,40%	10,10%	10,10%	16,10%	13,50%	10,60%	1,60%	1,20%	27,10%
IDV(10)	60,50%	63,00%	63,00%	77,20%	90,00%	63,10%	41,10%	65,60%	66,80%
IDV(11)	78,90%	84,20%	84,20%	81,90%	81,00%	81,10%	64,20%	65,90%	79,00%
IDV(12)	99,10%	99,10%	99,10%	99,40%	99,50%	99,20%	99,00%	81,90%	99,80%
IDV(13)	95,40%	95,40%	95,40%	95,20%	95,20%	95,40%	94,40%	58,80%	95,80%
IDV(14)	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	100,00%	92,60%	100,00%
IDV(15)	14,10%	16,90%	16,90%	24,60%	21,10%	18,00%	5,50%	1,50%	28,70%
IDV(16)	55,20%	58,00%	58,00%	65,50%	80,40%	58,90%	29,00%	6,90%	64,60%
IDV(17)	95,20%	96,20%	96,20%	95,90%	95,20%	96,00%	90,40%	81,40%	94,90%
IDV(18)	90,50%	90,50%	90,50%	91,60%	90,90%	90,60%	89,60%	85,90%	92,10%
IDV(19)	42,10%	53,90%	53,90%	43,60%	33,90%	51,40%	22,90%	2,00%	30,00%
IDV(20)	63,40%	66,40%	66,40%	68,90%	65,90%	65,50%	49,60%	54,90%	72,40%
IDV(21)	52,10%	52,20%	52,20%	61,10%	59,80%	55,00%	45,50%	1,80%	56,90%
MÉDIA	71,34%	72,95%	72,95%	74,91%	74,94%	72,98%	64,51%	56,05%	75,50%

Tabela VIII
CLASSIFICAÇÃO DOS CENÁRIOS DE FALHA DO TEP POR NÍVEL DE DETECTABILIDADE.

Categoria	FDR Operacional	Cenários Associados (IDV)	Características Operacionais
Forte Detecção (Verde)	FDR > 95%	1, 2, 4, 6, 7, 12, 14	Distúrbios abruptos com impacto significativo nas medições.
Detecção Moderada (Amarelo)	50% < FDR < 95%	11, 13, 17, 18	Falhas sutis de evolução gradual ou impacto limitado.
Difícil Detecção (Vermelho)	FDR < 50%	3, 5, 9, 15, 16, 19, 20, 21	Impacto direto mínimo ou fraca interação dinâmica com as variáveis.

baseadas em dados aplicadas ao processo Tennessee Eastman [2], [5], [12]. O estudo avaliou tanto métodos estatísticos multivariados clássicos (PCA, DPCA) [3] quanto técnicas avançadas que incorporam dinâmica temporal (ICA, MICA) e objetivos de aprendizado supervisionado (variantes do PLS, FDA).

B. Principais Constatações

- 1) **Trade-off entre FDR e FAR:** O MICA atinge a menor taxa de alarmes falsos (0,52%), mas com sensibilidade de detecção reduzida para falhas difíceis (FDR média de 64,5%). Em contrapartida, o PAE alcança a maior FDR média (75,5%), porém com FAR elevada (17,08%). O DPCA oferece um bom equilíbrio (FDR 72,95%, FAR 6,56%).
- 2) **A informação temporal melhora o desempenho:** As extensões temporais (DPCA vs. PCA, TPLS vs. PLS, MICA vs. ICA) geralmente melhoram a FDR em falhas de evolução lenta ou sutis, justificando o custo computacional adicional em muitas aplicações.
- 3) **A dificuldade das falhas varia:** Falhas abruptas e de magnitude significativa (IDV(01), IDV(02), IDV(04), IDV(06), IDV(07)) são detectadas de forma confiável (FDR > 95%) por todos os métodos. Falhas sutis com impacto mínimo nas medições (IDV(03), IDV(09), IDV(15)) permanecem desafiadoras, com FDR frequentemente abaixo de 25%.
- 4) **Os métodos supervisionados apresentam desempenho variável:** Embora os métodos baseados em PLS atinjam FDR média competitiva (72,9–74,9%), a FDA exhibe alta variância, destacando-se em algumas falhas e falhando

completamente em outras. Isso reflete a sensibilidade à composição dos dados de treinamento e ao desbalanceamento de classes.

- 5) **A seleção do método depende dos requisitos da aplicação:** Para infraestruturas críticas que exigem alta especificidade, o MICA é a melhor opção. Para monitoramento de propósito geral com ênfase na cobertura de detecção, recomenda-se o DPCA ou o PAE. Para aplicações focadas em qualidade, o TPLS ou o MPLS são apropriados.

C. Direções para Pesquisas Futuras

- **Métodos híbridos e ensembles:** Desenvolver estratégias inteligentes de fusão que ponderem adaptativamente múltiplos métodos com base no estado do processo e no desempenho histórico.
- **Abordagens de aprendizado profundo:** Investigar redes neurais recorrentes (LSTM, GRU) e mecanismos de atenção para capturar dependências temporais de forma mais eficaz do que as abordagens tradicionais de variáveis defasadas.
- **Métodos de kernel:** Explorar extensões com kernel (KPCA, KPLS) para capturar variedades não lineares do processo.
- **Aprendizado por transferência:** Investigar a adaptação de domínio para permitir a transferência de conhecimento de processos bem estudados (como o TE) para diferentes aplicações industriais.
- **Implementação em tempo real:** Avaliar os requisitos computacionais para implantação embarcada e desenvolver mecanismos de atualização online.
- **Análise de causa raiz:** Estender os sistemas de detecção com módulos de isolamento e identificação para orientar as decisões de manutenção.
- **Quantificação de incerteza:** Incorporar estruturas bayesianas para quantificar a confiança nas decisões de detecção de falhas e reduzir alarmes falsos.

O objetivo final é desenvolver sistemas adaptativos de detecção de falhas com múltiplos métodos, capazes de operar de forma confiável em diversos ambientes industriais, com o mínimo de configuração manual, mantendo ao mesmo tempo altos padrões de confiabilidade.

D. Código Fonte e Reprodutibilidade

Os algoritmos, rotinas de pré-processamento e códigos computacionais implementados para a obtenção dos resultados apresentados neste trabalho estão disponíveis publicamente no repositório [9]. O material inclui scripts desenvolvidos em linguagem Python, estruturados de forma modular, utilizando POO e amplamente comentados para garantir a reprodutibilidade e fins de auditoria científica.

REFERÊNCIAS

- [1] Dayal, B. S., & MacGregor, J. F. (1997). *Improved PLS algorithms*. Journal of Chemometrics, 11(1), 73-85.
- [2] Downs, J. J., & Vogel, E. F. (1993). *A plant-wide industrial process control problem*. Computers & Chemical Engineering, 17(3), 245-255.
- [3] Favoreel, W., De Moor, B., & Van Overschee, P. (2000). *Subspace state space system identification for industrial processes*. Journal of Process Control, 10(2-3), 149-155.
- [4] Gavish, M., & Donoho, D. L. (2014). *The optimal hard threshold for singular values is $4/\sqrt{3}$* . IEEE Transactions on Information Theory, 60(8), 5040-5053.
- [5] Germano, A., Guedes, L. A., Costa, B., & Bezerra, C. (2016). *Deteção de falhas no processo Tennessee Eastman utilizando métricas de tipicidade e excentricidade*. In Proceedings of the 13th International Conference on Control, Automation and Systems (ICCAS), pp. 1000-1005.
- [6] Gertler, J. (1998). *Fault detection and diagnosis in engineering systems*. Marcel Dekker, New York.
- [7] Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems* (2nd ed.). O'Reilly Media, Inc.
- [8] Isermann, R. (2011). *Fault-diagnosis applications: Model-aided diagnosis and fault-tolerant control*. Berlin, Heidelberg: Springer-Verlag.
- [9] S. J. A. Silva, "Atividade 3 - Identificação de Falhas (Sistemas Inteligentes 2026)," *GitHub repository*, 2026. [Online]. Disponível em: <https://github.com/SauloJose/SistemasInteligentes2026/tree/main/Atividade%203%20-%20Identifica%C3%A7%C3%A3o%20de%20Falhas>. Acesso em: 18 mai. 2026.
- [10] Spina, D. E., Campos, L. F. O., de Arruda, W. F., Melo, A., Alves, M. F. S., Rabello, G. L., Anzai, T. K., & Pinto, J. C. (2024). *Comparison of autoencoder architectures for fault detection in industrial processes*. Digital Chemical Engineering, 12, 100162.
- [11] Venkatasubramanian, V., Rengaswamy, R., Yin, K., & Kavuri, S. N. (2003). *A review of process fault detection and diagnosis: Part I. Quantitative model-based methods*. Computers & Chemical Engineering, 27(3), 293-311.
- [12] Yin, S., Ding, S. X., Haghani, A., Hao, H., & Zhang, P. (2012). *A comparison study of basic data-driven fault diagnosis and process monitoring methods on the benchmark Tennessee Eastman process*. Journal of Process Control, 22(9), 1567-1581.



Saulo José Almeida Silva Técnico em Instalações Elétricas pelo Instituto Federal de Alagoas (IFAL, 2021). Bacharel em Engenharia Elétrica com ênfase em Instalações Elétricas pelo IFAL (2026). Especialização em Automação Industrial pela Eduno. Atualmente é mestrando em Engenharia Elétrica na Universidade Federal de Campina Grande (UFCG), atuando na área de Robótica com foco em coordenação de sistemas robóticos heterogêneos.