

Rastreamento Bidimensional de Alvos via Filtro de Kalman Estendido em Sistemas de Posicionamento por Estações Base

Saulo José Almeida Silva, *Mestrando, UFCG,*

Resumo—A localização precisa é um requisito fundamental para a operação autônoma de sistemas robóticos móveis. Este trabalho apresenta o desenvolvimento, a implementação e a análise rigorosa de um Filtro de Kalman Estendido (EKF) aplicado ao rastreamento bidimensional de alvos utilizando medições não lineares de distância (*range-only*). Fundamentado em um modelo cinemático de Posição-Velocidade-Aceleração (PVA), o estimador foi avaliado por meio de um ambiente de simulação em Python. A arquitetura viabiliza o monitoramento contínuo da acurácia posicional (RMSE), da consistência estatística via *Normalized Innovation Squared* (NIS) e da validação espacial de crença através da Taxa de *Inliers*. Os resultados demonstram que, sob sintonia adequada das matrizes de processo ($\mathbf{Q}$) e medição ($\mathbf{R}$), o EKF atinge precisão submétrica e robustez contra oclusões temporárias. Em contraste, a descalibração paramétrica revela um desacoplamento perigoso: subestimar $\mathbf{R}$ gera falsas altas taxas de *inliers* enquanto corrompe o NIS, e subestimar $\mathbf{Q}$ induz a atrasos de fase severos. Conclui-se que cruzar métricas geométricas e estatísticas é imperativo para atestar a verdadeira confiabilidade do filtro.

Index Terms—Filtro de Kalman Estendido, Localização em Tempo Real, Posicionamento *Range-Only*, Consistência Estatística.

I. INTRODUÇÃO

A O passo que os sistemas robóticos autônomos assumem tarefas mais complexas, cresce também a exigência por soluções de navegação precisas e confiáveis. Para mitigar as incertezas inerentes a esse processo, a literatura tem apostado fortemente em arquiteturas de fusão sensorial — que combinam dados de múltiplos sensores — associadas a análises estatísticas das medições. Essa integração tem se mostrado essencial para refinar a estimativa de estado do sistema e viabilizar sua aplicação no mundo real [1], [2].

O grande desafio no desenvolvimento dessas soluções de localização está nos erros instrumentais e nos ruídos estocásticos que afetam a dinâmica do robô. Mesmo sob uma modelagem cinemática detalhada, perturbações ambientais e não-linearidades — presentes tanto na resposta física dos sensores quanto na própria dinâmica veicular — acabam inserindo margens inevitáveis de imprecisão no estado estimado.

Para contornar essa limitação e obter estimativas de alta fidelidade, utiliza-se o Filtro de Kalman (KF), um estimador ótimo iterativo para sistemas lineares sob o critério do erro quadrático mínimo [3]. Como parte da família dos filtros

bayesianos, o KF estima variáveis de estado não mensuradas diretamente, o que viabiliza sua aplicação em cenários de observabilidade incompleta [4]. Essa formulação clássica, no entanto, é limitada em sistemas de posicionamento baseados em distância (alcance), cujas equações de observação são essencialmente não-lineares. Nesses cenários, aplica-se o Filtro de Kalman Estendido (EKF), que contorna a não linearidade por meio da linearização do modelo em torno da estimativa corrente [4], [5].

Embora o EKF possua uma fundamentação teórica consolidada, seu sucesso prático depende diretamente do ajuste das matrizes de covariância do processo ($\mathbf{Q}$) e de medição ($\mathbf{R}$). A sintonia desses parâmetros requer simulações computacionais detalhadas, etapa essencial no desenvolvimento de sistemas de navegação. Um exemplo dessa abordagem é o trabalho de Falek e Kaniewski [6], que propuseram um ambiente em MATLAB para avaliar o comportamento do EKF em redes de posicionamento baseadas em estações fixas.

Nesse contexto, este trabalho apresenta um simulador em Python voltado à análise do rastreamento bidimensional de alvos via quatro estações base. A ferramenta integra uma GUI interativa para avaliar a acurácia posicional (RMSE), a consistência estatística (NIS) e o comportamento da crença do robô (Taxa de *Inliers*). Para detalhar essa abordagem, o artigo está estruturado da seguinte forma: a Seção II revisa a fundamentação do EKF; a Seção III detalha a modelagem cinemática proposta; a Seção IV descreve a metodologia e as métricas de validação; a Seção V discute os resultados comparativos de sintonia; e a Seção VI apresenta as conclusões e trabalhos futuros.

A. Notação e Convenções

Neste trabalho, adota-se a seguinte convenção de notação: escalares são representados por letras minúsculas em itálico (a), vetores por minúsculas em negrito ($\mathbf{a}$ ou $\hat{\mathbf{x}}$) e matrizes por maiúsculas em negrito ($\mathbf{A}$ ou $\mathbf{P}$).

No domínio discreto, o subscrito k denota a variável física real no instante de tempo atual (como o estado $\mathbf{x}_k$ ou a medição $\mathbf{z}_k$). Por outro lado, os estados e as covariâncias calculados pelo estimador utilizam uma notação composta:

- $k|k-1$: indica os valores *a priori* (etapa de predição), computados a partir do histórico do sistema até o instante $k-1$, tais como o estado predito $\hat{\mathbf{x}}_{k|k-1}$ e a covariância do erro $\mathbf{P}_{k|k-1}$.
- $k|k$: representa os valores *a posteriori* (etapa de correção), atualizados após a incorporação da nova

medição, tais como o estado corrigido $\hat{\mathbf{x}}_{k|k}$ e a covariância do erro $\mathbf{P}_{k|k}$.

II. REVISÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo apresenta a base teórica para o problema de estimativa de estados em robótica. O texto parte da modelagem determinística ideal e avança para os filtros probabilísticos usados na mitigação de incertezas em sistemas reais. Inicialmente, são apresentados os conceitos de sistemas dinâmicos e as fontes de ruído que afetam o comportamento do robô. Em seguida, introduz-se a definição de crença (*belief*) sob a suposição de Markov, o que fundamenta a relação geométrica entre a matriz de covariância e a região de incerteza do agente. Por fim, são discutidos o modelo Gauss-Markov, a discretização temporal, as formulações do Filtro de Kalman (Linear e Estendido) e as métricas para validação do estimador.

A. Sistemas Dinâmicos e Modelagem Determinística

A modelagem de robôs móveis para navegação e controle costuma utilizar a representação em espaço de estados. No domínio do tempo contínuo, a evolução do vetor de estados ocultos $\mathbf{x}(t) \in \mathbb{R}^n$ e as medições ideais do sistema são descritas por equações diferenciais e algébricas [7], na forma:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t)) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{h}(\mathbf{x}(t)) \quad (1)$$

onde $\mathbf{u}(t) \in \mathbb{R}^m$ é o vetor de entradas de controle e $\mathbf{z}(t) \in \mathbb{R}^d$ é o vetor de medições. Se as funções $\mathbf{f}$ e $\mathbf{h}$ forem lineares, o sistema pode ser escrito em sua forma canônica:

$$\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t) \quad \text{e} \quad \mathbf{z}(t) = \mathbf{H}_c \mathbf{x}(t) \quad (2)$$

As matrizes $\mathbf{A}_c$, $\mathbf{B}_c$ e $\mathbf{H}_c$ definem a dinâmica, a entrada e a observação contínuas [7]. Essa abordagem determinística assume sensores perfeitos e um modelo físico exato, desconsiderando os ruídos e distúrbios comuns em ambientes reais.

B. Sistemas Estocásticos e Fontes de Incerteza

Na prática, os sistemas robóticos sofrem perturbações que inviabilizam o uso de modelos puramente determinísticos. Essas incertezas vêm de duas fontes principais [2]:

- 1) **Ruído de Processo (ϵ):** Representa distúrbios dinâmicos, forças ambientais (como atrito variante, irregularidades no solo e correntes de ar) e erros de modelagem que afetam a locomoção do robô.
- 2) **Ruído de Medição (δ):** Agrupa as incertezas dos próprios sensores. Em sistemas de localização por radiofrequência ou acústicos, decorre de efeitos de multicaminho, ruído térmico nos circuitos, atenuação de sinal e falhas de calibração [8].

Com a inclusão desses ruídos, o estado deixa de ser um ponto exato e passa a ser tratado como uma variável aleatória. A evolução temporal do sistema e as leituras dos sensores passam a ser modeladas por densidades de probabilidade condicionais:

$$\mathbf{x}_k \sim P(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (3)$$

$$\mathbf{z}_k \sim P(\mathbf{z}_k \mid \mathbf{x}_k) \quad (4)$$

onde $k \in \mathbb{N}$ indica o passo de tempo discreto. O tratamento matemático dessas incertezas garante que os estimadores operem de forma estável mesmo sob condições severas [6].

C. Robótica Probabilística, Suposição de Markov e a Crença (*Belief*)

Para lidar com as incertezas de modelos e sensores, a robótica probabilística calcula a crença (*belief*) do robô a respeito de seu próprio estado. O *belief* é a distribuição de probabilidade a posteriori do vetor de estados $\mathbf{x}_k$, condicionada ao histórico de comandos enviados e medições recebidas [4]:

$$\text{bel}(\mathbf{x}_k) = P(\mathbf{x}_k \mid \mathbf{z}_{1:k}, \mathbf{u}_{1:k}) \quad (5)$$

Para viabilizar o cálculo dessa distribuição em tempo real, aplica-se a **Suposição de Markov**. Esse postulado assume que o estado atual $\mathbf{x}_k$ é uma estatística suficiente do sistema, contendo toda a informação do passado. Assim, o estado futuro depende apenas do estado presente e da ação atual, o que simplifica a probabilidade condicional para:

$$P(\mathbf{x}_k \mid \mathbf{x}_{1:k-1}, \mathbf{u}_{1:k}, \mathbf{z}_{1:k-1}) = P(\mathbf{x}_k \mid \mathbf{x}_{k-1}, \mathbf{u}_k) \quad (6)$$

A propriedade de Markov permite dividir o cálculo do *belief* de forma recursiva em duas etapas: predição e correção, que formam a estrutura dos filtros de estimação sequenciais [4].

D. O Modelo Gauss-Markov

O cálculo das distribuições probabilísticas torna-se tratável quando o sistema segue o Modelo Gauss-Markov. Esse modelo define um processo que obedece à propriedade de Markov e cujos ruídos de processo e medição (ϵ_k e δ_k) são gaussianos, brancos e com média nula [9].

A principal vantagem dessa modelagem está na conservação das propriedades estatísticas: transformações lineares aplicadas a variáveis gaussianas geram novas variáveis gaussianas [8]. Com isso, o *belief* $\text{bel}(\mathbf{x}_k)$ permanece estritamente gaussiano ao longo do tempo.

Como uma distribuição gaussiana é definida apenas pelo seu vetor de médias ($\hat{\mathbf{x}}$) e por sua matriz de covariância ($\mathbf{P}$), o problema de rastrear uma função contínua de dimensão infinita resume-se a atualizar esses dois parâmetros a cada passo de tempo discreto.

E. Discretização do Sistema e das Covariâncias

Embora os modelos cinemáticos baseiem-se no tempo contínuo (t), os processadores digitais operam em intervalos discretos Δt . Considerando o vetor de controle $\mathbf{u}(t)$ constante dentro de cada intervalo de amostragem, o sistema linear contínuo $\dot{\mathbf{x}}(t) = \mathbf{A}_c \mathbf{x}(t) + \mathbf{B}_c \mathbf{u}(t)$ é convertido para sua forma discreta equivalente sob o modelo Gauss-Markov [9]:

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (7)$$

As matrizes discretas de transição de estados ($\mathbf{A}_k$) e de entrada ($\mathbf{B}_k$) são obtidas a partir das matrizes contínuas pelas relações:

$$\mathbf{A}_k = e^{\mathbf{A}_c \Delta t} \quad \text{e} \quad \mathbf{B}_k = \left(\int_0^{\Delta t} e^{\mathbf{A}_c \tau} d\tau \right) \mathbf{B}_c \quad (8)$$

Discretização das Covariâncias de Ruído: A amostragem digital também exige a discretização das matrizes de covariância dos ruídos [9]. A matriz de covariância do ruído de processo contínuo, $\mathbf{Q}_c$, propaga-se de acordo com a própria dinâmica do sistema. A matriz discreta equivalente, $\mathbf{Q}_k$, é calculada pela integral:

$$\mathbf{Q}_k = \int_0^{\Delta t} e^{\mathbf{A}_c \tau} \mathbf{Q}_c e^{\mathbf{A}_c^T \tau} d\tau \quad (9)$$

Para taxas de amostragem altas ($\Delta t \ll 1$), pode-se aproximar essa relação por $\mathbf{Q}_k \approx \mathbf{Q}_c \Delta t$, assumindo um crescimento linear da incerteza [9]. No entanto, em modelos cinemáticos de ordem superior — como o espaço de estados Posição-Velocidade-Aceleração (PVA) deste trabalho —, a resolução analítica da Equação (9) é necessária para manter o acoplamento cruzado das incertezas, gerando os termos polinomiais apresentados na Seção III.

Extensão para Sistemas Não Lineares: Se a dinâmica do sistema contínuo for não linear, utilizam-se métodos de integração numérica para a discretização. O método de Euler, por exemplo, resulta na aproximação:

$$\mathbf{x}_k \approx \mathbf{x}_{k-1} + f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) \Delta t \quad (10)$$

Para propagar a incerteza gaussiana nesses casos, o modelo aproximado deve ser linearizado localmente por meio de matrizes Jacobianas a cada passo k [4].

F. Filtros de Estimação Baseados em Kalman

O Filtro de Kalman é a solução ótima para propagar e corrigir o *belief* gaussiano em sistemas lineares sob a suposição de Markov. O algoritmo não estima o estado como um ponto fixo, mas rastreia os parâmetros que definem sua distribuição de probabilidade.

1) *Filtro de Kalman Linear:* Com base no modelo Gauss-Markov discreto, a dinâmica e o modelo de observação incorporam os ruídos de processo (ϵ_k) e medição (δ_k):

$$\mathbf{x}_k = \mathbf{A}_k \mathbf{x}_{k-1} + \mathbf{B}_k \mathbf{u}_k + \epsilon_k \quad (11)$$

$$\mathbf{z}_k = \mathbf{H}_k \mathbf{x}_k + \delta_k \quad (12)$$

onde $\epsilon_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ e $\delta_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$. O filtro calcula recursivamente o estado corrigido $\hat{\mathbf{x}}_{k|k}$ (média) e sua matriz de covariância $\mathbf{P}_{k|k}$ (incerteza). O processo é dividido em etapas de predição e correção, conforme descrito no Algoritmo 1 [4].

Algorithm 1 Filtro de Kalman Linear

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow \mathbf{A}_k \hat{\mathbf{x}}_{k-1|k-1} + \mathbf{B}_k \mathbf{u}_k$$

$$2: \mathbf{P}_{k|k-1} \leftarrow \mathbf{A}_k \mathbf{P}_{k-1|k-1} \mathbf{A}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$3: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$4: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

Se houver oclusão de sinal ou indisponibilidade dos sensores, a etapa de correção (linhas 4 a 6) não é executada. Nessas situações, o filtro opera em malha aberta apenas com a predição cinemática. Como consequência, a covariância $\mathbf{P}_{k|k-1}$ cresce a cada passo, resultando no aumento contínuo do ROI Dinâmico.

2) *Filtro de Kalman Estendido (EKF):* Quando o sistema de localização utiliza distâncias radiais em relação a estações com coordenadas conhecidas, as equações de observação tornam-se não lineares devido à geometria do problema. Nesses cenários, utiliza-se o Filtro de Kalman Estendido (EKF) [4], que aceita funções não lineares genéricas g e h :

$$\mathbf{x}_k = g(\mathbf{u}_k, \mathbf{x}_{k-1}) + \epsilon_k \quad (13)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \delta_k \quad (14)$$

Para propagar as matrizes de incerteza, o algoritmo utiliza uma expansão em série de Taylor de primeira ordem. Essa linearização local exige o cálculo das matrizes Jacobianas $\mathbf{G}_k$ e $\mathbf{H}_k$ em torno das estimativas atuais:

$$\mathbf{G}_k = \left. \frac{\partial g(\mathbf{u}_k, \mathbf{x}_{k-1})}{\partial \mathbf{x}_{k-1}} \right|_{\mathbf{x}_{k-1} = \hat{\mathbf{x}}_{k-1|k-1}} \quad (15)$$

$$\mathbf{H}_k = \left. \frac{\partial h(\mathbf{x}_k)}{\partial \mathbf{x}_k} \right|_{\mathbf{x}_k = \hat{\mathbf{x}}_{k|k-1}} \quad (16)$$

Essas matrizes Jacobianas substituem as matrizes fixas do caso linear na propagação das incertezas e no cálculo do ganho de Kalman ($\mathbf{K}_k$), permitindo o rastreamento em sistemas com não linearidades geométricas (Algoritmo 2).

Algorithm 2 Filtro de Kalman Estendido (EKF)

Require: $\hat{\mathbf{x}}_{k-1|k-1}, \mathbf{P}_{k-1|k-1}, \mathbf{u}_k, \mathbf{z}_k$

Predição (Propagação do Modelo):

$$1: \hat{\mathbf{x}}_{k|k-1} \leftarrow g(\mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$2: \mathbf{G}_k \leftarrow \text{Jacobiano}(g, \mathbf{u}_k, \hat{\mathbf{x}}_{k-1|k-1})$$

$$3: \mathbf{P}_{k|k-1} \leftarrow \mathbf{G}_k \mathbf{P}_{k-1|k-1} \mathbf{G}_k^T + \mathbf{Q}_k$$

Correção (Atualização pela Medição):

$$4: \mathbf{H}_k \leftarrow \text{Jacobiano}(h, \hat{\mathbf{x}}_{k|k-1})$$

$$5: \mathbf{K}_k \leftarrow \mathbf{P}_{k|k-1} \mathbf{H}_k^T (\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k)^{-1}$$

$$6: \hat{\mathbf{x}}_{k|k} \leftarrow \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k (\mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}))$$

$$7: \mathbf{P}_{k|k} \leftarrow (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k) \mathbf{P}_{k|k-1} (\mathbf{I} - \mathbf{K}_k \mathbf{H}_k)^T + \mathbf{K}_k \mathbf{R}_k \mathbf{K}_k^T$$

Ensure: $\hat{\mathbf{x}}_{k|k}, \mathbf{P}_{k|k}$

G. Métricas de Avaliação e Consistência Estocástica

O desempenho do estimador é avaliado por meio de métricas de precisão geométrica e testes estatísticos baseados nos resíduos da inovação [8].

1) *Root Mean Square Error (RMSE)*: A precisão geométrica espacial nas trajetórias bidimensionais é medida pela Raiz do Erro Quadrático Médio (RMSE). O RMSE calcula a distância euclidiana média entre o estado real $\mathbf{x}_k$ e o estado corrigido $\hat{\mathbf{x}}_{k|k}$ em um horizonte de N amostras:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{k=1}^N \|\mathbf{x}_k - \hat{\mathbf{x}}_{k|k}\|^2} \quad (17)$$

Essa métrica também pode ser calculada de forma independente para os eixos cartesianos (X e Y) para identificar a direção de eventuais falhas de rastreamento.

2) *Normalized Innovation Squared (NIS)*: A precisão medida pelo RMSE não garante que o estimador seja consistente do ponto de vista estatístico. Um filtro é consistente se seus erros de estimação tiverem média nula e covariância compatível com os valores teóricos calculados pelo próprio algoritmo [8]. O teste do quadrado da inovação normalizada (NIS) verifica se a incerteza estimada na matriz $\mathbf{P}_k$ condiz com o comportamento real das medições.

A inovação $\boldsymbol{\nu}_k \in \mathbb{R}^d$ representa a diferença entre a medição real e a predição calculada pelo filtro:

$$\boldsymbol{\nu}_k = \mathbf{z}_k - h(\hat{\mathbf{x}}_{k|k-1}) \quad (18)$$

A matriz de covariância teórica da inovação, obtida na etapa de correção, é dada por:

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k \quad (19)$$

O escalar NIS (ϵ_k) é calculado pela forma quadrática baseada na distância de Mahalanobis:

$$\epsilon_k = \boldsymbol{\nu}_k^T \mathbf{S}_k^{-1} \boldsymbol{\nu}_k \quad (20)$$

Se o modelo cinemático e as matrizes de ruído ($\mathbf{Q}_k$ e $\mathbf{R}_k$) estiverem corretos, a variável ϵ_k segue uma distribuição Qui-Quadrado (χ^2) com n_z graus de liberdade, onde n_z é a dimensão do vetor de medições $\mathbf{z}_k$ [8].

Quando o histograma empírico dos resultados se mantém dentro dos limites de aceitação da distribuição Qui-Quadrado, o filtro e o ROI Dinâmico são considerados consistentes. Desvios prolongados para fora desses limites indicam erros de parametrização, sinalizando que o filtro está subestimando ou superestimando as incertezas reais do sistema [8].

III. FORMULAÇÃO DO PROBLEMA E MODELAGEM DO SISTEMA

Para analisar o comportamento do EKF quanto à convergência, ajuste de parâmetros e consistência estatística, este estudo delinea um cenário de rastreamento bidimensional baseado exclusivamente em dados de distância (*range-only tracking*) [8]. Essa modelagem expande o método sugerido em [6], descrevendo a movimentação do agente por meio de um modelo cinemático estruturado no espaço de estados de Posição, Velocidade e Aceleração (PVA).

A. Descrição do Problema

O problema abordado consiste em estimar a trajetória de um robô móvel que opera em um plano bidimensional. O agente se desloca dentro de uma arena monitorada por uma infraestrutura de localização local, composta por $M = 4$ estações fixas (âncoras) instaladas em posições conhecidas, denotadas por $\mathbf{p}_i = [X_i, Y_i]^T$ para $i = 1, \dots, 4$. O arranjo completo desse ambiente operacional encontra-se esquematizado na Figura 1.

O robô não possui sensores de odometria ou de velocidade própria, dependendo exclusivamente de medições escalares de distância obtidas via radiofrequência ou ondas acústicas em relação a cada uma das estações. O objetivo do estimador é processar essas observações ruidosas e reconstruir, a cada passo temporal, a posição horizontal (X) e vertical (Y) do agente, estimando também suas componentes de velocidade e aceleração instantâneas.




Figura 1: Representação geométrica do sistema de posicionamento: o agente móvel no espaço bidimensional e os raios de medição (*range-only*) oriundos das quatro estações base fixas nos vértices da arena.

B. Modelo Cinemático de Processo (Espaço de Estados PVA)

Diferentemente de abordagens simplificadas de velocidade constante, o estado do agente móvel no instante discreto k passa a ser representado por um vetor expandido de seis dimensões: $\mathbf{x}_k = [x_k, y_k, v_{x,k}, v_{y,k}, a_{x,k}, a_{y,k}]^T$. Nessa estrutura, (x_k, y_k) correspondem às coordenadas de posição cartesiana, $(v_{x,k}, v_{y,k})$ às componentes da velocidade linear e $(a_{x,k}, a_{y,k})$ às acelerações instantâneas nos eixos X e Y , respectivamente.

A dinâmica temporal do sistema sob regime de aceleração constante (CA) é integrada ao longo do intervalo de amostragem Δt . Essa operação dá origem à matriz de transição de estados $\mathbf{A}_k$ (6×6), especificada na Equação (21):

$$\mathbf{A}_k = \begin{bmatrix} 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} & 0 \\ 0 & 1 & 0 & \Delta t & 0 & \frac{\Delta t^2}{2} \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \quad (21)$$

Fatores práticos como o escorregamento de rodas, desalinhamentos mecânicos e irregularidades do terreno introduzem erros cumulativos na navegação [4]. Na formulação PVA escolhida, esse comportamento estocástico é transposto para o modelo admitindo que as perturbações ajam de forma independente sobre os componentes de posição, velocidade e aceleração. Essas fontes de incerteza são sintetizadas pela matriz de densidade espectral de potência contínua $\mathbf{Q}_c = \text{diag}(q_1, q_2, q_3, q_4, q_5, q_6)$.

Ao calcular a discretização analítica desse termo, ponderada pela própria dinâmica veicular no intervalo Δt , obtém-se uma matriz de covariância discreta $\mathbf{Q}_k$ caracterizada por ser esparsa e simétrica. O perfil estritamente diagonal de $\mathbf{Q}_c$ garante o desacoplamento estocástico entre as dinâmicas dos eixos horizontal (X) e vertical (Y). Os elementos não nulos associados aos estados do eixo X (índices 0, 2 e 4) são calculados conforme as relações dispostas na Equação (22):

$$\begin{cases} Q_{0,0} = q_1 \Delta t + q_3 \frac{\Delta t^3}{3} + q_5 \frac{\Delta t^5}{20} \\ Q_{0,2} = Q_{2,0} = q_3 \frac{\Delta t^2}{2} + q_5 \frac{\Delta t^4}{8} \\ Q_{0,4} = Q_{4,0} = q_5 \frac{\Delta t^3}{6} \\ Q_{2,2} = q_3 \Delta t + q_5 \frac{\Delta t^3}{3} \\ Q_{2,4} = Q_{4,2} = q_5 \frac{\Delta t^2}{2} \\ Q_{4,4} = q_5 \Delta t \end{cases} \quad (22)$$

De maneira análoga, os componentes vinculados ao eixo Y (índices 1, 3 e 5) replicam essa mesma estrutura algébrica, utilizando as variâncias espectrais específicas $\{q_2, q_4, q_6\}$ detalhadas na Equação (23):

$$\begin{cases} Q_{1,1} = q_2 \Delta t + q_4 \frac{\Delta t^3}{3} + q_6 \frac{\Delta t^5}{20} \\ Q_{1,3} = Q_{3,1} = q_4 \frac{\Delta t^2}{2} + q_6 \frac{\Delta t^4}{8} \\ Q_{1,5} = Q_{5,1} = q_6 \frac{\Delta t^3}{6} \\ Q_{3,3} = q_4 \Delta t + q_6 \frac{\Delta t^3}{3} \\ Q_{3,5} = Q_{5,3} = q_6 \frac{\Delta t^2}{2} \\ Q_{5,5} = q_6 \Delta t \end{cases} \quad (23)$$

C. Modelo de Observação e Geometria das Estações Base

A partir do arranjo de infraestrutura detalhado na Seção III-A, o vetor de observações obtido a cada passo amostral é estruturado como $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$. A relação geométrica entre o estado cinemático estimado do robô e a distância escalar real até a i -ésima estação fixa é governada por uma função de observação não linear $h_i(\mathbf{x}_k)$, descrita na Equação (24):

$$h_i(\mathbf{x}_k) = \sqrt{(x_k - X_i)^2 + (y_k - Y_i)^2} \quad (24)$$

Como o vetor de estado possui seis dimensões e as leituras dependem estritamente das coordenadas de posição (x_k, y_k) ,

as derivadas parciais da função de medição associadas aos componentes de velocidade e aceleração anulam-se por completo [8]. Sob essas condições, a matriz Jacobiana $\mathbf{H}_k$ (4×6) avaliada a cada iteração assume o formato estabelecido na Equação (25):

$$\mathbf{H}_k = \begin{bmatrix} \frac{x_k - X_1}{h_1(\mathbf{x}_k)} & \frac{y_k - Y_1}{h_1(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \frac{x_k - X_4}{h_4(\mathbf{x}_k)} & \frac{y_k - Y_4}{h_4(\mathbf{x}_k)} & 0 & 0 & 0 & 0 \end{bmatrix}_{\mathbf{x}_k = \hat{\mathbf{x}}_k | k-1} \quad (25)$$

Para concluir a modelagem matemática do sensor, a matriz de covariância do ruído de medição é definida como $\mathbf{R}_k = \text{diag}(\sigma_1^2, \sigma_2^2, \sigma_3^2, \sigma_4^2)$, em que cada termo diagonal reflete a variância do erro instrumental intrínseco de sua respectiva âncora de leitura.

D. Cenário de Desafio: Modelagem de Oclusão Temporal

Para avaliar os limites do estimador e a utilidade prática da região de interesse (ROI) dinâmica e do teste NIS, projetou-se uma janela de oclusão severa no ambiente de simulação. Dentro de um intervalo cronometrado $t \in [t_{\text{start}}, t_{\text{end}}]$, as leituras vindas das quatro estações base são intencionalmente suprimidas ($\mathbf{z}_{i,k} \rightarrow \emptyset$).


Esse bloqueio — cujo comportamento é ilustrado na Figura 2 — força o algoritmo a depender apenas das projeções geradas pela matriz de transição PVA (21). Sob condições normais de operação com o filtro atualizando as medições, a elipse mantém-se estável e restrita (Figura 2a). Contudo, sem o suporte das correções trazidas pelos sensores durante a oclusão, as incertezas de aceleração modeladas em $\mathbf{Q}_k$ acumulam-se rapidamente. O resultado direto é uma expansão geométrica acentuada na matriz de covariância predita ($\mathbf{P}_{k|k-1}$), que se traduz no alargamento progressivo da elipse de confiança (ROI) ao longo do deslocamento do robô, variando conforme a trajetória realizada (Figuras 2b e 2c).

IV. METODOLOGIA E EXPERIMENTAÇÃO

Este capítulo detalha a metodologia utilizada para avaliar o desempenho, a sensibilidade e a robustez à oclusão do estimador proposto. A apresentação segue a ordem lógica dos experimentos: inicialmente, descreve-se a geração cinemática das trajetórias de referência. Em seguida, detalham-se os cenários de teste e a modelagem do filtro. Por fim, definem-se as métricas estatísticas aplicadas na avaliação do Filtro de Kalman Estendido (EKF) sob diferentes parametrizações.

A. Síntese Cinemática das Trajetórias de Referência

Para que a precisão do Filtro de Kalman Estendido (EKF) possa ser avaliada, é indispensável compará-lo a um referencial absoluto e livre de ruídos, o *Ground Truth*. Nessa etapa, o simulador atua como um gerador de gabaritos: ele calcula a física exata do alvo para cada instante discreto k e armazena essas informações no vetor de estado $\mathbf{x}_k = [p_x, p_y, v_x, v_y, a_x, a_y]^T$, que engloba as posições, velocidades e acelerações reais nos eixos ortogonais.



(a) Operação nominal: predição e atualização. (b) Oclusão: trajetória 1 (predição pura). (c) Oclusão: trajetória 2 (predição pura).

Figura 2: Representação visual da incerteza do EKF (ROI dinâmica): a elipse em cinza denota a incerteza predita ($\mathbf{P}_{k|k-1}$), enquanto a elipse em verde representa a incerteza atualizada após a correção ($\mathbf{P}_{k|k}$). (a) Regime de operação estável sob observações contínuas; (b) e (c) expansão da incerteza e degradação da precisão decorrentes da supressão das medições (occlusão temporal) em distintos perfis de trajetória.

Como um alvo em uma aplicação real pode apresentar desde um trajeto altamente previsível até manobras bruscas, o simulador foi projetado para testar os limites do estimador utilizando duas abordagens distintas de movimento:

- **Curvas paramétricas analíticas (Determinísticas):** Simulam cenários onde o alvo obedece a regras geométricas bem definidas e contínuas. Servem para testar o filtro sob dinâmicas estáveis e previsíveis.
- **Modelos numéricos comportamentais (Estocásticos):** Inserem aleatoriedade na navegação do alvo. Servem para testar a capacidade de adaptação do EKF quando o objeto realiza trajetórias erráticas ou mudanças repentinas de direção.

O conjunto completo dessas trajetórias, abrangendo todos os perfis cinemáticos abordados nos testes, pode ser visualizado na Figura 3.

1) *Geração de Curvas Paramétricas e Analíticas:* Para os testes com movimentos contínuos e regulares, as posições do alvo no simulador são ditadas por funções trigonométricas e hiperbólicas dependentes do tempo. Um cuidado fundamental nessa etapa foi evitar o cálculo numérico das derivadas. Para garantir que o *Ground Truth* seja matematicamente exemplar e livre de erros de discretização, a velocidade e a aceleração do alvo são extraídas a partir da diferenciação analítica exata das equações de posição, conforme detalha o Algoritmo 3.

As trajetórias com quinas, como o percurso quadrado, obedecem a esse mesmo rigor determinístico. A única diferença é que a modelagem utiliza segmentos de reta conectados para formar as arestas, aplicando-se uma restrição geométrica de fechamento para garantir que o alvo retorne exatamente à coordenada onde iniciou o percurso.

2) *Geração de Navegação Aleatória e Oclusões:* Para aproximar a simulação do comportamento estocástico de um alvo real, desenvolveu-se um algoritmo de navegação aleatória. O agente (UGV - Unmanned Ground Vehicle) move-se em linha reta por distâncias mínimas antes de realizar deflexões suaves. Se o robô atinge os limites da arena (raio superior a 35 metros), um mecanismo de evasão direciona o movimento de volta ao centro, mantendo o robô na área útil.

Algorithm 3 Geração de Trajetórias Paramétricas Analíticas

Require: Tempo contínuo $t_k = k\Delta t$, Parâmetros geométricos (Amplitude A , Frequência ω)

```

1: for cada instante  $k$  do
2:   if Perfil = Circular then
3:      $\mathbf{p}_k \leftarrow [c_x + R \cos(\omega t_k), c_y + R \sin(\omega t_k)]^T$ 
4:   else if Perfil = Mudança de Faixa (Tanh) then
5:      $\mathbf{p}_k \leftarrow [v_x t_k, c_y + A \tanh(S \cdot t_k)]^T$ 
6:   else if Perfil = Lemniscata then
7:      $\mathbf{p}_k \leftarrow [c_x + A \sin(\omega t_k), c_y + \frac{A}{2} \sin(2\omega t_k)]^T$ 
8:   end if
9:    $\mathbf{v}_k \leftarrow \frac{d}{dt} \mathbf{p}_k$ 
10:   $\mathbf{a}_k \leftarrow \frac{d}{dt} \mathbf{v}_k$ 
11:   $\mathbf{x}_k \leftarrow [\mathbf{p}_k^T, \mathbf{v}_k^T, \mathbf{a}_k^T]^T$ 
12: end for

```

Ensure: Sequência de estados reais $\mathbf{x}_{1:N}$

Como as mudanças de direção são aleatórias, a aceleração de referência é calculada por diferenciação numérica discreta, conforme estruturado no Algoritmo 4.

B. Cenários de Simulação e Estratégia de Sintonia

Para avaliar o estimador na prática, a campanha de testes foi dividida em **6 cenários cinemáticos** (ilustrados na Figura 3), abrangendo diferentes perfis de aceleração e condições de oclusão. Além do movimento do alvo, o comportamento do EKF depende diretamente das suas matrizes de covariância ($\mathbf{Q}_k$ para o processo e $\mathbf{R}_k$ para a medição). Para testar a robustez e a sensibilidade do algoritmo a esses parâmetros, cada cenário foi avaliado sob **duas condições de sintonia distintas**:

- 1) **Situação Sintonizada (Filtro Calibrado):** Representa a condição de funcionamento ideal do rastreador. Os valores das matrizes foram ajustados de forma empírica, baseando-se nas propriedades do ambiente e refinados por tentativa e erro até que o filtro apresentasse o melhor desempenho. A matriz de medição foi definida como $\mathbf{R} = 0,09\mathbf{I}_4$ (quadrado do desvio padrão do ruído das




Figura 3: Visualização bidimensional das trajetórias de referência (*Ground Truth*) geradas pelo motor de simulação para a avaliação do estimador sob diferentes perfis cinemáticos.

Algorithm 4 Geração de Navegação Dinâmica Aleatória

Require: Vetor posição central $\mathbf{p}_c$, Limite da arena $R_{\max}$, Ruído cinemático w

```

1: for cada instante  $k$  do
2:   if Distância percorrida  $> D_{\min}$  then
3:     if  $\|\mathbf{p}_{k-1} - \mathbf{p}_c\| > R_{\max}$  then
4:        $\theta_{\text{alvo}} \leftarrow \text{Ângulo forçado em direção a } \mathbf{p}_c$ 
5:     else
6:        $\theta_{\text{alvo}} \leftarrow \theta_{k-1} + \mathcal{U}(-\frac{\pi}{3}, \frac{\pi}{3})$ 
7:     end if
8:      $v_{\text{alvo}} \leftarrow v_{\text{base}} + \mathcal{U}(-w, w)$ 
9:   end if
10:   $\theta_k \leftarrow \text{SuavizarTransição}(\theta_{k-1}, \theta_{\text{alvo}})$ 
11:   $v_k \leftarrow \text{SuavizarTransição}(v_{k-1}, v_{\text{alvo}})$ 
12:   $\mathbf{v}_k \leftarrow [v_k \cos(\theta_k), v_k \sin(\theta_k)]^T$ 
13:   $\mathbf{p}_k \leftarrow \mathbf{p}_{k-1} + \mathbf{v}_k \Delta t$ 
14:   $\mathbf{a}_k \leftarrow (\mathbf{v}_k - \mathbf{v}_{k-1}) / \Delta t$ 
15: end for

Configuração Especial para Oclusão Cíclica:
16: if Modo Oclusão then
17:   Emite uma máscara binária atribuindo valor Falso
   (Oculito) no segmento temporal central de 4 blocos.
18: end if

```

torres, $\sigma = 0,30$ m), enquanto a matriz de processo foi fixada em $\mathbf{Q} = 0,64\mathbf{I}_6$ ($0,8^2$), assumindo estatisticamente as incertezas de modelagem do movimento. O critério de sucesso foi a minimização do erro de posição aliada a elipses de confiança visualmente e

estatisticamente coerentes com a trajetória real.

- 2) **Situação Não Sintonizada (Filtro Descalibrado):** Representa falhas na configuração do projeto. Nessa etapa, os valores das matrizes foram intencionalmente alterados por superestimação (Sup.) ou subestimação (Sub.). O objetivo de impor essas condições anormais é avaliar a sensibilidade do estimador, demonstrar o impacto do desalinhamento de covariâncias no erro adaptativo e comprovar a importância de uma sintonia rigorosa.

A Tabela I consolida todas as variáveis utilizadas nos testes: a configuração de movimento do alvo, o nível de ruído físico (σ) simulado nos sensores e os valores numéricos utilizados para sintonizar (ou descalibrar) o EKF em cada um dos seis cenários.

C. Configuração do Estimador e Modelagem do Ruído

O objetivo do filtro é estimar o estado completo do alvo (o vetor PVA $\mathbf{x}_k$, detalhado na Seção III). Para alimentar o algoritmo, o sistema mede a distância do robô até quatro estações rádio-base fixadas nos cantos da arena.

Como nenhum sensor no mundo real é perfeito, o simulador precisa "sujar" as medidas ideais do *Ground Truth*. Para imitar a imprecisão real, o sistema injeta um erro aleatório em cada canal: soma-se à distância exata um ruído gaussiano branco de média zero e desvio padrão σ (valores indicados na Tabela I).

Isso resulta no vetor de observação $\mathbf{z}_k = [z_{1,k}, z_{2,k}, z_{3,k}, z_{4,k}]^T$, que contém as quatro distâncias

Tabela I: Parâmetros de Configuração Cinemática e Sintonia das Matrizes (Mundo Simulado vs. Estimador EKF)

Parâmetro	Cenário 1	Cenário 2	Cenário 3	Cenário 4	Cenário 5	Cenário 6
Perfil	Circular	Quadrada	Tanh	Lemniscata	Nav. Aleatória	Oclusão Cíclica
Movimento	$v = 10,0 \text{ m/s}$ $r = 30,0 \text{ m}$	$v = 10 \text{ m/s}$ $L = 40,0 \text{ m}$	$A_y = 20,0 \text{ m}$ $v = 10,0 \text{ m/s}$	$v = 10,0 \text{ m/s}$ $A = 35,0 \text{ m}$	$v_0 = 8,0 \text{ m/s}$ $\epsilon_v = 0,5 \text{ m/s}$	$v = 5,0 \text{ m/s}$ 30 fr/occlusão
Variáveis do Ambiente Simulado (Adição de Ruído Físico)						
Posição das Torres	$B_1[10, 10]; B_2[190, 10]; B_3[190, 130]; B_4[10, 130]$					
Tempo de Simulação	40 s					
Taxa de Quadros (FPS)	30					
Semente Aleatória (Seed)	42					
Ruído nas Torres (σ)	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m	0,30 m
Sintonia do EKF: Condição Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$	$0,09I_4$
Matriz Processo $Q_{6 \times 6}$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$	$0,64I_6$
Sintonia do EKF: Condição Não Sintonizada						
Matriz Medição $R_{4 \times 4}$	$0,1I_4$ (Sup.)	$0,1I_4$ (Sup.)	$0,01I_4$ (Sub.)	$0,09I_4$	$0,01I_4$ (Sub.)	$0,01I_4$ (Sub.)
Matriz Processo $Q_{6 \times 6}$	$0,01I_6$ (Sub.)	$0,01I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,3I_6$ (Sub.)	$0,5I_6$ (Sub.)	$0,05I_6$ (Sub.)

Nota: I_n representa a matriz identidade de dimensão $n \times n$, denotando configurações diagonais. A matriz R apresenta um superdimensionamento conservador intencional ($0,9I_4$), não refletindo estritamente a variância do ruído injetado (σ^2). No Cenário 4 (Não Sintonizado), R foi propositalmente mantido inalterado para isolar e avaliar exclusivamente o efeito da subestimação de Q . (Sup.) = Descalibração por Superestimação; (Sub.) = Descalibração por Subestimação.

ruidosas que o EKF efetivamente recebe como entrada, conforme a Equação (26):

$$z_{i,k} = \|\mathbf{p}_k - \mathbf{p}_i\| + v_{i,k}, \quad v_{i,k} \sim \mathcal{N}(0, \sigma^2) \quad \forall \quad i = 1, \dots, 4 \quad (26)$$

É importante destacar que o EKF trabalha diretamente com essas distâncias puras na sua forma não-linear (z_k). No entanto, para que possamos desenhar a posição lida pelos sensores na interface gráfica do simulador, o sistema realiza um cálculo paralelo. Ele pega essas quatro distâncias com ruído e aplica um algoritmo numérico de multilateração por Mínimos Quadrados para estimar uma coordenada cartesiana $\mathbf{m}_k = [m_{x,k}, m_{y,k}]^T$. Essa coordenada 2D serve estritamente como apoio visual para a tela e para a validação externa, não interferindo nas contas do Filtro de Kalman.

D. Ambiente Computacional e Infraestrutura de Simulação

Para automatizar a execução dos cenários e garantir a reprodutibilidade dos dados, o simulador foi desenvolvido em *Python* (versão 3.10) utilizando uma arquitetura modular, conforme ilustrado na Figura 4. O processamento matricial e a computação vetorizada do EKF foram implementados com a biblioteca *NumPy*.

Conforme detalhado no diagrama, a arquitetura divide-se logicamente entre o núcleo de simulação e a camada de aplicação. O fluxo de execução inicia-se na Interface Gráfica do Usuário (GUI), onde são definidos os parâmetros iniciais, incluindo a sintonia empírica das matrizes de covariância de processo (Q_k) e de ruído de medição (R_k). Esses parâmetros alimentam o bloco *Simulador*, onde o *Gerador de Trajetórias* estabelece a cinemática real do alvo (*ground truth*).

Para avaliar adequadamente a capacidade de estimação do filtro, a trajetória exata é ramificada para dois destinos: o




Figura 4: Diagrama da arquitetura de software da aplicação de simulação, destacando o fluxo de dados entre o gerador de trajetórias, o estimador de estados e a camada de aplicação.

Gerenciador de Métricas (servindo como base de comparação para o cálculo de erros) e a *Modelagem do Mundo e das Entidades*. Este último atua como o simulador do sistema de localização, convertendo as posições reais em distâncias ruidosas relativas a quatro torres (multilateração). Essa pseudo-observação ruidosa alimenta, então, a etapa de *Correção* do Filtro de Kalman, que trabalha em malha fechada com a *Predição* estocástica.

A GUI, construída nativamente com a biblioteca *Tkinter*, não se limita à parametrização, atuando também na camada de *Aplicação*. Ela integra o *Visualizador de Vídeo* — que renderiza instantaneamente o vetor de observações e a elipse de incerteza da região de interesse (ROI) — e os painéis do *Gerenciador de Métricas*, que acompanham as estatísticas de NIS e RMSE. Apesar dessa integração visual para inspeção qualitativa, o núcleo numérico do simulador opera de forma

independente, garantindo que as campanhas de teste em lote e a geração de arquivos de log ocorram de forma assíncrona e automatizada.

E. Métodos de Avaliação e Consistência

O desempenho do EKF é avaliado pela sua precisão espacial e consistência estatística. A acurácia geométrica é quantificada pela Raiz do Erro Quadrático Médio (RMSE), calculada de forma independente para os eixos X e Y ao comparar as estimativas *a posteriori* ($\hat{x}_{k|k}, \hat{y}_{k|k}$) com o *Ground Truth*. O erro médio com sinal (ME) também é monitorado para identificar eventuais vieses sistemáticos no rastreamento.

Embora a análise espacial meça a exatidão geométrica, ela não garante o equilíbrio estatístico do estimador. Para a validação formal de consistência, utiliza-se o *Normalized Innovation Squared* (NIS). O teste do NIS avalia se a magnitude dos resíduos de inovação é coerente com a incerteza teórica parametrizada nas matrizes de covariância $\mathbf{Q}_k$ e $\mathbf{R}_k$ [8].

1) *Validação da Crença do Estimador (Inlier Rate)*: Como métrica complementar em ambiente de simulação, a convergência da crença (*belief*) do filtro é avaliada graficamente pela taxa de *inliers*. Por depender do *Ground Truth*, essa abordagem restringe-se à calibração e análise do comportamento do modelo frente a dados sintéticos controlados.

Baseando-se no conceito de elipsoide de erro [4], quantifica-se a proporção de frames em que o estado real (x_{GT}, y_{GT}) permanece contido na fronteira de incerteza do filtro. A validação baseia-se na distância de Mahalanobis aplicada sobre a submatriz de covariância de posição *a posteriori* $\mathbf{P}_{\text{pos}} = \mathbf{P}_{k|k}^{(1:2,1:2)}$. Definindo o vetor de erro real como $\tilde{\mathbf{p}}_k = [x_{GT,k} - \hat{x}_{k|k}, y_{GT,k} - \hat{y}_{k|k}]^T$, o estado é classificado como um *inlier* se atender à restrição:

$$\tilde{\mathbf{p}}_k^T (\mathbf{P}_{\text{pos}})^{-1} \tilde{\mathbf{p}}_k \leq M \quad (27)$$

em que M é o valor crítico da distribuição Qui-Quadrado (χ^2) bicaudal com 2 graus de liberdade para o nível de significância adotado.

Para a renderização em tempo real na interface gráfica, a elipse é aproximada por uma janela delimitadora (*bounding box*) baseada no critério 3σ . Os desvios-padrão marginais teóricos são dados por:

$$\sigma_{x,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(1,1)})} \quad (28)$$

$$\sigma_{y,\text{filt}} = \sqrt{\max(10^{-6}, P_{k|k}^{(2,2)})} \quad (29)$$

Os limites semi-eixais da janela visual (L_x, L_y) incorporam uma constante de salvaguarda inferior $\tau_{\min}$ para evitar o colapso da caixa em cenários de incerteza nula ou falhas de inicialização:

$$L_x = \max(\tau_{\min}, 3\sigma_{x,\text{filt}}) \quad (30)$$

$$L_y = \max(\tau_{\min}, 3\sigma_{y,\text{filt}}) \quad (31)$$

A Figura 5 ilustra a correlação espacial entre a elipse probabilística (Equação 27) e a janela ortogonal de renderização (Equações 30 e 31), permitindo aferir qualitativamente se a

dispersão das estimativas é coerente com a evolução da matriz $\mathbf{P}$.

2) *Análise de Estabilidade Estatística via Limites de Confiança do NIS*: Enquanto a taxa de *inliers* atua como um validador visual externo restrito à simulação, o NIS avalia a estabilidade matemática de forma independente do *Ground Truth*, refletindo a operação real do algoritmo. O teste de hipóteses é governado por um intervalo de confiança bicaudal de 95%, cujos graus de liberdade (*DOF*) dependem do número de torres de recepção ativas na multilateração a cada passo de tempo k .

Para um cenário padrão com 4 graus de liberdade (4 *DOF*), os limites críticos da tabela χ^2 são $\chi_{0,025,4}^2 = 0,484$ (inferior) e $\chi_{0,975,4}^2 = 11,143$ (superior). O histórico do NIS permite classificar o comportamento dinâmico do EKF em três regimes:

- **Filtro Consistente**: O NIS oscila predominantemente dentro dos limites calculados. Espera-se que aproximadamente 95% das amostras temporais residam nessa faixa, validando a representação correta da própria incerteza do filtro.
- **Filtro Otimista (Subestimação do Erro)**: O NIS ultrapassa repetidamente o limite superior. Isso indica que os resíduos reais são significativamente maiores do que a covariância calculada em $\mathbf{P}$, sinalizando que o filtro confia excessivamente no modelo preditivo em detrimento das medições, o que gera risco de divergência.
- **Filtro Pessimista (Superestimação do Erro)**: O NIS permanece abaixo do limite inferior. Nesse estado, a matriz de covariância cresce de forma desproporcional aos resíduos de inovação. O filtro torna-se excessivamente conservador e lento para responder a variações dinâmicas do alvo.




Figura 5: Representação da métrica de *inliers*. A elipse valida estatisticamente a convergência frente ao *Ground Truth*, enquanto a janela retangular delimita a incerteza para fins de visualização na GUI.

V. RESULTADOS E DISCUSSÃO

Este capítulo detalha a avaliação experimental do Filtro de Kalman Estendido (EKF) ao longo dos seis cenários de navegação propostos na Seção IV. A análise fundamenta-se em métricas de acurácia posicional (RMSE e Erro Máximo), consistência estatística (NIS) e validação espacial (Taxa de *Inliers*). Para avaliar a sensibilidade do algoritmo, os ensaios comparam o EKF com matrizes calibradas em contraponto a uma configuração intencionalmente descalibrada. A Tabela II consolida os indicadores quantitativos obtidos na simulação.

Devido a restrições de formatação, as composições gráficas completas (painéis comparativos de todas as trajetórias estimadas e históricos da métrica NIS para os seis cenários) foram alocadas no **Apêndice B**. Além disso, o código-fonte do simulador, os dados brutos e as imagens em alta resolução estão publicamente disponíveis no repositório do projeto no GitHub¹.

A. Interface Gráfica e Ambiente de Simulação

A Figura 6 exibe o ambiente de simulação desenvolvido para este estudo. A interface gráfica integra a renderização espacial da arena, a telemetria das posições estimadas face ao *ground truth* e os painéis de monitoramento temporal de RMSE e NIS. Essa estrutura permite a manipulação direta das matrizes de covariância **Q** e **R**, viabilizando a análise empírica do impacto da calibração nas elipses de incerteza do filtro.

B. Análise de Acurácia Posicional e Distribuição de Erros

A parametrização do EKF apresentou correlação direta com a mitigação do ruído de observação. Conforme os dados consolidados na Tabela II e as trajetórias detalhadas no Apêndice B, a configuração sintonizada manteve o RMSE_x e o RMSE_y em níveis sub-métricos estritos, com erros em *X* variando entre 0,11m e 0,13m, e em *Y* entre 0,14m e 0,18m nos cenários de visibilidade total. No Cenário 2 (Trajetória Quadrada), caracterizado por descontinuidades severas de aceleração ortogonal nos vértices, a sintonia correta demonstrou robustez ao conter o Erro Máximo Absoluto em 0,58m. Em contrapartida, a configuração não sintonizada sob regime lento ($Q = 0,01$; $R = 0,10$) falhou em acompanhar as transições abruptas, resultando em um salto do RMSE para 0,60m em *X* e 0,82m em *Y*, além de registrar um pico de erro máximo de 2,24m devido ao atraso de fase clássico.

A evolução temporal dessa métrica é detalhada na Figura 7, onde a curva de erro da condição calibrada permanece estável e contida dentro da margem operacional prevista.

Para aprofundar a avaliação do comportamento estatístico do estimador, a Figura 8 apresenta o comportamento estocástico dos resíduos de predição. Nos gráficos de dispersão e histogramas associados à condição sintonizada, nota-se que os erros de estimação em *X* e *Y* se distribuem assintoticamente como uma normal bivariada, com viés médio estatisticamente nulo ($\mu_x \approx -0,00$ m no cenário do quadrado). Quando a sintonia falha, a distribuição perde a sua característica gaussiana

e exibe caudas pesadas ou dispersões deslocadas, refletindo o descompasso geométrico e o atraso de fase na estimação dos estados.

C. Consistência Estatística e Monitoramento do NIS

A coerência entre a incerteza teórica calculada pelo filtro e os resíduos de inovação reais foi avaliada por meio da estatística *Normalized Innovation Squared* (NIS). Para o modelo rastreado por quatro torres ativas (4 graus de liberdade), a esperança teórica do NIS é exatamente $\mathbb{E}[NIS] = 4,0$. O limite crítico superior bicaudal para um nível de confiança de 95% situa-se em $\chi^2_{0,975,4} = 11,143$.

Como ilustra a Figura 9 e os dados da Tabela II, o EKF sintonizado demonstrou alto equilíbrio e consistência estatística. Os valores médios operacionais ($\overline{NIS}$) flutuaram estavelmente entre 3,34 e 3,86, aproximando-se com rigor do valor teórico esperado de 4,0. As taxas de violação do limite superior permaneceram estritamente controladas (entre 0,75% e 2,29%), validando estatisticamente a matriz de covariância do erro de estimação **P**.

Por outro lado, o perfil não sintonizado expôs dois comportamentos patológicos distintos: nos cenários de subestimação drástica do ruído de leitura ($R = 0,01$ nos Cenários 3 a 6), o filtro operou em regime severamente otimista. A média do NIS disparou (atingindo 31,67 no Cenário 6), com taxas de violação do limite crítico que superaram 84%. Nos cenários com superestimação de R combinada com redução de Q (Cenários 1 e 2), o filtro tendeu à lentidão e perda de reatividade, acumulando inovações elevadas que inflaram o $\overline{NIS}$ para 24,07 no Cenário 2, estourando o limite em mais de 50% das amostras.

D. Região de Confiança e Taxa de Inliers

A Taxa de *Inliers* (TI) quantificou a porcentagem de frames em que o erro real de posicionamento esteve contido dentro da elipse de confiança calculada pelo filtro. Nos cenários sintonizados, em decorrência da calibração exata das covariâncias, a TI apresentou desempenho ótimo, cravando 100,00% nas trajetórias suaves (Cenários 1, 3, 4, 5 e 6) e mantendo-se em patamar seguro de 96,88% na severa geometria do quadrado. Isso assegura que as elipses geradas pelo estimador refletem de forma fiel a dispersão espacial do erro. Na condição descalibrada dos Cenários 1 e 2, o estreitamento incorreto das elipses combinado ao atraso físico da trajetória fez a região de confiança colapsar, derrubando a TI para níveis críticos de 10,08% e 28,07%, respectivamente.

E. Resposta Transitória sob Oclusão (Cenário 6)

O Cenário 6 validou a estabilidade do algoritmo em malha aberta ao impor uma janela de oclusão temporária de sinal, reduzindo a Taxa de Detecção (TD) global para 90%. A Figura 10 detalha o intervalo de interrupção das medições. A modelagem cinemática consistente permitiu que a propagação de estados estimasse a posição puramente preditiva com base nas últimas velocidades calculadas. Embora o afastamento temporário do sinal tenha expandido o erro máximo absoluto

¹Disponível em: <https://github.com/SauloJose/PASKalmanTraj> - Acesso em: 22 jun. 2026.

Tabela II: Resumo das Métricas de Desempenho do EKF (Condição Sintonizada vs. Não Sintonizada)

Cenário	$RMSE_x$ [m]	$RMSE_y$ [m]	E_{max} [m]	μ_x [m]	NIS	$NIS \in IC$ [%]	TD [%]	TI [%]
CONDIÇÃO SINTONIZADA ($Q = 0,64I_6$; $R = 0,09I_4$)								
Cenário 1	0,11	0,16	0,64	+0,01	3,39	96,33	100,00	100,00
Cenário 2	0,13	0,18	0,58	0,00	3,86	95,84	100,00	96,88
Cenário 3	0,12	0,14	0,58	+0,00	3,34	96,58	100,00	100,00
Cenário 4	0,11	0,15	0,58	+0,01	3,34	97,17	100,00	100,00
Cenário 5	0,11	0,16	0,57	+0,00	3,49	96,58	100,00	100,00
Cenário 6	0,17	0,34	2,62	+0,01	3,40	95,19	90,00	100,00
CONDIÇÃO NÃO SINTONIZADA (Parâmetros Descalibrados)								
Cenário 1	0,23	0,34	0,75	+0,01	6,76	80,25	100,00	10,08
Cenário 2	0,60	0,82	2,24	-0,02	24,07	49,48	100,00	28,07
Cenário 3	0,16	0,20	0,79	+0,00	23,85	26,75	100,00	97,25
Cenário 4	0,14	0,20	0,74	+0,01	25,50	22,67	100,00	93,83
Cenário 5	0,15	0,21	0,73	+0,00	24,14	26,08	100,00	96,25
Cenário 6	0,17	0,33	2,62	+0,01	31,67	15,56	90,00	71,76

Cenários: 1: Circular; 2: Quadrada; 3: Tang. Hiperbólica; 4: Lemniscata; 5: Aleatória; 6: Oclusão.

Nota: Limites bicaudais do NIS a 95% de confiança para 4 G.L. são [0, 484; 11, 143]. TD: Taxa de Detecção; TI: Taxa de *Inliers*.




Figura 6: Ambiente gráfico desenvolvido em Python. O painel central exibe a cinemática do alvo, ladeado pelos controles de simulação à esquerda e gráficos de monitoramento temporal à direita.





Figura 7: Evolução temporal do RMSE (Cenário 2). A estabilidade da curva reflete a consistência do filtro quando devidamente sintonizado frente a manobras evasivas.

para 2,62m no ápice da oclusão, o sistema evitou o colapso numérico e restabeleceu a convergência sub-métrica imediatamente após a reconexão com as balizas, mantendo um RMSE global controlado de 0,17m em X e 0,34m em Y .


VI. CONCLUSÃO

A. Resumo e Principais Constatações

Este trabalho analisou o comportamento de um Filtro de Kalman Estendido (EKF) sob o modelo Posição-Velocidade-Aceleração (PVA) no rastreamento 2D com medições *range-only*. Em condições ideais de sintonia ($Q = 0,64$ e $R = 0,09$), o sistema apresentou alta precisão espacial (RMSE abaixo de 0,34m) e consistência estatística (NIS dentro do intervalo de confiança em mais de 95% do tempo), além de lidar com



(a) Condição Sintonizada



(b) Condição Não Sintonizada

Figura 8: Histogramas e dispersão dos erros de previsão (Cenário 2). Em (a), a condição sintonizada converge para uma distribuição normal centrada no zero. Em (b), a ausência de calibração induz dispersão irregular e acúmulo de erros de fase.




Figura 9: Comportamento temporal da métrica NIS. A calibração adequada mantém o parâmetro próximo à média teórica (4,0) e abaixo do limite crítico superior (11,14).




Figura 10: Recorte do Cenário 6 sob oclusão temporária. O EKF propaga a cinemática em malha aberta sem divergência crítica.

robustez em cenários de oclusão graças à inércia mecânica do modelo.

A principal descoberta, evidenciada ao descalibrar as matrizes intencionalmente, foi o claro desacoplamento entre precisão visual e coerência matemática. Subestimar a covariância de processo ($\mathbf{Q} = 0,01$) engessa o filtro, fazendo a Taxa de *Inliers* desabar para cerca de 10% por gerar elipses de incerteza artificialmente pequenas. Já a subestimação da medição ($\mathbf{R} = 0,01$) cria uma falsa sensação de acerto: o filtro persegue o ruído às cegas, mantendo o RMSE baixo e os *Inliers* acima de 93%. No entanto, ele opera em completa inconsistência matemática, uma falha crítica que só é exposta pelo fato do NIS estourar o limite de 11,143.

B. Contribuições

As principais entregas desta pesquisa incluem:

- O desenvolvimento de um ambiente de simulação capaz de renderizar elipses de incerteza e auditar matrizes de covariância em tempo real.
- A consolidação do uso conjunto de RMSE e NIS como ferramenta definitiva de diagnóstico, provando que erros de posição aparentes não bastam para validar o filtro.
- A formulação da Taxa de *Inliers* a partir de uma Região de Interesse (ROI) Dinâmica. Além de mensurar a coerência da crença do robô, essa estratégia abre um caminho promissor para sistemas de visão computacional, permitindo que o algoritmo processe apenas recortes preditivos da imagem.

C. Limitações e Trabalhos Futuros

O estudo limitou-se a modelar os ruídos como puramente gaussianos, desconsiderando distúrbios severos encontrados

na prática (como efeitos de *multipath* e NLOS em redes UWB), além de ter adotado um processo de calibração manual empírico.

Para solucionar essas lacunas e expandir o projeto, sugerem-se as seguintes frentes de trabalho:

- **Sintonia Automática:** Implementar algoritmos de otimização matemática (como descida de gradiente ou algoritmos genéticos) para sintonizar $\mathbf{Q}$ e $\mathbf{R}$ de forma totalmente autônoma.
- **Integração com Visão Computacional Prática:** Empregar a ROI preditiva calculada pelo EKF em fluxos reais de processamento de câmera para quantificar ganhos práticos em *Frames Por Segundo* (FPS).
- **Filtros Avançados:** Comparar este EKF com estimadores que não dependem do cálculo de matrizes Jacobianas para contornar dinâmicas altamente não lineares, como o Filtro de Kalman *Unscented* (UKF) ou Filtros de Partículas.

D. Conclusão Final

Em suma, projetar um bom estimador significa entender que quantificar a própria incerteza de maneira realista é tão vital quanto calcular a coordenada final do alvo. O equilíbrio entre a precisão macroespacial do RMSE e a auditoria interna do NIS, aliado às otimizações viabilizadas pela Taxa de *Inliers*, consolida uma base metodológica segura e eficiente para o avanço de algoritmos em robótica móvel e sistemas embarcados.

REFERÊNCIAS

- [1] Á. Odry, R. Fullér, I. J. Rudas, and P. Odry, “Kalman filter for mobile-robot attitude estimation: Novel optimized and adaptive solutions,” *Mechanical Systems and Signal Processing*, vol. 110, pp. 569–589, 2018.
- [2] G. Reina, A. Vargas, K. Nagatani, and K. Yoshida, “Adaptive kalman filtering for gps-based mobile robot localization,” in *Proceedings of the 2007 IEEE International Workshop on Safety, Security and Rescue Robotics (SSRR)*. Rome, Italy: IEEE, September 2007.
- [3] R. E. Kalman, “A new approach to linear filtering and prediction problems,” *Transactions of the ASME—Journal of Basic Engineering*, vol. 82, no. Series D, pp. 35–45, 1960.
- [4] S. Thrun, W. Burgard, and D. Fox, *Probabilistic Robotics*, ser. Intelligent Robotics and Autonomous Agents series. Cambridge, MA, USA: The MIT Press, 2005.
- [5] S. Y. Chen, “Kalman filter for robot vision: A survey,” *IEEE Transactions on Industrial Electronics*, vol. 59, no. 11, pp. 4409–4419, 2012.
- [6] P. Fałek and P. Kaniewski, “Computer application for testing kalman filter,” in *Conference Proceedings of SPIE*, vol. 11442. SPIE, 2020, p. 1144213.
- [7] K. Ogata, *Modern Control Engineering*, 5th ed. Boston, MA, USA: Prentice Hall, 2010.
- [8] Y. Bar-Shalom, X. R. Li, and T. Kirubarajan, *Estimation with Applications to Tracking and Navigation: Theory, Algorithms and Software*. New York, NY, USA: John Wiley & Sons, 2001.
- [9] D. Simon, *Optimal State Estimation: Kalman, H_∞ , and Nonlinear Approaches*. Hoboken, NJ, USA: John Wiley & Sons, 2006.
- [10] S. J. A. Silva, “Ferramenta de simulação e rastreamento bidimensional via EKF,” <https://github.com/SauloJose/PASKalmanTraj>, 2026, repositório GitHub. Acesso em: 13 jun. 2026.

APÊNDICE A

MATERIAL SUPLEMENTAR E REPOSITÓRIO DO CÓDIGO

O código-fonte completo da ferramenta de simulação desenvolvida neste trabalho está disponível publicamente para

consulta e reprodução dos testes. O repositório inclui a interface gráfica (GUI) em Python, os scripts de geração das trajetórias e a implementação matemática do EKF.

Também foram disponibilizados no link os gráficos de todas as simulações em alta resolução, incluindo as trajetórias espaciais e as métricas do NIS que não couberam na íntegra ao longo do texto.

O acesso ao código e aos dados adicionais pode ser feito pelo link:

<https://github.com/SauloJose/PASKalmanTra>

No repositório [10], é possível rodar o simulador localmente para interagir com o ajuste das matrizes $\mathbf{Q}$ e $\mathbf{R}$, além de acompanhar a variação dinâmica da janela de ROI e das elipses de incerteza do filtro em tempo real.

APÊNDICE B

MAPEAMENTO VISUAL E ESTATÍSTICO COMPLETO

Este apêndice reúne os gráficos das trajetórias espaciais e a evolução temporal do NIS para os seis cenários testados. A sequência de imagens permite comparar diretamente a precisão e a consistência do EKF sintonizado com o filtro descalibrado. Com isso, fica evidente o impacto visual da parametrização incorreta sobre as elipses de incerteza e os erros do sistema.




Figura 11: Trajetórias estimadas na **condição sintonizada**. Observa-se o rastreamento preciso da dinâmica do alvo e a mitigação contínua do ruído de observação, evidenciando o desempenho ideal do filtro.




Figura 12: Trajetórias estimadas na **condição não sintonizada**. Notam-se divergências significativas em relação à verdade terrestre (*ground truth*), com evidentes atrasos de fase e sobreposições bruscas nas curvas.




Figura 13: Evolução temporal da métrica RMSE para a **condição sintonizada**




Figura 14: Evolução temporal da métrica RMSE para a **condição não sintonizada**.




Figura 15: Evolução temporal da métrica NIS para a **condição sintonizada**. A estatística mantém-se predominantemente abaixo do limite de confiança de 95% (linha tracejada em 9,49), comprovando a consistência interna do estimador.




Figura 16: Evolução temporal da métrica NIS para a **condição não sintonizada**. A constante violação do limiar estatístico evidencia a degradação estrutural e a perda de confiança na matriz de covariância preditiva.




Figura 17: Distribuição dos resíduos (histogramas) para a **condição sintonizada**. Os perfis mantêm forte aderência à distribuição normal, indicando que as inovações do filtro são não viesadas.







Figura 18: Distribuição dos resíduos (histogramas) para a **condição não sintonizada**. Observa-se a acentuada perda de normalidade e o surgimento de assimetrias, o que caracteriza um comportamento subótimo.




(a) Círculo




(b) Quadrado




(c) Tangente Hiperbólica



(d) Lemniscata




(e) Aleatória




(f) Oclusão


Figura 19: Gráficos de dispersão (*scatter plots*) das inovações para a **condição sintonizada**. Os pontos concentram-se simetricamente em torno da origem, refletindo a eficácia do estimador na modelagem do ruído.




(a) Círculo




(b) Quadrado




(c) Tangente Hiperbólica



(d) Lemniscata



(e) Aleatória



(f) Oclusão

Figura 20: Gráficos de dispersão das inovações para a **condição não sintonizada**. A dispersão irregular e o distanciamento acentuado da origem denotam a introdução de viés e a imprecisão preditiva do modelo.